

Implementación de Técnicas de Subrogación de Modelos para el Control de Procesos No Lineales

Álvaro Páez¹, Alejandro Ardila¹, Jorge M. Gómez¹

Departamento de Ingeniería Química y de Alimentos, Universidad de los Andes
Edificio Mario Laserna. Cra. 1 Este 19A-40, Bogotá, Colombia

1 Introducción

La optimización de procesos constituye un elemento fundamental en la industria química, ya que permite mejorar la eficiencia operativa, reducir costos y mantener la competitividad en un entorno industrial cada vez más exigente. Sin embargo, la búsqueda continua de un mejor rendimiento se enfrenta al desafío de gestionar procesos químicos no lineales y altamente complejos [1], [2]. Los sistemas industriales compuestos por múltiples equipos presentan comportamientos dinámicos complejos que desafían los métodos de control convencionales, como los lazos de control por retroalimentación basados en controladores PID (Proporcional-Integral-Derivativo), en los cuales pueden presentarse demoras significativas, sensibilidad a perturbaciones y limitaciones en el manejo de interacciones entre variables [3], [4]. Con el fin de superar estas limitaciones, el Control Predictivo Basado en Modelo (Model Predictive Control, MPC) se ha consolidado como una de las estrategias de control avanzado más utilizadas en procesos industriales. Este método emplea un modelo dinámico del proceso para predecir su comportamiento futuro dentro de un horizonte de tiempo determinado y resolver, en cada instante de operación, un problema de optimización que permite determinar las acciones de control más adecuadas [5]. Gracias a su capacidad para manejar sistemas multivariables, considerar restricciones operativas y anticipar el efecto de perturbaciones, el MPC ha sido ampliamente adoptado en diversos sectores industriales. No obstante, incluso las estrategias de control avanzadas, como el MPC, presentan dificultades cuando la dinámica del proceso no se conoce con precisión o está sujeta a variaciones significativas. La complejidad numérica, caracterizada por fuertes interacciones entre variables del proceso y dinámicas no modeladas, junto con la necesidad de resolver continuamente problemas de optimización, puede traducirse en respuestas insuficientes o en la falta de convergencia del controlador. Como respuesta a estas limitaciones, en los últimos años ha surgido el uso de modelos subrogados, también conocidos como metamodelos, los cuales buscan aproximar el comportamiento de modelos rigurosos mediante representaciones matemáticas más simples construidas a partir de datos [6], [7]. Estos modelos permiten reducir significativamente la carga computacional asociada a la simulación y optimización de procesos complejos, manteniendo al mismo tiempo un nivel adecuado de precisión en la predicción del comportamiento del sistema [8], [9]. El presente trabajo se enmarca en la continuidad de una línea de investigación en la cual se desarrolló previamente la subrogación de un proceso de destilación extractiva con el objetivo de implementar estrategias de control predictivo capaces de rechazar perturbaciones en las variables del sistema [10]. En dicho estudio, se utilizó un modelo subrogado basado en representación en espacio de estados, el cual será empleado en este trabajo como referencia de comparación frente a otros métodos de identificación y modelado, específicamente los modelos ARX, ARMAX y las máquinas de soporte vectorial (Support Vector Machines, SVM).

2 Estado del arte

La implementación de controles predictivos avanzados como el control predictivo basado en modelos (MPC) se ve limitada por el alto costo computacional asociado a los modelos rigurosos que describen procesos químicos complejos. Al requerir cálculos numéricos intensivos, la subrogación de modelos surge como una técnica eficiente para representar el comportamiento del sistema mediante aproximaciones matemáticas. A través de metamodelos, es posible establecer relaciones entre variables de entrada y salida con el objetivo de mantener la integridad del control mientras se reduce la carga computacional [6]. Diversos estudios han explorado la subrogación de modelos con el propósito de integrarlos en sistemas de control predictivo.

2.1 Modelos ARX y ARMAX

Los modelos ARX (AutoRegressive with eXogenous inputs) constituyen una clase de modelos lineales de identificación de sistemas en tiempo discreto que describen la salida actual del sistema como una combinación lineal de sus salidas pasadas y de las entradas actuales y pasadas [11]. Su estructura general se expresa como:

$$A(q)\bar{y}(k) = B(q)\bar{u}(k - n_k) + \bar{e}(k) \quad (1)$$

$$A(q) = a_1 + a_2q^{-1} + \dots + a_nq^{-n_a} \quad (2)$$

$$B(q) = b_1 + b_2q^{-1} + \dots + b_nq^{-n_b+1} \quad (3)$$

En las ecuaciones 1-3, $y(k)$ representa la salida del sistema en el instante k , $u(k)$ la entrada manipulada, $A(q)$ y $B(q)$ los polinomios que contienen los parámetros del modelo, n_a y n_b el número de polos y ceros del sistema, respectivamente, y n_k el retraso del modelo. El término $e(k)$ corresponde al ruido blanco que captura las perturbaciones no modeladas y q^{-1} es el operador de retraso. Los parámetros del modelo se estiman típicamente mediante el método de mínimos cuadrados ordinarios, lo que garantiza una solución analítica cerrada [11]. Una ventaja importante de los modelos ARX en el contexto del control MPC es su compatibilidad directa con herramientas computacionales de identificación de sistemas, lo que permite su integración inmediata en esquemas de control sin necesidad de transformaciones adicionales. Estudios recientes han aplicado modelos ARX en la identificación y control de columnas de destilación, reportando desempeños adecuados incluso cuando el proceso presenta comportamientos ligeramente no lineales [12]. Sin embargo, su desempeño puede verse limitado en presencia de fuertes no linealidades, situación en la que estructuras como los modelos NARX o modelos de mayor complejidad pueden ofrecer mejores resultados [13]. No obstante, cuando el sistema presenta un nivel de ruido significativo, resulta conveniente utilizar modelos ARMAX, los cuales incorporan un término adicional que modela explícitamente la dinámica del error:

$$C(q) = c_1 + c_2q^{-1} + \dots + c_{n_c}q^{-n_c} \quad (4)$$

2.2 Representación en espacio de estados

La representación en espacio de estados describe la dinámica de un sistema mediante un conjunto de ecuaciones diferenciales de primer orden que capturan su evolución temporal a través de un conjunto de variables internas. Estas variables se agrupan en el vector de estados, el cual contiene la información mínima necesaria para caracterizar el comportamiento dinámico del proceso y establecer la relación entre las entradas y las salidas del sistema. De manera general, esta representación se expresa mediante las ecuaciones 5 y 6

$$\dot{x}(t) = Ax(t) + Bu(t) \quad (5)$$

$$y(t) = Cx(t) \quad (6)$$

Donde $x(t)$ representa un vector con las derivadas de primer orden de las variables de estado, $x(t)$ es el vector de variables de estado, $u(t)$ es el vector con las variables de entrada, $y(t)$ es el vector con las variables de salida y A , B , y C son las matrices de estado, entrada y salida respectivamente. Diversos estudios han aplicado esta formulación para modelar y controlar sistemas dinámicos complejos. Por ejemplo, utilizando una representación en espacio de estados para convertir una simulación dinámica rigurosa en un modelo matemático simplificado se puede obtener la matriz de transferencia del sistema [14], lo que permite diseñar un controlador óptimo mediante la técnica de realimentación de ganancia, facilitando el diseño del esquema de control y mejorando el desempeño dinámico del proceso. En otra investigación se empleó el espacio de estados en la identificación de sistemas dinámicos no lineales basada en datos mediante autocodificadores profundos, un tipo de redes neuronales [15]. En este enfoque, el autocodificador aprende una representación latente del sistema, es decir, un conjunto de variables internas no observables directamente, pero capaces de capturar la dinámica del proceso, que actúan como vectores de estado. Los autores validaron esta aproximación mediante simulaciones en lazo abierto y posteriormente evaluaron su desempeño dentro de un esquema de control predictivo basado en modelos (MPC) en lazo cerrado. Otros estudios han desarrollado un esquema de MPC para el control de procesos por lotes afectados por perturbaciones desconocidas y fallas en actuadores. En este trabajo emplearon una representación no mínima del espacio de estados, es decir, una formulación que incorpora más estados de los estrictamente necesarios para describir la dinámica de entrada-salida del proceso [16]. Esta ampliación permitió mejorar el desempeño en el lazo cerrado, ya que el sistema logró compensar simultáneamente las variaciones en las entradas y los errores de seguimiento.

2.3 Modelo Hammerstein–Wiener

Los modelos Hammerstein–Wiener constituyen una estructura ampliamente utilizada para la identificación de sistemas no lineales. En este enfoque, la dinámica del proceso se describe mediante un bloque lineal formulado en espacio de estados, mientras que las variables de entrada y/o salida se transforman mediante funciones no lineales estáticas, es decir, funciones sin dinámica ni memoria. En particular, el bloque Hammerstein introduce una no linealidad estática en la entrada antes del sistema lineal, mientras que el bloque Wiener aplica una transformación no lineal a la salida del sistema lineal. Esta arquitectura permite representar comportamientos no lineales al combinar un modelo dinámico lineal, responsable de describir la evolución temporal del sistema, con transformaciones estáticas que pueden capturar fenómenos como saturaciones, zonas muertas o ganancias dependientes del estado [17]. Debido a esta estructura híbrida, los modelos Hammerstein–Wiener resultan especialmente adecuados para procesos químicos, ya que mejoran la capacidad de representar relaciones no lineales entre las variables de entrada y salida del sistema.

2.4 Resumen de las estrategias de subrogación

La elección de la técnica de subrogación de modelos para el control y la optimización de procesos químicos no lineales debe basarse en las características específicas del sistema que se desea modelar. Los modelos ARX y ARMAX son adecuados cuando el proceso presenta una dinámica lineal o ligeramente no lineal, lo que permite una representación eficiente con un costo computacional bajo. Sin embargo, su aplicabilidad se ve limitada cuando el sistema presenta no linealidades complejas o perturbaciones significativas. En estos casos, las máquinas de soporte vectorial (SVM) ofrecen una mayor robustez, ya que son capaces de manejar relaciones no lineales más complejas y de generalizar bien a partir de conjuntos de datos limitados. Las SVM se convierten en una opción poderosa para sistemas con alta incertidumbre y variabilidad en sus dinámicas. A pesar de sus ventajas, su integración en esquemas de control predictivo, como el MPC, presenta desafíos debido a que los modelos no son directamente lineales y requieren técnicas adicionales para su implementación en tiempo real. Por último, la representación en espacio de estados es una opción más robusta para procesos con dinámicas altamente no lineales o para sistemas que involucren interacciones complejas entre múltiples variables. Esta técnica permite capturar de manera precisa las interacciones internas y externas del sistema, pero a costa de un mayor costo computacional, debido a la necesidad de resolver sistemas de ecuaciones diferenciales. Por todo lo anterior, se busca comparar los diferentes métodos para determinar sus diferencias en el caso propuesto. En la Tabla 1 se presenta una comparación general entre las principales estrategias de modelado utilizadas en procesos químicos.

Tabla 1. Comparación de estrategias de subrogación para control de procesos

Modelo	Tipo	No linealidad	Complejidad	Integración MPC	Aplicaciones
Espacio de estados	Lineal dinámico	Baja-media	Media	Directa	Control multivariable
ARX / ARMAX	Lineal dinámico	Media	Media	Directa	Identificación de sistemas
SVM	No lineal	Alta	Alta	Requiere MPC no lineal	Sistemas no lineales
Hammerstein-Wiener	Híbrido	Media-alta	Media	Compatible	Procesos químicos

2.5 Métodos de modelamiento de columnas de destilación

El modelamiento de columnas de destilación se basa comúnmente en el modelo MESH (Mass, Equilibrium, Summation and Heat), el cual asume equilibrio termodinámico entre las fases vapor y líquido en cada etapa de la columna [10]. El número total de ecuaciones algebraicas que describen una columna de destilación en un instante dado puede calcularse mediante:

$$N_{ec} = N(2C + 3) \quad (7)$$

donde N representa el número de etapas teóricas de la columna y C el número de componentes químicos presentes en el sistema. En simulaciones dinámicas, este sistema de ecuaciones se resuelve para cada intervalo de tiempo considerado en la discretización del proceso. Por lo tanto, el número total de ecuaciones que debe resolver el simulador se expresa como:

$$N_{et} = N_{ec} \times N_i \quad (8)$$

donde N_i representa el número de intervalos de tiempo utilizados en la simulación dinámica. El esquema general del proceso de destilación considerado en este trabajo se presenta en el Anexo correspondiente.

3 Metodología

El presente trabajo se desarrolló como una extensión y comparación del estudio realizado por Quintero y Botía et al. [10] sobre la subrogación de modelos para el control predictivo de un proceso de destilación extractiva. La metodología se estructuró en dos fases principales: (i) la replicación y verificación de la base metodológica establecida en dicho trabajo, que incluye el caso de estudio, las simulaciones rigurosas y la generación de datos dinámicos; y (ii) la implementación y evaluación de nuevas estrategias de subrogación orientadas al control. En la primera fase se utilizó el mismo caso de estudio correspondiente a la separación de una mezcla azeotrópica metanol-acetona mediante destilación extractiva con dimetilsulfóxido (DMSO) como agente separador. Inicialmente, se verificó el correcto funcionamiento del modelo del proceso en estado estacionario en Aspen Plus. Posteriormente, el proceso fue llevado a un entorno dinámico mediante Aspen Plus Dynamics, donde se implementó la estructura de control regulatorio necesaria para garantizar la estabilidad hidráulica del sistema durante la operación.

Una vez estabilizado el proceso en el entorno dinámico, se realizaron pruebas de escalón en las variables manipuladas del sistema, correspondientes al calor de rehervidor y la relación de reflujo en cada columna ($Q_{R,T-101}$, $Q_{R,T-102}$, RR_{T-101} y RR_{T-102}), mientras se monitoreó la respuesta de las variables controladas asociadas a la pureza de los productos, representadas por las temperaturas en etapas específicas de las columnas ($T_{36,T-101}$ y $T_{8,T-102}$), para obtener datos dinámicos representativos del comportamiento del sistema frente a perturbaciones.

Estos datos fueron posteriormente utilizados para la construcción de modelos subrogados capaces de aproximar el comportamiento dinámico del modelo riguroso. En el trabajo original, la subrogación del sistema se realizó mediante representaciones en espacio de estados (SS). En el presente estudio, este método de subrogación se mantiene como referencia y se implementan adicionalmente modelos ARX y ARMAX con el objetivo de comparar el desempeño de diferentes estrategias de subrogación orientadas al control. Los modelos obtenidos fueron evaluados mediante métricas estadísticas de ajuste y posteriormente integrados en un esquema de control predictivo basado en modelo (MPC) mediante una co-simulación entre Aspen Plus Dynamics y MATLAB®-Simulink®, lo que permitió analizar su desempeño frente a perturbaciones en las corrientes de alimentación del proceso.



Figura 1. Flujo del proceso de subrogación de modelos para el control predictivo

3.1 Software empleado

Para el desarrollo de las simulaciones del proceso se empleó la suite aspenONE® de Aspen Technology Inc. (versión 11), específicamente los programas Aspen Plus V11 y Aspen Plus Dynamics V11, con el objetivo de simular el proceso tanto en estado estacionario como en régimen dinámico. Los datos generados durante la simulación dinámica fueron posteriormente exportados al entorno de MATLAB® y Simulink® R2025b de MathWorks Inc. En este entorno se realizaron las tareas de procesamiento de datos, la identificación de modelos subrogados y la implementación de los esquemas de control predictivo basados en modelo (MPC). Para la identificación de los modelos ARX y ARMAX se empleó el System Identification Toolbox de MATLAB®, el cual permite estimar modelos dinámicos a partir de datos de entrada-salida obtenidos del proceso. Por otra parte, el esquema de control MPC se implementó mediante el Model Predictive Control Toolbox, lo que permitió integrar directamente los modelos identificados en el controlador y evaluar su desempeño en el entorno de co-simulación con Aspen Plus Dynamics.

3.2 Caso de estudio y simulación rigurosa

Con el fin de establecer una base de comparación consistente, se adoptó el mismo caso de estudio y el modelo riguroso desarrollado por Quintero y Botía et al. [10] correspondiente a un proceso de destilación extractiva para la separación de una mezcla azeotrópica de metanol y acetona.

3.2.1 Descripción del proceso

El proceso consiste en la separación de una mezcla azeotrópica de metanol-acetona mediante destilación extractiva utilizando dimetilsulfóxido (DMSO) como agente separador. La configuración del sistema está compuesta por dos columnas de destilación acopladas: una columna extractiva $T - 101$ y una columna de recuperación de solvente $T - 102$. En la columna extractiva $T - 101$ se introduce la mezcla azeotrópica junto con el solvente DMSO, el cual modifica el equilibrio vapor-líquido del sistema y permite romper el azeótropo. Como resultado, la acetona se obtiene en el destilado mientras que la corriente de fondo contiene metanol y solvente. Esta corriente se envía posteriormente a la columna $T - 102$, donde se realiza la recuperación del solvente mediante destilación, obteniéndose metanol en el destilado y DMSO en el fondo para su recirculación al proceso. El modelo del proceso se implementó inicialmente en Aspen Plus para verificar la consistencia de las condiciones operativas en estado estacionario antes de su análisis dinámico.

3.2.2 Esquema de control regulatorio

Para garantizar la estabilidad hidráulica y operativa del sistema durante las simulaciones dinámicas, se implementó un esquema de control regulatorio basado en controladores de retroalimentación proporcional-integral (PI). El sistema de control incluye lazos de control de nivel en los tanques de condensadores y rehervidores de ambas columnas, así como lazos de

control de presión en cada columna de destilación. Estos lazos permiten mantener condiciones de operación estables y evitar problemas operativos tales como sobrellenado de equipos o variaciones de presión dentro del sistema. La sintonización de los controladores PI se realizó mediante el método de Tyreus-Luyben, el cual se basa en la determinación de la ganancia y el período últimos del sistema para establecer los parámetros de control adecuados. Los valores finales de sintonización corresponden a los reportados por Quintero y Botía et al. [10]. Una vez implementado el esquema de control, se realizó una prueba de estabilidad del sistema para verificar su correcto funcionamiento. Para esta prueba se aplicó una perturbación tipo escalón correspondiente a un incremento del 15% en el flujo molar de la corriente de alimentación azeotrópica respecto a su valor nominal. Los resultados obtenidos confirmaron que el sistema de control regulatorio permite mantener la estabilidad hidráulica del proceso, lo que constituye una base adecuada para el análisis dinámico posterior.

3.2.3 Generación de datos dinámicos mediante pruebas de escalón

Para obtener los datos necesarios para la identificación de modelos subrogados se realizaron pruebas de escalón (step tests) en la simulación dinámica del proceso utilizando Aspen Plus Dynamics. Estas pruebas consisten en aplicar cambios escalón en las variables manipuladas del proceso y registrar la respuesta dinámica de las variables de interés, con el propósito de excitar la dinámica del sistema y generar información suficiente para la identificación de modelos dinámicos.

En el contexto de la subrogación orientada al control, las variables manipuladas consideradas fueron la potencia de los rehervidores y la razón de reflujo de cada columna. Debido a que la medición directa de fracciones molares en procesos industriales continuos puede resultar costosa o difícil de implementar, se seleccionaron las temperaturas de etapa como variables controladas, dado que presentan una fuerte correlación con la pureza de los productos. En particular, se seleccionaron la temperatura de la etapa 36 para la columna $T - 101$ y la temperatura de la etapa 8 para la columna $T - 102$, debido a su alta sensibilidad frente a cambios en las condiciones operativas.

Durante el análisis de los datos obtenidos se observó la presencia de pequeñas variaciones residuales en las señales de temperatura que no son completamente explicadas por los cambios escalón aplicados. Estas variaciones pueden interpretarse como ruido en los datos, asociado principalmente a errores de modelado y a la capacidad limitada de los modelos subrogados para reproducir completamente la dinámica del sistema, así como a efectos numéricos inherentes a la discretización temporal y a los algoritmos de integración empleados en la simulación dinámica. Este comportamiento resulta relevante para la identificación de modelos subrogados, particularmente en estructuras como los modelos ARX y ARMAX, en los cuales el término de ruido representa dinámicas no modeladas y errores de aproximación inherentes al proceso de identificación.

3.3 Subrogación de modelos

La subrogación del proceso se realizó con el objetivo de construir modelos dinámicos simplificados capaces de reproducir el comportamiento del modelo riguroso y que puedan ser utilizados dentro de esquemas de control predictivo basado en modelo. En el trabajo original de Quintero y Botía et al. [10], la subrogación se realizó mediante representaciones en espacio de estados. En el presente estudio, dicho modelo se mantiene como referencia o línea base para la comparación, y se implementan adicionalmente modelos de tipo ARX y ARMAX con el fin de evaluar su capacidad para representar la dinámica del proceso.

3.3.1 Preprocesamiento de datos

Antes de identificar los modelos, todas las variables de entrada y salida se transformaron en desviaciones respecto a su valor nominal de operación. Esta transformación permite centrar el análisis en la dinámica del proceso alrededor del punto de operación. La desviación de cada variable se calculó mediante:

$$X_{desv} = \frac{(X - X_{nominal})}{X_{nominal}} \quad (9)$$

3.3.2 Identificación de modelos subrogados

La identificación de los modelos subrogados se realizó en el entorno MATLAB® R2025b, empleando el System Identification Toolbox, a partir de los datos obtenidos de las simulaciones dinámicas del proceso. En primer lugar, se consideró como referencia el modelo en espacio de estados desarrollado en el trabajo previo. Posteriormente, se identificaron modelos de tipo ARX y ARMAX con el objetivo de evaluar su capacidad para aproximar la dinámica del proceso mediante estructuras lineales discretas. Para los modelos ARX se llevó a cabo un barrido sistemático de órdenes utilizando las funciones `arxstruc` y `selstruc` del toolbox, las cuales permiten explorar automáticamente distintas combinaciones de parámetros autorregresivos y exógenos. En este contexto, los términos autorregresivos corresponden a valores pasados de la variable de salida del sistema (temperatura de etapa), mientras que los términos exógenos representan la influencia de las variables de entrada del proceso, en este caso la potencia del rehervidor y la razón de reflujo de cada columna. Una vez determinada la estructura ARX más adecuada, esta se utilizó como base para la identificación de modelos ARMAX, variando el orden asociado al polinomio de ruido (nc) y estimando los parámetros del modelo mediante las rutinas de identificación disponibles en el

toolbox. Para cada valor de n_c , se generó un modelo candidato y se evaluó su desempeño mediante simulación frente a los datos originales. El desempeño de cada modelo, para cada columna del proceso ($T - 101$ y $T - 102$), se evaluó mediante el coeficiente de determinación (R^2) y el error cuadrático medio (RMSE) entre las salidas del modelo y los datos generados por el modelo riguroso. Estos indicadores permitieron seleccionar las estructuras con mejor capacidad predictiva para su posterior implementación en el esquema de control predictivo basado en modelo.

3.3.3 Métricas de evaluación

Para evaluar la capacidad de los modelos subrogados de reproducir la dinámica del proceso se emplearon métricas estadísticas de ajuste. En particular, se calcularon el coeficiente de determinación R^2 y la media cuadrática del error (RECM), los cuales permiten cuantificar la calidad del ajuste entre las predicciones del modelo y los datos obtenidos de la simulación rigurosa. Las métricas se calcularon según las ecuaciones 10 y 11:

$$RECM = \sqrt{\frac{\sum_{n=1}^N (y_n - \hat{y}_n)^2}{N}} \quad (10)$$

$$R^2 = 1 - \frac{\sum_{n=1}^N (y_n - \hat{y}_n)^2}{\sum_{n=1}^N (y_n - \bar{y})^2} \quad (11)$$

3.4 Implementación del control MPC y co-simulación

Con el fin de evaluar el desempeño de los modelos subrogados dentro de un entorno de control, se implementó un esquema de MPC mediante una co-simulación entre Aspen Plus Dynamics y MATLAB®-Simulink®. En este esquema, la simulación dinámica del proceso se ejecuta en Aspen Plus Dynamics, mientras que el controlador MPC se implementa en Simulink. La comunicación entre ambos entornos permite que el controlador utilice los modelos subrogados para calcular las acciones de control en cada instante. Las variables manipuladas consideradas fueron la potencia de los rehervidores y la razón de reflujo de las columnas, mientras que las variables controladas correspondieron a las temperaturas de etapa seleccionadas para cada columna. Para evaluar el desempeño del controlador se aplicaron perturbaciones de tipo escalón en los flujos de alimentación del proceso durante un horizonte dinámico de simulación de 100 horas. El desempeño del sistema de control se evaluó en términos del error relativo respecto al valor nominal de la variable controlada, del tiempo de estabilización del sistema y del esfuerzo de control requerido para mantener la operación estable.

3.4.1 Formulación del problema de optimización MPC

En cada instante de control k , el controlador MPC resuelve un problema de optimización utilizando un problema de programación cuadrática (QP). Este tiene un vector de decisión z_k que define la secuencia futura de acciones de control frente a las variables manipuladas:

$$z_k^T = [u(k|k)^T u(k+1|k)^T \dots u(k+p-1|k)^T, \epsilon_k] \quad (12)$$

$$\min_{z_k} J(z_k) = J_y(z_k) + J_u(z_k) + J_{\Delta u}(z_k) + J_\epsilon(z_k) \quad (13)$$

Dentro del vector, se optimizan dichas acciones a lo largo del horizonte de predicción p , al mismo tiempo que ϵ_k penaliza las violaciones de las restricciones. El MPC realiza la acción de la ecuación 13, minimizando una función de costo resultante de la suma de cuatro términos. El primer término J_y , formulado en la ecuación 14, compara el error entre las salidas propuestas por los metamodelos con su referencia a lo largo del horizonte, mientras que J_u , de la ecuación 15, penaliza las desviaciones de las dos variables manipuladas con respecto al valor en estado estable. Por el otro lado, el término $J_{\Delta u}$, expuesto en la ecuación 16, compara los cambios en las variables manipuladas consecutivas para evitar cambios bruscos. Por último, J_ϵ penaliza la variable de relajación asociada a posibles violaciones de restricciones, garantizando que estas solo ocurran cuando sea estrictamente necesario [18].

$$J_y(z_k) = \sum_{j=1}^{n_y} \sum_{i=1}^p \left\{ \frac{w_{i,j}^y}{s_j^y} [r_j(k+i|k) - y_j(k+i|k)] \right\}^2 \quad (14)$$

$$J_u(z_k) = \sum_{j=1}^{n_u} \sum_{i=1}^{p-1} \left\{ \frac{w_{i,j}^u}{s_j^u} [u_j(k+i|k) - u_{j,target}(k+i|k)] \right\}^2 \quad (15)$$

$$J_{\Delta u}(z_k) = \sum_{j=1}^{n_u} \sum_{i=1}^{p-1} \left\{ \frac{w_{i,j}^{\Delta u}}{s_j^u} [u_j(k+i|k) - u_j(k+i-1|k)] \right\}^2 \quad (16)$$

$$J_{\varepsilon}(z_k) = \rho_{\varepsilon} \varepsilon_k^2 \quad (17)$$

En el contexto del estudio realizado, los modelos subrogados SS, ARX y ARMAX son los responsables del cálculo de las salidas predichas y $(k+i|k)$, además de proporcionar la relación dinámica entre las variables manipuladas futuras $u(k+i|k)$ y el comportamiento esperado del proceso; permitiendo así que el optimizador evalúe el impacto de cada posible secuencia de control sobre el desempeño futuro del sistema.

3.4.2 Integración con Aspen Plus Dynamics

La co-simulación entre Simulink y Aspen Plus Dynamics se realiza mediante el intercambio de señales de entrada y salida en cada intervalo de muestreo, donde Aspen envía a Simulink las mediciones actuales de las variables controladas (temperaturas de etapa) y el controlador MPC calcula las acciones de control, las cuales son enviadas de regreso a Aspen como ajustes en la potencia de los rehervidores y en la razón de reflujo, permitiendo así cerrar el lazo de control y considerar de forma dinámica la influencia de perturbaciones externas en el proceso.

3.4.3 Evaluación del desempeño del controlador

Para cuantificar la efectividad del esquema de control implementado, se evaluó el desempeño del sistema mediante un conjunto de métricas que permiten analizar la calidad del seguimiento de referencia, la rapidez de respuesta del sistema y el esfuerzo requerido por las variables manipuladas. El error relativo de seguimiento permite cuantificar la diferencia entre el valor de la variable controlada y su valor de referencia a lo largo del tiempo. Este indicador se calcula mediante la siguiente expresión:

$$e_{rel}(t) = \frac{|Y(t) - Y_{ref}(t)|}{Y_{ref}(t)} \quad (18)$$

El tiempo de estabilización se define como el tiempo requerido para que las variables controladas ingresen y permanezcan dentro de una banda de tolerancia de $\pm 2\%$ respecto a su valor nominal después de la aplicación de una perturbación. Este indicador permite evaluar la rapidez con la que el sistema recupera condiciones estables de operación. Además, para evaluar con mayor precisión la calidad del control, se utilizaron las siguientes métricas de error integral.

El criterio de la integral del valor absoluto del error (IAE) mide el error absoluto acumulado a lo largo del tiempo y se calcula como:

$$IAE = \int_0^{\infty} |e(t)| dt \quad (19)$$

El criterio de la integral del error cuadrático mide el error cuadrático acumulado, penalizando los errores de mayor magnitud:

$$ISE = \int_0^{\infty} e^2(t) dt \quad (20)$$

Por otro lado, el criterio de la integral del valor absoluto del error multiplicado por el tiempo (ITAE) pondera los errores con el tiempo, favoreciendo la penalización de los errores que persisten durante períodos prolongados:

$$ITAE = \int_0^{\infty} t|e(t)| dt \quad (21)$$

Finalmente, la integral del error cuadrático multiplicado por el tiempo (ITSE) es una métrica análoga a la ITAE, pero incorpora el error al cuadrado, lo que incrementa la penalización de los errores de mayor magnitud y duración:

$$ITSE = \int_0^{\infty} te^2(t) dt \quad (22)$$

Estas métricas de error integral permiten una evaluación más completa del desempeño del controlador, ya que cuantifican tanto la magnitud de los errores como su persistencia en el tiempo [19]. Los resultados obtenidos con estas métricas permitieron comparar la capacidad de los distintos modelos subrogados para mantener la estabilidad del proceso, minimizar el error de seguimiento y reducir el esfuerzo de control requerido, proporcionando así una evaluación cuantitativa del desempeño de cada estrategia de modelado dentro del esquema de control predictivo basado en modelo.

4 Resultados y Discusión

Entre los resultados obtenidos, primero se comparó el ajuste de la subrogación del modelo con respecto a los datos del steptest. Posteriormente se realizó una evaluación del control por medio de los datos obtenidos en la co-simulación de Simulink y Aspen Plus Dynamics por métodos gráficos y los índices de rendimiento presentados anteriormente.

4.1 Subrogación de modelos

Los modelos subrogados se realizaron a partir de la consideración de dos entradas; la potencia del rehervidor y la relación de reflujo, con una salida de temperatura de etapa. En el caso de la $T - 101$, los modelos predicen la temperatura de la etapa 36, mientras que en la $T - 102$ se encuentra la temperatura de la etapa 8. Esto considerando los perfiles de temperatura donde se determina que estas etapas son las de mayor sesibilidad [10]. De esta manera se obtienen los 4 modelos porevaluar para las dos torres: ARX, ARMAX, SS y NLARX-SVM. Se evalúan métricas de ajuste del sistema, sin embargo, un perfecto acople no es necesario para la implementación del modelo en control predictivo. En la Tabla 2 se puede evidenciar el RMSE y el R2, los cuales presentan una pequeña mejora en el siguiente orden entre modelos: $SS < ARX < ARMAX < NARX - SVM$ para $T - 101$ y $ARX < ARMAX < SS < NARX - SVM$ para $T - 102$. No obstante, es importante recalcar el alcance de todos los metamodelos al representar la tendencia general.




Figura 2. Comparación de los modelos subrogados para el control de $T - 101$




Figura 3. Comparación de los modelos subrogados para el control de $T - 102$

Tabla 2. Métricas de las subrogaciones de control

Columna	Modelo	RECM	R^2
T-101	SS	1.4331	0.8327
T-101	ARX	1.4276	0.8340
T-101	ARMAX	1.4073	0.8387
T-102	SS	5.4304	0.7232
T-102	ARX	5.7524	0.6894
T-102	ARMAX	5.7294	0.6919

4.2 Control predictivo frente a perturbaciones

Al obtener los modelos que relacionan las variables manipuladas con la variable controlada, es posible implementar el MPC y realizar pruebas de comportamiento frente a perturbaciones. Estas son un aumento del 8% en ente. Teniendo en consideración la implementación de los modelos en el MPC, solo se realizó el control predictivo de los modelos lineales: ARX, ARMAX, SS. Los resultados comparativos se dividieron en tres partes, comenzando por los costos computacionales en la Tabla 4 que evalúan el tiempo de Simulink, el CPU utilizado por paso y la memoria RAM necesaria para la simulación. Comparando los tres modelos se evidencia que el costo de segundos en Simulink y milisegundos de CPU por paso es el menor para el modelo de espacio de estado, sin embargo, la memoria RAM es la mayor a comparación de los otros dos modelos. A pesar de esto, es posible observar que las diferencias entre costos computacionales no son amplias, por lo cual son necesarios más criterios para determinar el mejor modelo.




Figura 4. Comportamiento de la variable controlada en comparación con el valor nominal en la simulación de control $T - 101$




Figura 5. Comportamiento de la variable controlada en comparación con el valor nominal en la simulación de control $T - 102$

Continuando con las métricas de control básicas, se comparan los tiempos de estabilización y el error con respecto al setpoint para las dos perturbaciones en cada modelo. En la Tabla 5 se denota que todos los metamodelos implementados en el MPC lograron alcanzar un error menor al 1%, por lo que el objetivo de control de perturbaciones se alcanzó en los tres casos. De todos modos, se puede visualizar tanto en la tabla como en la Figura 4 y Figura 5 existen diferencias en el error y el tiempo de estabilización. En general, el modelo ARMAX generó una estabilización más rápida, de 6.7 horas aproximadamente,

cercana a valores de literatura a comparación de los otros dos modelos. Sin embargo, el error en este metamodelo aumenta; caso contrario al modelo ARX, el cual tiene los errores más pequeños; incluso llegando a 0.2% en $T - 102$ para la primera perturbación; pero aumentando considerablemente el tiempo de estabilización. Debido a que ningún modelo es concluyente al compararlos por medio del tiempo y el error, es necesario utilizar criterios integrales de desempeño para determinar cuál realiza el mejor trabajo de control.

Tabla 3. Costos computacionales

Modelo	T. Simulink (s)	CPU/paso (ms)	RAM (MB)
SS	1373.914	1136.406	6.156
ARX	1425.248	1178.865	5.9959
ARMAX	1463.379	1210.405	6.0456

Tabla 4. Métricas de las subrogaciones de control

Sistema	Modelo	P1 [°C]	P2 [°C]	SP [°C]	er_1	er_2	t_1 [h]	t_2 [h]
T-101	SS	109.93	110.19	110.73	0.72	0.49	7.42	6.42
T-101	ARMAX	109.858	110.134	110.73	0.79	0.54	6.66	5.75
T-101	ARX	110.25	110.345	110.73	0.43	0.35	6.75	11.66
T-102	SS	153.17	154.05	153.52	0.23	0.35	10.83	13.91
T-102	ARMAX	153.068	154.193	153.52	0.29	0.44	9.25	11.83
T-102	ARX	153.184	154.314	153.52	0.22	0.52	10.16	15.58

Con el objetivo de encontrar el mejor modelo para el control se implementaron los errores integrales expuestos en la sección 3.4.3. Estos permiten evaluar el desempeño del controlador a lo largo de toda la simulación, considerando tanto la magnitud de los errores como su persistencia en el tiempo. En la Tabla 5 se presentan los valores de IAE, ISE e ITAE para cada modelo y cada torre. Para $T - 101$ el modelo de espacio de estados presenta los mejores resultados en las tres métricas, mientras que para $T - 102$ el modelo ARX es el que obtiene los mejores resultados. Esto evidencia que no existe un modelo que sea mejor para ambas torres, por lo cual es necesario evaluar la posibilidad de realizar un sistema de control híbrido, donde se utilice el modelo de espacio de estados para controlar $T - 101$ y el modelo ARX para controlar $T - 102$. Evaluando los resultados de estas integrales que penalizan los errores que comete el controlador es posible identificar que para $T - 101$ el modelo de espacio de estados al tener el menor error acumulado. Sin embargo, para la $T - 102$ el metamodelo con los mejores resultados fue el ARX con una mejora considerable frente al espacio de estados. Es por lo tanto importante evaluar la posibilidad de realizar un sistema de control híbrido, para el control predictivo del sistema.

Tabla 5. Criterios integrales

Columna	Modelo	IAE	ISE	ITAE
T-101	SS	27.8556	22.8293	820.5299
T-101	ARX	29.2630	25.3459	854.7348
T-101	ARMAX	29.0401	24.9062	849.5095
T-102	SS	72.9121	271.4348	2672.708
T-102	ARX	66.4872	229.2892	2409.309
T-102	ARMAX	66.6544	229.2642	2419.636

5 Conclusiones

La subrogación de modelos para el control predictivo en sistemas no lineales como el caso de estudio planteado fue realizada exitosamente con resultados importantes a la hora de escoger un método de subrogación. Los tres modelos lograron estabilizar la variable controlada dentro de un rango de error menor al 1%. Es por ello que puede concluir que los metamodelos de espacio de estado y los modelos ARX generan respuestas precisas y rápidas frente a perturbaciones en los flujos de entrada; lográndolo por medio del control de las temperaturas de las etapas con mayor sensibilidad del proceso de destilación. Sin embargo, es importante denotar que, según el análisis del control por medio de perturbaciones establecidas, hubo diferencias entre la respuesta del MPC por modelo. A partir de estas diferencias se logró deducir que el mejor entre los tres metamodelos para controlar la $T - 101$ fue el de espacio de estados; mientras que el modelo ARX representó un mejor control predictivo para la $T - 102$. Estos resultados, al no tener en cuenta la implementación de los dos MPC en un mismo sistema, llevan a la duda de si un control mixto con dos metamodelos diferentes obtendrá resultados favorables o similares.

6 Declaración de uso de inteligencia artificial generativa

En el artículo se realizaron revisiones y correcciones generales utilizando el modelo GPT-5.3 de OpenAI LLC. Se compartieron párrafos con el objetivo de corregir errores ortográficos y de redacción básicos. Los autores asumen la responsabilidad del contenido escrito.

References

- [1] Z. Zhang, S. Li, and Y. Yang, "Explorative policy optimization for industrial-scale operation of complex process control systems," *Journal of Process Control*, vol. 152, Aug. 2025. DOI: 10.1016/j.jprocont.2025.103471
- [2] Y. Zou, X. Ma, Y. Yang, and S. Li, "An overview of chemical process operation-optimization under complex operating conditions," *Digital Chemical Engineering*, Sep. 2025. DOI: 10.1016/j.dche.2025.100249
- [3] N. Hu, "The limitations of traditional pid controllers and modern optimization methods," *Applied and Computational Engineering*, 2025. DOI: 10.54254/2755-2721/147/2025.22912
- [4] D. Mora-Mariano and A. Flores-Tlacuahuac, "A machine learning approach for the surrogate modeling of uncertain distributed process engineering models," *Chemical Engineering Research and Design*, vol. 186, pp. 433–450, Oct. 2022. DOI: 10.1016/j.cherd.2022.07.050
- [5] T. Geyer, *Model Predictive Control of High Power Converters and Industrial Drives*. John Wiley & Sons, 2017.
- [6] C. He, Y. Zhang, D. Gong, and X. Ji, "A review of surrogate-assisted evolutionary algorithms for expensive optimization problems," *Expert Systems with Applications*, May 2023. DOI: 10.1016/j.eswa.2022.119495
- [7] D. Štunek and S. Lazarova-Molnar, "Surrogate modeling: Review and opportunities for expert knowledge integration," in *Procedia Computer Science*, 2025, pp. 826–833. DOI: 10.1016/j.procs.2025.03.106
- [8] Z. T. Wilson and N. V. Sahinidis, "The alamo approach to machine learning," *Computers & Chemical Engineering*, vol. 106, pp. 785–795, Nov. 2017. DOI: 10.1016/j.compchemeng.2017.02.010
- [9] K. McBride and K. Sundmacher, "Overview of surrogate modeling in chemical process engineering," *Chemie Ingenieur Technik*, Mar. 2019. DOI: 10.1002/cite.201800091
- [10] J. E. Quintero, M. Botía, and J. M. Gómez, *Subrogación de modelos para control y optimización de procesos*, 2025.
- [11] A. Perez and Y. Yang, "Offset-free arx-based adaptive model predictive control applied to a nonlinear process," *ISA Transactions*, vol. 123, pp. 251–262, Apr. 2022. DOI: 10.1016/j.isatra.2021.05.030
- [12] H. Zhang, J. Chen, C. Hua, Z. Ding, P. Lu, and C. Yang, "Proportional-integral control and arx-based model predictive control for extractive dividing wall column," *Chemical Engineering and Processing*, vol. 196, Feb. 2024. DOI: 10.1016/j.cep.2023.109643
- [13] J. Jin, S. Wu, A. Nuerlan, Y. Liu, and J. Wan, "Adaptive model predictive control of sodium-cooled fast reactor core based on arx modeling and kalman filtering," *Annals of Nuclear Energy*, vol. 232, p. 112215, Jul. 2026. DOI: 10.1016/j.anucene.2026.112215
- [14] J. M. Barrios Sánchez and R. Baeza Serrato, "Design and development of an optimal control model in system dynamics through state-space representation," *Applied Sciences*, vol. 13, no. 12, Jun. 2023. DOI: 10.3390/app13127154
- [15] D. Masti and A. Bemporad, "Learning nonlinear state-space models using autoencoders," *Automatica*, vol. 129, Jul. 2021. DOI: 10.1016/j.automatica.2021.109666
- [16] R. Zhang, J. Lu, H. Qu, and F. Gao, "State space model predictive fault-tolerant control for batch processes with partial actuator failure," *Journal of Process Control*, vol. 24, no. 5, pp. 613–620, 2014. DOI: 10.1016/j.jprocont.2014.03.004
- [17] M. Ławryńczuk, "Nonlinear predictive control for hammerstein-wiener systems," *ISA Transactions*, vol. 55, pp. 49–62, Mar. 2015. DOI: 10.1016/j.isatra.2014.09.018
- [18] MathWorks, *Qp optimization problem for linear mpc*, Accessed: March 9, 2026, 2026. [Online]. Available: <https://la.mathworks.com/help/mpc/ug/optimization-problem.html>
- [19] G. Guna, D. Prabhakaran, and M. Thirumarimurugan, "Design, implementation, control and optimization of single stage pilot scale reverse osmosis process," *Water Science and Technology*, vol. 84, no. 10–11, pp. 2923–2942, Nov. 2021. DOI: 10.2166/wst.2021.302

Nomenclature

A. Latin symbols

Symbol	Description	Unit
A	State matrix of the state-space model (Eqs. 5–6)	–
$A(q)$	Autoregressive polynomial in the ARX/ARMAX model (Eqs. 1–2)	–
a_i	Coefficients of the autoregressive polynomial $A(q)$, $i = 1, \dots, n_a$	–
B	Input matrix of the state-space model (Eq. 5)	–
$B(q)$	Input polynomial in the ARX/ARMAX model (Eqs. 1, 3)	–

b_i	Coefficients of the input polynomial $B(q)$, $i = 1, \dots, n_b$	—
C	Output matrix of the state-space model (Eq. 6)	—
C	Number of chemical components in the MESH distillation model (Eq. 7)	—
$C(q)$	Noise polynomial in the ARMAX model (Eq. 4)	—
c_i	Coefficients of the noise polynomial $C(q)$, $i = 1, \dots, n_c$	—
$e(k)$	White-noise / unmodeled disturbance term in ARX (discrete time)	—
$\bar{e}(k)$	Discrete-time noise signal in the ARX/ARMAX formulation (Eq. 1)	—
$e(t)$	Control tracking error (continuous time), used in IAE, ISE, ITAE, ITSE	°C
$e_{rel}(t)$	Relative tracking error between controlled variable and setpoint (Eq. 18)	—
er_1, er_2	Relative steady-state errors after the first and second disturbances (Table 4)	—
i	Prediction-step index within the MPC horizon ($i = 1, \dots, p$)	—
j	Controlled-output or manipulated-variable index	—
$J(z_k)$	Total MPC cost (objective) function (Eq. 13)	—
$J_y(z_k)$	Output tracking term of the MPC cost function (Eq. 14)	—
$J_u(z_k)$	Manipulated-variable penalty term of the MPC cost function (Eq. 15)	—
$J_{\Delta u}(z_k)$	Control-move rate-of-change penalty term of the MPC cost function (Eq. 16)	—
$J_\epsilon(z_k)$	Slack-variable penalty term of the MPC cost function (Eq. 17)	—
k	Current discrete-time step index	—
n	Sample index used in the RECM and R^2 summations (Eqs. 10–11)	—
n_a	Order of the autoregressive polynomial $A(q)$ (number of poles)	—
n_b	Order of the input polynomial $B(q)$ (number of zeros)	—
n_c	Order of the noise polynomial $C(q)$ in the ARMAX model	—
n_k	Input delay of the ARX/ARMAX model (number of samples) (Eq. 1)	—
n_u	Number of manipulated variables in the MPC formulation	—
n_y	Number of controlled output variables in the MPC formulation	—
N	Number of data samples used in the RECM and R^2 calculations (Eqs. 10–11)	—
N	Number of theoretical stages in the distillation column (MESH model, Eq. 7)	—
N_{ec}	Number of algebraic equations describing the column at a given instant (Eq. 7)	—
N_{et}	Total number of equations solved throughout the dynamic simulation (Eq. 8)	—
N_i	Number of time intervals in the dynamic simulation (Eq. 8)	—
p	MPC prediction horizon length (Eqs. 12–16)	steps
P_1	Controlled-variable temperature after the first disturbance (Table 4)	°C
P_2	Controlled-variable temperature after the second disturbance (Table 4)	°C
q	Forward shift operator	—
q^{-1}	Backward shift (unit-delay) operator	—
Q_R	Reboiler heat duty (generic)	kW
$Q_{R,T-101}$	Reboiler heat duty of the extractive column T-101 (manipulated variable)	kW
$Q_{R,T-102}$	Reboiler heat duty of the solvent-recovery column T-102 (manipulated variable)	kW
R^2	Coefficient of determination (goodness-of-fit metric, Eq. 11)	—
$r_j(k+i k)$	Predicted reference (setpoint) for output j at prediction step i (Eq. 14)	—
$RECM$	Root mean square error — Raíz del Error Cuadrático Medio (Eq. 10)	°C
RR_{T-101}	Reflux ratio of column T-101 (manipulated variable)	—
RR_{T-102}	Reflux ratio of column T-102 (manipulated variable)	—
s_j^u	Scaling factor for manipulated variable j in the MPC cost (Eqs. 15–16)	—
s_j^y	Scaling factor for output variable j in the MPC cost (Eq. 14)	—
SP	Setpoint (reference) temperature (Table 4)	°C
t	Continuous time; also integration variable in IAE, ISE, ITAE, ITSE	h
t_1	Settling time after the first disturbance (Table 4)	h
t_2	Settling time after the second disturbance (Table 4)	h
T	Temperature (generic)	°C
$T_{36,T-101}$	Temperature at stage 36 of column T-101 — controlled variable for T-101	°C
$T_{8,T-102}$	Temperature at stage 8 of column T-102 — controlled variable for T-102	°C
u	Manipulated variable (generic)	—
$u(k)$	Discrete-time manipulated-variable signal	—
$\bar{u}(k)$	Discrete-time input signal in the ARX/ARMAX formulation (Eq. 1)	—
$u(t)$	Continuous-time input vector (state-space, Eq. 5)	—
$u_j(k+i k)$	Predicted manipulated variable j at prediction step i (Eqs. 15–16)	—
$u_{j,target}(k+i k)$	Target (desired steady-state) value for manipulated variable j (Eq. 15)	—
$w_{i,j}^y$	MPC tuning weight for output j at prediction step i (Eq. 14)	—
$w_{i,j}^u$	MPC tuning weight for manipulated variable j at prediction step i (Eq. 15)	—
$w_{i,j}^{\Delta u}$	MPC tuning weight for the rate of change of manipulated variable j (Eq. 16)	—
$x(t)$	Continuous-time state vector (Eq. 5)	—
$\dot{x}(t)$	Time derivative of the state vector (Eq. 5)	—
X	Generic process variable used in the deviation normalisation (Eq. 9)	—
X_{desv}	Relative deviation of variable X from its nominal operating value (Eq. 9)	—
$X_{nominal}$	Nominal (steady-state) operating value of variable X (Eq. 9)	—
y	Controlled output variable (generic)	—
$y(k)$	Discrete-time system output signal (ARX/ARMAX inline description)	—

$\bar{y}(k)$	Discrete-time output signal in the ARX/ARMAX formulation (Eq. 1)	–
$y(t)$	Continuous-time output vector (state-space, Eq. 6)	–
$y_j(k+i k)$	Predicted controlled output j at prediction step i (Eqs. 14)	–
y_n	Observed (rigorous-model) output at sample n (Eqs. 10–11)	–
$\hat{y}_n$	Surrogate-model predicted output at sample n (Eqs. 10–11)	–
$\bar{y}$	Mean of the observed output samples; used in R^2 denominator (Eq. 11)	–
$Y(t)$	Controlled process output in continuous time (Eq. 18)	°C
$Y_{ref}(t)$	Reference (setpoint) value of the process output (Eq. 18)	°C
z_k	MPC decision vector — sequence of future control moves and slack variable (Eq. 12)	–
z_k^T	Transpose of the MPC decision vector (Eq. 12)	–

B. Greek symbols

Symbol	Description	Unit
Δ	Finite-difference / increment operator (e.g. Δu : change in manipulated variable)	–
ε_k	Slack variable for soft-constraint relaxation at time step k (written ϵ_k in Eq. 12 and ε_k in Eq. 17; both refer to the same variable)	–
ρ_ε	Penalty coefficient on the slack variable in the MPC cost (Eq. 17)	–

C. Subscripts

Subscript	Description
36	Stage 36 of column T-101 (temperature measurement location)
8	Stage 8 of column T-102 (temperature measurement location)
a	Autoregressive polynomial order
b	Input polynomial order
c	Noise polynomial order
$desv$	Relative deviation from the nominal operating point
ec	Algebraic equation count (MESH model)
et	Total equation count in the dynamic simulation
i	Prediction-step index within the MPC horizon
j	Controlled-output or manipulated-variable index
k	Current discrete-time step
n	Sample index in statistical fit metrics (RECM, R^2)
$nominal$	Nominal (steady-state) operating value
R	Reboiler (used in Q_R , $Q_{R,T-101}$, etc.)
ref	Reference (setpoint) value
rel	Relative quantity
$target$	Desired steady-state target for a manipulated variable
T-101	Extractive distillation column identifier
T-102	Solvent-recovery distillation column identifier

D. Superscripts

Superscript	Description
T	Transpose of a matrix or vector
$\hat{}$	Estimated (surrogate-model predicted) value
$\bar{}$	Mean value; also used in ARX/ARMAX overbar signal notation
Δu	Rate-of-change of the manipulated variable (as tuning-weight superscript)
u	Manipulated-variable quantity (as scaling or tuning-weight superscript)
y	Controlled-output quantity (as scaling or tuning-weight superscript)
-1	Unit-delay operation on shift operator q

E. Abbreviations

Abbreviation	Description
ARMAX	AutoRegressive Moving Average with eXogenous inputs
ARX	AutoRegressive with eXogenous inputs
CPU	Central Processing Unit
DMSO	Dimethyl sulfoxide (extractive distillation solvent)
IAE	Integral of Absolute Error (Eq. 19)
ISE	Integral of Squared Error (Eq. 20)
ITAE	Integral of Time-weighted Absolute Error (Eq. 21)
ITSE	Integral of Time-weighted Squared Error (Eq. 22)
MESH	Mass, Equilibrium, Summation, and Heat (distillation modelling framework)
MPC	Model Predictive Control
NARX	Nonlinear AutoRegressive with eXogenous inputs
NLARX-SVM	Nonlinear ARX model coupled with a Support Vector Machine
PFD	Process Flow Diagram
PI	Proportional-Integral controller
PID	Proportional-Integral-Derivative controller
QP	Quadratic Programming
RAM	Random Access Memory
RECM	Raíz del Error Cuadrático Medio (Spanish equivalent of RMSE, Eq. 10)
RMSE	Root Mean Square Error
SS	State Space
SVM	Support Vector Machine

7 Anexos

7.1 Diagramas




Figura 6. Diagrama del proceso de destilación extractiva.




Figura 7. Diagrama del control implementado en Simulink.

7.2 Parámetros de los metamodelos

Tabla 7. Parámetros de modelos de subrogación para T-101

Modelo	Entrada	Parámetros
SS-T101	–	$A = [40.8, -41.47, -3.201, -2.235, -3.453, 4.586]$ $B = [0.165, -18.52, -1.84, -11.35, 0.8057, 7.268]$ $C = [10.59, 1.733, -2.845, -9.098, 0.9113, 2.971]$
ARX-T101	–	$A = [1.000, -1.354, 0.198, -0.003, 0.119, 0.085, 0.011, -0.024, -0.026, -0.036, 0.022, 0.005, -0.002, -0.002, 0.007]$ $B = [0.000, 0.164, -0.158, -0.027, -0.009, 0.012, 0.018, 0.011, 0.003, -0.008, -0.007, 0.002, 0.001, 0.000, -0.002]$
ARMAX-T101	–	$A = [1.000, -2.486, 2.019, -0.616, 0.179, -0.051, -0.050, -0.013, 0.004, -0.015, 0.054, -0.021, -0.005, 0.002, -0.000]$ $B = [0.000, 0.164, -0.343, 0.199, -0.024, 0.014, 0.002, -0.006, -0.005, -0.008, 0.003, 0.007, -0.001, -0.001, -0.001]$ $C = [1.000, -1.133, 0.288]$

Tabla 8. Parámetros de modelos de subrogación para T-102

Modelo	Entrada	Parámetros
SS-T102	–	$A = [-12.31, -3.067, 7.829, -8.206, -13.97, -8.776, -6.807, 5.213]$ $B = [-0.7859, -0.3498, 19.37, -3.938, -7.507, -2.394, 1.11, -0.09381]$ $C = [-7.394, -19, 0.3128, 13.91, 22.35, 7.993, 10.39, -5.793]$
ARX-T102	–	$A = [1.000, -1.756, 0.895, -0.162, 0.208, -0.086, -0.304, 0.270, -0.064, 0.060, -0.093, 0.000, 0.058, -0.039, 0.012]$ $B = [0.000, 0.310, -0.411, 0.085, 0.018, 0.115, -0.002, -0.174, 0.054, 0.016, 0.035, -0.036, -0.024, 0.021, -0.008]$
ARMAX-T102	–	$A = [1.000, -2.185, 2.223, -1.556, 0.797, -0.272, -0.152, 0.339, -0.321, 0.225, -0.154, 0.061, 0.018, -0.043, 0.021]$ $B = [0.000, 0.310, -0.544, 0.440, -0.255, 0.158, -0.041, -0.109, 0.123, -0.098, 0.058, -0.043, 0.005, 0.014, -0.015]$ $C = [1.000, -0.431, 0.581]$