

Implementación de Técnicas de Subrogación de Modelos para el Control de Procesos No Lineales

Álvaro Páez¹, Alejandro Ardila¹, Jorge M. Gómez¹

Departamento de Ingeniería Química y de Alimentos, Universidad de los Andes
Edificio Mario Laserna. Cra. 1 Este 19A-40, Bogotá, Colombia

1 Introducción

La optimización de procesos es fundamental en la industria química, debido a que constituye un factor clave para mejorar la eficiencia operativa, reducir costos y mantener una ventaja competitiva en el mercado global. Sin embargo, la búsqueda continua de un mejor rendimiento se enfrenta al desafío de gestionar procesos químicos no lineales y altamente complejos [1], [2]. Los sistemas industriales compuestos por múltiples equipos presentan comportamientos dinámicos complejos caracterizados por fuertes interacciones entre variables, no linealidades y acoplamientos que dificultan su análisis y control [3], [4]. Estas características representan un desafío significativo para los métodos de control convencionales, particularmente aquellos basados en lazos de control independientes, como los controladores PID (Proporcional-Integral-Derivativo), los cuales pueden presentar limitaciones en el manejo de dichas interacciones, así como sensibilidad a perturbaciones y efectos de retardo. Como consecuencia, pueden generarse respuestas lentas, sobreoscilaciones y dificultades para mantener la estabilidad y el desempeño óptimo del proceso. Estas características pueden generar respuestas lentas, sobreoscilaciones y dificultades para mantener la estabilidad y el desempeño óptimo del proceso. Con el fin de superar estas limitaciones, el Control Predictivo Basado en Modelo (Model Predictive Control, MPC) se ha consolidado como una de las estrategias de control avanzadas más utilizadas en procesos industriales. Este método emplea un modelo dinámico del proceso para predecir su comportamiento futuro dentro de un horizonte de tiempo determinado y resolver, en cada instante de operación, un problema de optimización que permite determinar las acciones de control más adecuadas [5]. Gracias a su capacidad para manejar sistemas multivariables, considerar restricciones operativas y anticipar el efecto de perturbaciones, el MPC ha sido ampliamente adoptado en diversos sectores industriales. No obstante, incluso las estrategias de control avanzadas, como el MPC, presentan dificultades cuando la dinámica del proceso no se conoce con precisión o está sujeta a variaciones significativas. La complejidad numérica, caracterizada por fuertes interacciones entre variables del proceso y dinámicas no modeladas, junto con la necesidad de resolver continuamente problemas de optimización, puede traducirse en respuestas insuficientes o en la falta de convergencia del controlador. Como respuesta a estas limitaciones, en los últimos años ha surgido el uso de modelos subrogados, también conocidos como metamodelos, los cuales buscan aproximar el comportamiento de modelos rigurosos mediante representaciones matemáticas más simples construidas a partir de datos [6], [7]. Estos modelos permiten reducir significativamente la carga computacional asociada a la simulación y optimización de procesos complejos, manteniendo al mismo tiempo un nivel adecuado de precisión en la predicción del comportamiento del sistema [8], [9]. El presente trabajo se enmarca en la continuidad de una línea de investigación en la cual se desarrolló previamente la subrogación de control para un proceso químico complejo con el objetivo de implementar estrategias de control predictivo orientadas al rechazo de perturbaciones en las variables del sistema [10]. En dicho estudio se utilizó un modelo subrogado basado en representación en espacio de estados, el cual será empleado en este trabajo como referencia de comparación frente a otros métodos de identificación y modelado, específicamente los modelos ARX, ARMAX, de primer orden con tiempo muerto (FOPDT) y modelos basados en función de transferencia.

2 Estado del arte

La implementación de controles predictivos avanzados como el control predictivo basado en modelos (Model Predictive Control, MPC) se ve limitada por el alto costo computacional asociado a los modelos rigurosos que describen procesos químicos complejos. Estos modelos requieren la solución numérica de sistemas de ecuaciones diferenciales y algebraicas de gran dimensión, lo que incrementa significativamente el tiempo de cálculo cuando se utilizan dentro de algoritmos de optimización en tiempo real. En este contexto, la subrogación de modelos surge como una técnica eficiente para representar el comportamiento dinámico del sistema mediante aproximaciones matemáticas de menor complejidad. A través de metamodelos, es posible establecer relaciones entre variables de entrada y salida con el objetivo de mantener la integridad del control mientras se reduce la carga computacional [6]. Diversos estudios han explorado la subrogación de modelos con el propósito de integrarlos en sistemas de control predictivo aplicados a procesos químicos complejos, incluyendo sistemas de separación por destilación.

2.1 Modelos ARX y ARMAX

Los modelos ARX (AutoRegressive with eXogenous inputs) constituyen una clase de modelos lineales de identificación de sistemas en tiempo discreto que describen la salida actual del sistema como una combinación lineal de sus salidas pasadas y de las entradas actuales y pasadas [11]. Su estructura general se expresa como:

$$A(q)y(k) = B(q)u(k - n_k) + e(k) \quad (1)$$

$$A(q) = 1 + a_1q^{-1} + a_2q^{-2} + \dots + a_{n_a}q^{-n_a} \quad (2)$$

$$B(q) = b_1q^{-1} + b_2q^{-2} + \dots + b_{n_b}q^{-n_b} \quad (3)$$

donde $y(k)$ representa la salida del sistema en el instante discreto k , $u(k)$ corresponde a la entrada manipulada, $A(q)$ y $B(q)$ son los polinomios que contienen los parámetros del modelo, n_a y n_b representan el número de polos y ceros del sistema, respectivamente, y n_k es el retraso del modelo. El término $e(k)$ corresponde al ruido blanco que captura perturbaciones no modeladas, mientras que q^{-1} representa el operador de retraso temporal. Los parámetros del modelo se estiman típicamente mediante el método de mínimos cuadrados ordinarios, lo que permite obtener una solución analítica cerrada y computacionalmente eficiente [11]. Una ventaja particular de los modelos ARX en el contexto del control predictivo es su compatibilidad directa con herramientas de identificación de sistemas utilizadas en la industria, lo que facilita su integración en esquemas de control sin necesidad de conversiones adicionales y reduce el riesgo de inconsistencias en la discretización del modelo. El término de ruido en los modelos ARX tiene una interpretación física relevante en el contexto de simulaciones dinámicas de procesos químicos, ya que puede representar perturbaciones no medidas, incertidumbre en los parámetros termodinámicos del simulador o errores asociados a la discretización temporal del modelo. Estudios recientes han aplicado modelos ARX para la identificación y control de columnas de destilación, reportando desempeños adecuados incluso cuando el proceso presenta comportamientos dinámicos ligeramente no lineales. Sin embargo, su desempeño puede verse limitado en presencia de no linealidades significativas o altos niveles de ruido en los datos. Cuando el sistema presenta perturbaciones importantes o dinámicas de error más complejas, resulta conveniente utilizar modelos ARMAX (AutoRegressive Moving Average with eXogenous inputs), los cuales incorporan un término adicional que modela explícitamente la dinámica del error:

$$C(q) = 1 + c_1q^{-1} + c_2q^{-2} + \dots + c_{n_c}q^{-n_c} \quad (4)$$

Esta extensión permite mejorar la capacidad predictiva del modelo al capturar correlaciones temporales en el ruido del sistema, lo que resulta especialmente útil en aplicaciones de control predictivo donde la precisión del modelo influye directamente en el desempeño del controlador. Sin embargo, la inclusión del término de media móvil también incrementa la complejidad del proceso de identificación y puede requerir un mayor volumen de datos para obtener estimaciones confiables de los parámetros del modelo. En general, los modelos ARMAX pueden ofrecer un mejor desempeño en términos de precisión de predicción y robustez frente a perturbaciones, aunque su implementación puede ser más compleja en comparación con los modelos ARX, lo que debe ser considerado al seleccionar la estrategia de modelado para su integración en esquemas de control predictivo.

2.2 Modelo de primer orden con tiempo muerto (FOPDT)

Los modelos de tipo FOPDT representan dinámicamente un sistema por medio de parámetros identificables como la ganancia K_p , la constante de tiempo τ y el tiempo muerto θ . Las ganancias proporcionales tienen una interpretación física directa al relacionar las unidades de cambio entre variables. Conjuntamente, la constante de tiempo se interpreta como la velocidad de respuesta del sistema; la cual, a su vez, se complementa con el tiempo muerto al ser el tiempo antes de que el sistema reaccione frente a un cambio. Estos parámetros juntos son una representación comúnmente utilizada en procesos de control por su interpretabilidad y simpleza, subrogando en diferentes casos problemas SISO (Single Input, Single Output) [12]. La fórmula general del modelo es la siguiente:

$$y(s) = \sum_{i=1}^n \left(\frac{K_{p,i}}{1 + \tau_i s} e^{-\theta_i s} \right) u_i(s) \quad (5)$$

Para el caso de estudio proporcionado por Quintero y Botía et al. [10], que plantea un problema de control MISO, es importante notar que los parámetros del modelo se representan como una matriz de valores, uno para cada variable manipulada u_i [13]. Se han realizado diversos trabajos con modelos FOPDT en el contexto de control predictivo, tanto en procesos de producción de hidrógeno como en sistemas de destilación. Adjisetiya y Wahid et al. [14] compararon estrategias de control predictivo basadas en modelos FOPDT formulados desde enfoques SISO y MIMO, desarrollando controladores MPC para cuatro compresores en un proceso de generación de biogás a partir de biomasa. Al comparar los resultados experimentales, los autores reportan un mejor desempeño en los modelos MIMO más robustos; sin embargo, también señalan que en algunos casos la mejora no es significativa, e incluso que modelos con menor número de variables pueden presentar mejores respuestas. En un caso más cercano al presente estudio, Setiawan y Alifah et al. [15] realizaron una comparación entre un MPC no lineal

basado en redes neuronales y un MPC lineal basado en modelos FOPDT, aplicado a un proceso de destilación criogénica de gas natural licuado. Los autores identificaron dificultades en el modelo no lineal debido a discrepancias entre los valores de planta y del modelo. Solo tras modificar la función de costo del MPC, el modelo basado en redes neuronales logró superar el desempeño del modelo FOPDT. Estos resultados sugieren que, aunque los modelos FOPDT pueden ser adecuados para representar sistemas con comportamiento predominantemente lineal o con dinámicas moderadamente complejas, su desempeño puede verse limitado en presencia de no linealidades significativas o fuertes interacciones entre variables. Por lo tanto, es fundamental evaluar cuidadosamente la aplicabilidad de estos modelos en función de las características dinámicas del proceso y de los requerimientos específicos del esquema de control predictivo a implementar.

2.3 Modelo de función de transferencia identificable

Una representación del control mediante funciones de transferencia es una opción clásica en el desarrollo de lazos de control. Estas pueden derivarse a partir de un análisis riguroso del sistema o bien identificarse a partir de datos, reduciendo así la complejidad del modelado. Los modelos de función de transferencia poseen parámetros identificables en el denominador, a_p , y en el numerador, b_z , además de un posible retraso temporal τ . Este tipo de modelo es similar a los modelos FOPDT, con la diferencia de que sus parámetros no tienen un significado físico directo.

$$y(s) = \sum_{i=1}^n e^{-\tau s} \frac{b_z s^z + b_{z-1} s^{z-1} + \dots + b_0}{a_p s^p + a_{p-1} s^{p-1} + \dots + a_0} u_i(s) \quad (6)$$

La estructura general del modelo para un problema MISO se presenta a continuación [16]. En esta, n representa el número de variables de entrada, p el número de polos y z el número de ceros, siendo estos los parámetros estructurales que definen el modelo final en tiempo continuo s . De esta forma, se logra relacionar la variable controlada y con las variables manipuladas u y modelar la dinámica del sistema. Este enfoque lineal ha sido utilizado en diversos estudios de control predictivo, tanto en generadores eléctricos como en procesos químicos complejos. Al-Khamis y Gumis et al. [17] presentan un estudio comparativo entre un modelo en espacio de estados y un modelo basado en funciones de transferencia para el control predictivo de un generador de inducción. Sus resultados indican que el modelo de función de transferencia reduce el esfuerzo matemático, alcanza el estado estacionario más rápidamente y, en general, presenta un mejor desempeño que el modelo en espacio de estados. Por otro lado, Zhou y Zhu et al. [18] proponen un método de aislamiento de fallos en procesos químicos complejos, como el *Tennessee Eastman Process*. Los resultados obtenidos son prometedores, ya que logran implementar un algoritmo MPC basado en un modelo identificado mediante funciones de transferencia. Sin embargo, no se encontraron estudios que utilicen este tipo de modelo con el objetivo específico de rechazo de perturbaciones.

2.4 Representación en espacio de estados

La representación en espacio de estados describe la dinámica de un sistema mediante un conjunto de ecuaciones diferenciales de primer orden que capturan su evolución temporal a través de variables internas denominadas estados. Esta formulación es particularmente adecuada para sistemas multivariados y para el diseño de estrategias de control avanzadas.

$$\dot{x}(t) = Ax(t) + Bu(t) \quad (7)$$

$$y(t) = Cx(t) \quad (8)$$

donde $x(t)$ representa el vector de variables de estado, $u(t)$ corresponde al vector de entradas manipuladas, $y(t)$ representa el vector de salidas del sistema y A , B y C son las matrices que describen la dinámica del proceso. La representación en espacio de estados resulta especialmente útil en el diseño de controladores predictivos debido a su capacidad para manejar sistemas multivariados y restricciones operativas. No obstante, el incremento en la dimensión del vector de estados puede aumentar la complejidad computacional del problema de optimización, lo que motiva la búsqueda de modelos subrogados más simples para su implementación en tiempo real. Diversos estudios han aplicado la representación en espacio de estados para el diseño de controladores predictivos en procesos químicos complejos, reportando que esta formulación puede mejorar el desempeño del controlador al capturar dinámicas multivariadas y no lineales de manera más precisa. Sin embargo, la implementación de esta representación puede requerir un mayor esfuerzo computacional, lo que debe ser considerado al seleccionar la estrategia de modelado para su integración en esquemas de control predictivo.

2.5 Modelo Hammerstein–Wiener

Los modelos Hammerstein–Wiener constituyen una estructura ampliamente utilizada para la identificación de sistemas no lineales. En este enfoque, la dinámica del proceso se describe mediante un bloque lineal combinado con funciones no lineales estáticas aplicadas a la entrada y/o a la salida del sistema. Esta arquitectura permite representar comportamientos no lineales al combinar un modelo dinámico lineal con transformaciones estáticas capaces de capturar fenómenos como saturaciones, zonas muertas o ganancias dependientes del estado. Debido a esta estructura híbrida, los modelos Hammerstein–Wiener

resultan adecuados para procesos químicos en los que las relaciones entre variables presentan no linealidades moderadas. A pesar de su capacidad para representar no linealidades, la identificación y validación de estos modelos puede requerir un mayor volumen de datos y un proceso de ajuste más complejo, lo que puede limitar su aplicación en entornos donde se requiere implementación en tiempo real o integración directa con algoritmos de control predictivo.

2.6 Resumen de las estrategias de subrogación

La elección de la técnica de subrogación debe basarse en las características dinámicas del proceso, el nivel de no linealidad presente en el sistema y los requerimientos computacionales del esquema de control. Los modelos ARX y ARMAX representan alternativas eficientes para sistemas con dinámicas predominantemente lineales o ligeramente no lineales, mientras que los modelos FOPDT y las funciones de transferencia proporcionan estructuras simples y de fácil interpretación que facilitan su implementación en aplicaciones industriales. Por su parte, la representación en espacio de estados permite describir sistemas multivariados complejos y constituye la base de muchas formulaciones de control predictivo. Sin embargo, esta formulación puede implicar un mayor costo computacional debido al incremento en el número de variables del sistema. En este contexto, el presente trabajo evalúa diferentes estrategias de modelado dinámico con el objetivo de determinar sus diferencias y su desempeño en un problema de control predictivo aplicado a una columna de destilación extractiva bajo condiciones de perturbación. El análisis se centra en la comparación de modelos ARX, ARMAX, FOPDT, función de transferencia y espacio de estados, considerando tanto criterios computacionales como indicadores de desempeño dinámico para determinar la estrategia de modelado más adecuada para su integración en un esquema de control predictivo en tiempo real.

Tabla 1. Comparación de estrategias de subrogación para control de procesos

Modelo	Tipo	Capacidad para no linealidades	Complejidad computacional	Integración con MPC	Aplicaciones típicas
Espacio de estados	Lineal dinámico	Baja-media	Media	Directa	Control multivariable
ARX y ARMAX	Lineal dinámico	Media	Media	Directa	Identificación de sistemas y control multivariable
FOPDT (First Order Plus Dead Time)	Lineal dinámico con parámetros físicos	Baja	Baja	Directa	Procesos térmicos, destilación, sistemas SISO/MISO
Función de transferencia identificable	Lineal dinámico	Baja-media	Baja-media	Directa	Modelado empírico del proceso
Hammerstein-Wiener	Híbrido lineal-no lineal	Media-alta	Media	Compatible con MPC no lineal	Procesos químicos no lineales

2.7 Métodos de modelamiento de columnas de destilación

El modelamiento de columnas de destilación se basa comúnmente en el modelo MESH (Mass, Equilibrium, Summation and Heat), el cual asume equilibrio termodinámico entre las fases vapor y líquido en cada etapa de la columna. Este enfoque constituye la base de la mayoría de los simuladores comerciales de procesos químicos. Debido al elevado número de ecuaciones que deben resolverse en cada instante de tiempo, los modelos dinámicos rigurosos presentan una alta carga computacional, especialmente cuando se utilizan dentro de algoritmos de optimización en tiempo real. Esta característica justifica el uso de modelos subrogados que permitan representar la dinámica del sistema con un menor costo computacional. El número total de ecuaciones algebraicas que describen una columna de destilación en un instante dado puede calcularse mediante:

$$N_{ec} = N(2C + 3) \quad (9)$$

donde: N corresponde al número de etapas y C al número de componentes. En simulaciones dinámicas, este sistema de ecuaciones se resuelve para cada intervalo de tiempo considerado en la discretización del proceso. Por lo tanto, el número total de ecuaciones que debe resolver el simulador se expresa como:

$$N_{et} = N_{ec} \times N_i \quad (10)$$

donde: N_i corresponde al número de intervalos de tiempo utilizados en la simulación dinámica del proceso. El esquema general del proceso de destilación extractiva considerado en este trabajo se presenta en el Anexo correspondiente.

3 Metodología

El presente trabajo se desarrolló como una extensión y comparación del estudio realizado por Quintero y Botía et al. [10] sobre la subrogación de modelos para el control predictivo de un proceso de destilación extractiva. La metodología se estructuró en dos fases principales: (i) la replicación y verificación de la base metodológica establecida en dicho trabajo, que incluye el caso de estudio, las simulaciones rigurosas y la generación de datos dinámicos; y (ii) la implementación y evaluación de nuevas estrategias de subrogación orientadas al control. En la primera fase se utilizó el mismo caso de estudio correspondiente a la separación de una mezcla azeotrópica metanol-acetona mediante destilación extractiva con dimetilsulfóxido (DMSO) como agente separador. Inicialmente, se verificó el correcto funcionamiento del modelo del proceso en estado estacionario en Aspen Plus. Posteriormente, el proceso fue llevado a un entorno dinámico mediante Aspen Plus Dynamics, donde se implementó la estructura de control regulatorio necesaria para garantizar la estabilidad hidráulica del sistema durante la operación.

Una vez estabilizado el proceso en el entorno dinámico, se realizaron pruebas de escalón en las variables manipuladas del sistema, correspondientes al calor de rehvador y la relación de reflujo en cada columna ($Q_{R,T-101}$, $Q_{R,T-102}$, RR_{T-101} y RR_{T-102}). Simultáneamente, se monitoreó la respuesta de las variables controladas asociadas a la pureza de los productos, representadas por las temperaturas en etapas específicas de las columnas ($T_{36,T-101}^{Acet}$ y $T_{8,T-102}^{MetOH}$), con el fin de obtener datos dinámicos representativos del comportamiento del sistema frente a perturbaciones. Para cada columna (T-101 y T-102), los datos generados se dividieron en dos conjuntos independientes: uno destinado a la identificación (entrenamiento) de los modelos y otro para su validación. Esta estrategia permite evaluar la capacidad de generalización de los modelos y evitar problemas de sobreajuste (*overfitting*).

Estos datos fueron utilizados para la construcción de modelos subrogados capaces de aproximar el comportamiento dinámico del modelo riguroso. En el trabajo original, la subrogación del sistema se realizó mediante representaciones en espacio de estados (SS). En el presente estudio, este enfoque se mantiene como referencia y se implementan adicionalmente modelos ARX y ARMAX con el objetivo de comparar el desempeño de diferentes estrategias de subrogación orientadas al control. Los modelos obtenidos fueron evaluados mediante métricas estadísticas de ajuste y posteriormente integrados en un esquema de control predictivo basado en modelo (MPC), mediante una co-simulación entre Aspen Plus Dynamics y MATLAB®-Simulink®, lo que permitió analizar su desempeño frente a perturbaciones en las corrientes de alimentación del proceso. El flujo general de la metodología se ilustra en la Figura 1.

Flujograma de la subrogación para control



Figura 1. Flujo del proceso de subrogación de modelos para el control predictivo.

3.1 Software empleado

Para el desarrollo de las simulaciones del proceso se empleó la suite aspenONE® de Aspen Technology Inc. (versión 11), específicamente los módulos Aspen Plus V11 y Aspen Plus Dynamics V11, con el objetivo de simular el proceso tanto en estado estacionario como en régimen dinámico. Aspen Plus Dynamics permite exportar modelos en estado estacionario a

un entorno dinámico que resuelve las ecuaciones diferenciales algebraicas (DAE) del proceso con paso de tiempo variable, lo que resulta especialmente adecuado para la generación de datos de identificación en procesos altamente no lineales como la destilación extractiva [10]. Los datos generados durante la simulación dinámica fueron exportados al entorno de MATLAB® y Simulink® R2025b de MathWorks Inc., donde se realizaron las tareas de procesamiento de datos, la identificación de modelos subrogados y la implementación de los esquemas de control predictivo basados en modelo (MPC). Para la identificación de los modelos ARX y ARMAX se empleó el *System Identification Toolbox* de MATLAB®, el cual permite estimar modelos dinámicos lineales a partir de datos de entrada-salida. El esquema de control MPC se implementó mediante el *Model Predictive Control Toolbox*, lo que permitió integrar directamente los modelos identificados en el controlador y evaluar su desempeño en el entorno de co-simulación con Aspen Plus Dynamics.

3.2 Caso de estudio y simulación rigurosa

Con el fin de establecer una base de comparación consistente, se adoptó el mismo caso de estudio y modelo riguroso desarrollado por Quintero y Botía et al. [10], correspondiente a un proceso de destilación extractiva para la separación de una mezcla azeotrópica de metanol y acetona.

3.2.1 Descripción del proceso

El proceso consiste en la separación de una mezcla azeotrópica metanol-acetona mediante destilación extractiva utilizando dimetilsulfóxido (DMSO) como agente separador. La configuración del sistema comprende dos columnas de destilación acopladas: una columna extractiva ($T-101$) y una columna de recuperación de solvente ($T-102$). En la columna extractiva $T-101$ se introduce la mezcla azeotrópica junto con el solvente DMSO, el cual modifica la volatilidad relativa de los componentes al alterar el equilibrio vapor-líquido del sistema, permitiendo así romper el azeótropo y obtener acetona de alta pureza en el destilado. La corriente de fondos, compuesta por metanol y DMSO, se envía a la columna $T-102$, donde se recupera el solvente mediante destilación convencional, obteniéndose metanol en el destilado y DMSO en el fondo para su recirculación al proceso. El modelo del proceso fue implementado inicialmente en Aspen Plus para verificar la consistencia de las condiciones operativas en estado estacionario antes de proceder con el análisis dinámico.

3.2.2 Esquema de control regulatorio

Para garantizar la estabilidad hidráulica y operativa del sistema durante las simulaciones dinámicas, se implementó un esquema de control regulatorio basado en controladores de retroalimentación proporcional-integral (PI). El esquema incluye lazos de control de nivel en los condensadores y rehervidores de ambas columnas, así como lazos de control de presión en cada columna de destilación. Estos lazos permiten mantener condiciones de operación estables y evitar problemas operativos tales como el sobrellenado de equipos o variaciones no deseadas de presión dentro del sistema. La sintonización de los controladores PI se realizó mediante el método de Tyreus-Luyben, el cual determina los parámetros proporcional e integral a partir de la ganancia y el período últimos del sistema [19]. Los valores finales de sintonización corresponden a los reportados por Quintero y Botía et al. [10]. La validación del esquema de control regulatorio se llevó a cabo mediante una prueba de estabilidad consistente en un escalón del 15% en el flujo molar de la corriente de alimentación azeotrópica respecto a su valor nominal. Los resultados confirmaron que el sistema mantiene la estabilidad hidráulica ante esta perturbación, lo que constituye una base adecuada para el análisis dinámico posterior.

3.2.3 Generación de datos dinámicos mediante pruebas de escalón

Para obtener los datos necesarios para la identificación de los modelos subrogados se realizaron pruebas de escalón (*step tests*) en la simulación dinámica del proceso en Aspen Plus Dynamics. Estas pruebas consisten en aplicar cambios tipo escalón en las variables manipuladas y registrar la respuesta dinámica de las variables de salida de interés, con el propósito de excitar de manera adecuada la dinámica del sistema y garantizar la persistencia de excitación necesaria para la identificación paramétrica de los modelos [20]. En el contexto de la subrogación orientada al control, las variables manipuladas consideradas fueron la potencia de los rehervidores y la razón de reflujo de cada columna. Dado que la medición directa de fracciones molares en procesos industriales continuos puede resultar costosa o difícil de implementar en línea, se seleccionaron las temperaturas de etapa como variables controladas, en virtud de su fuerte correlación con la pureza de los productos. En particular, se seleccionaron la temperatura de la etapa 36 para la columna $T-101$ y la temperatura de la etapa 8 para la columna $T-102$, por presentar la mayor sensibilidad frente a cambios en las condiciones operativas, determinada a través del análisis del perfil de temperatura de cada columna [10]. Con el objetivo de disponer de conjuntos independientes para entrenamiento y validación, el procedimiento se realizó para dos *datasets* obtenidos de *stepcests* distintos.

Durante el análisis de los datos se observó la presencia de pequeñas variaciones residuales en las señales de temperatura que no son completamente explicadas por los cambios escalón aplicados. Estas variaciones pueden interpretarse como ruido en los datos, asociado a errores de modelado, a efectos numéricos inherentes a la discretización temporal y a los algoritmos de integración empleados en la simulación dinámica. Este comportamiento resulta especialmente relevante para los modelos

ARX y ARMAX, cuya estructura incluye explícitamente un término de ruido que permite capturar dinámicas no modeladas y errores de aproximación inherentes al proceso de identificación [21].

3.3 Subrogación de modelos

La subrogación del proceso se realizó con el objetivo de construir modelos dinámicos simplificados capaces de reproducir el comportamiento del modelo riguroso en un rango de operación relevante para el control, de modo que puedan ser integrados eficientemente dentro de esquemas de control predictivo basado en modelo. En el trabajo original de Quintero y Botía et al. [10], la subrogación se realizó mediante representaciones en espacio de estados. En el presente estudio, dicho enfoque se mantiene como línea base de comparación, y se implementan adicionalmente modelos de tipo ARX, ARMAX y función de transferencia (TF), con el fin de evaluar su capacidad para representar la dinámica del proceso y su idoneidad dentro del esquema de control.

3.3.1 Preprocesamiento de datos

Antes de proceder con la identificación de los modelos, todas las variables de entrada y salida se transformaron en desviaciones relativas respecto a su valor nominal de operación. Esta transformación, estándar en la identificación de sistemas para control, permite que los modelos se centren en la dinámica del proceso alrededor del punto de operación, lo que facilita la linealización y mejora el condicionamiento numérico del problema de identificación. La desviación relativa de cada variable se calculó mediante: centra el análisis en la dinámica del proceso alrededor del punto de operación, lo que facilita la linealización y mejora el condicionamiento numérico del problema de identificación. La desviación relativa de cada variable se calculó mediante:

$$X_{\text{desv}} = \frac{X - X_{\text{nominal}}}{X_{\text{nominal}}} \quad (11)$$

donde X es el valor medido de la variable y X_{nominal} es su valor en estado estacionario nominal.

3.3.2 Identificación de modelos subrogados

La identificación de los modelos subrogados se realizó en el entorno MATLAB® R2025b, utilizando el System Identification Toolbox y a partir de los datos obtenidos de las simulaciones dinámicas del proceso. En primer lugar, se consideró como referencia el modelo en espacio de estados desarrollado en el trabajo previo. Posteriormente, se identificaron modelos de tipo ARX y ARMAX con el objetivo de evaluar su capacidad para aproximar la dinámica del proceso mediante estructuras lineales discretas. Para los modelos ARX se realizó un barrido sistemático de órdenes utilizando las funciones `arxstruc` y `selstruc`, las cuales permiten explorar distintas combinaciones de parámetros autorregresivos y exógenos. En este contexto, los términos autorregresivos corresponden a valores pasados de la variable de salida del sistema (temperatura de etapa), mientras que los términos exógenos representan la influencia de las variables de entrada del proceso, es decir, la potencia del rehedidor y la razón de reflujo de cada columna. De manera análoga, se realizó un barrido para los modelos ARMAX, variando el orden asociado al polinomio de ruido (n_c) y estimando los parámetros del modelo mediante las rutinas de identificación disponibles en el toolbox. Para cada valor de n_c se generó un modelo candidato, cuyo desempeño fue evaluado mediante simulación frente a los datos experimentales. Por otra parte, en los modelos de función de transferencia se seleccionaron los polos y ceros que presentaron el mejor ajuste, junto con el retraso temporal identificado por MATLAB. En el caso de los modelos FOPDT, al tratarse de una estructura predefinida, se utilizó directamente la función correspondiente del toolbox.

Con el objetivo de evitar el sobreajuste, la validación de los modelos se realizó utilizando un conjunto de datos correspondiente a un segundo *step test*. Para aquellos modelos con mayor flexibilidad estructural, como los de espacio de estados, ARX y ARMAX, se realizó una nueva iteración de los parámetros estructurales con el fin de mejorar el ajuste al conjunto de validación. En cambio, los modelos de función de transferencia y FOPDT se validaron únicamente mediante la comparación entre las salidas reales y las predicciones del modelo ya identificado. El desempeño de la subrogación, para cada columna del proceso (T-101 y T-102), se evaluó mediante el coeficiente de determinación (R^2) y el error cuadrático medio (RMSE) entre las salidas del modelo y los datos generados por el modelo riguroso. Estos indicadores permitieron obtener una estimación preliminar del desempeño esperado de los modelos en el esquema de control predictivo.

3.3.3 Métricas de evaluación de los modelos subrogados

Para evaluar la capacidad de los modelos subrogados de reproducir la dinámica del proceso se emplearon métricas estadísticas de ajuste. En particular, se calcularon el coeficiente de determinación (R^2) y la raíz del error cuadrático medio (RECM), calculados entre las salidas predichas por el modelo y los datos generados por la simulación rigurosa. Estas métricas se calcularon según las Ecs. (12) y (13):

$$\text{RECM} = \sqrt{\frac{\sum_{n=1}^N (\hat{y}_n - y_n)^2}{N}} \quad (12)$$

$$R^2 = 1 - \frac{\sum_{n=1}^N (y_n - \hat{y}_n)^2}{\sum_{n=1}^N (y_n - \bar{y})^2} \quad (13)$$

donde N es el número de datos, y_n es el valor real, $\hat{y}_n$ es el valor predicho por el modelo para el instante n , y $\bar{y}$ es la media de los datos reales. Un valor de R^2 cercano a la unidad indica un ajuste adecuado, mientras que valores bajos de RECM señalan errores de predicción pequeños. Estos indicadores proporcionaron una evaluación previa de la capacidad predictiva de cada estructura, como guía para su posterior implementación en el esquema de control.

3.4 Implementación del control MPC y co-simulación

Con el fin de evaluar el desempeño de los modelos subrogados en un entorno de control real, se implementó un esquema de MPC mediante una co-simulación entre Aspen Plus Dynamics y MATLAB®-Simulink®. En este esquema, la simulación dinámica rigurosa del proceso se ejecuta en Aspen Plus Dynamics, mientras que el controlador MPC opera en Simulink. La comunicación entre ambos entornos se realiza a través de la interfaz ActiveX en cada intervalo de muestreo: Aspen envía a Simulink las mediciones actuales de las variables controladas (temperaturas de etapa), y el controlador calcula las acciones de control que son devueltas a Aspen como consignas de la potencia de los rehervidores y de la razón de reflujo, cerrando así el lazo de control.

Las variables manipuladas consideradas fueron la potencia de los rehervidores ($Q_{R,T-101}$, $Q_{R,T-102}$) y la razón de reflujo de las columnas (RR_{T-101} , RR_{T-102}), mientras que las variables controladas correspondieron a las temperaturas de etapa $T_{36,T-101}$ y $T_{8,T-102}$. Para evaluar el desempeño del controlador se aplicaron dos perturbaciones tipo escalón en los flujos de alimentación del proceso (un incremento del 8 % respecto al valor nominal en cada caso), sobre un horizonte de simulación de 100 horas. Las perturbaciones se aplicaron en instantes predefinidos dentro del horizonte de simulación con el fin de evaluar la capacidad de rechazo del controlador bajo condiciones reproducibles.

3.4.1 Formulación del problema de optimización MPC

En cada instante de control k , el controlador MPC resuelve un problema de programación cuadrática (QP) sobre un horizonte de predicción p . El vector de decisión z_k agrupa las acciones de control futuras y la variable de holgura ε_k :

$$z_k^T = [u(k|k)^T, u(k+1|k)^T, \dots, u(k+p-1|k)^T, \varepsilon_k] \quad (14)$$

El problema de optimización minimiza la función de costo compuesta:

$$\min_{z_k} J(z_k) = J_y(z_k) + J_u(z_k) + J_{\Delta u}(z_k) + J_\varepsilon(z_k) \quad (15)$$

donde cada término penaliza un aspecto distinto del desempeño del controlador. El término J_y cuantifica el error entre la trayectoria predicha y la referencia:

$$J_y(z_k) = \sum_{j=1}^{n_y} \sum_{i=1}^p \left\{ \frac{w_{i,j}^y}{s_j^y} [r_j(k+i|k) - y_j(k+i|k)] \right\}^2 \quad (16)$$

El término J_u penaliza las desviaciones de las variables manipuladas respecto a su valor objetivo en estado estable:

$$J_u(z_k) = \sum_{j=1}^{n_u} \sum_{i=1}^{p-1} \left\{ \frac{w_{i,j}^u}{s_j^u} [u_j(k+i|k) - u_{j,\text{target}}(k+i|k)] \right\}^2 \quad (17)$$

El término $J_{\Delta u}$ penaliza los cambios bruscos en las acciones de control, favoreciendo trayectorias suaves de las variables manipuladas:

$$J_{\Delta u}(z_k) = \sum_{j=1}^{n_u} \sum_{i=1}^{p-1} \left\{ \frac{w_{i,j}^{\Delta u}}{s_j^u} [u_j(k+i|k) - u_j(k+i-1|k)] \right\}^2 \quad (18)$$

Finalmente, J_ε penaliza la variable de holgura asociada a posibles violaciones de restricciones, garantizando la factibilidad del problema de optimización:

$$J_\varepsilon(z_k) = \rho_\varepsilon \varepsilon_k^2 \quad (19)$$

En las expresiones anteriores, $w_{i,j}^y$, $w_{i,j}^u$ y $w_{i,j}^{\Delta u}$ son los pesos de ponderación, s_j^y y s_j^u son los factores de escala, $r_j(k+i|k)$ es la referencia predicha, y $y_j(k+i|k)$ y $u_j(k+i|k)$ son las salidas y entradas predichas, respectivamente, para el instante $k+i$ calculadas en el instante k [22]. En el contexto del presente estudio, los modelos subrogados SS, ARX, ARMAX y TF son los encargados de proporcionar las salidas predichas $y_j(k+i|k)$, es decir, la relación dinámica entre las variables manipuladas futuras y el comportamiento esperado del proceso, lo que permite al optimizador evaluar el impacto de cada secuencia de control posible sobre el desempeño futuro del sistema.

3.4.2 Integración con Aspen Plus Dynamics

La co-simulación entre Simulink y Aspen Plus Dynamics se realiza mediante el intercambio de señales de entrada y salida en cada intervalo de muestreo a través de la interfaz ActiveX. En cada paso, Aspen Plus Dynamics proporciona a Simulink las mediciones actuales de las temperaturas de etapa de ambas columnas, y el controlador MPC calcula las acciones de control óptimas conforme al problema de la Ec. (15). Dichas acciones son enviadas de regreso a Aspen Plus Dynamics como consignas de la potencia de los rehervidores y de las razones de reflujo, cerrando el lazo de control y permitiendo evaluar la respuesta del proceso riguroso ante la acción del controlador basado en los modelos subrogados.

3.4.3 Evaluación del desempeño del controlador

Para cuantificar la efectividad del esquema de control implementado, se empleó un conjunto de métricas complementarias que permiten analizar la calidad del seguimiento de referencia, la rapidez de la respuesta y el esfuerzo de control requerido. El **error relativo de seguimiento** cuantifica la diferencia entre la variable controlada y su referencia en cada instante:

$$e_{\text{rel}}(t) = \frac{|Y(t) - Y_{\text{ref}}(t)|}{Y_{\text{ref}}(t)} \quad (20)$$

El **tiempo de estabilización** se define como el tiempo requerido para que la variable controlada ingrese y permanezca dentro de una banda de tolerancia de $\pm 2\%$ respecto a su valor nominal tras la aplicación de una perturbación.

Las **métricas de error integral** permiten una evaluación cuantitativa global del desempeño del controlador a lo largo de toda la simulación, considerando tanto la magnitud de los errores como su persistencia en el tiempo. El criterio de la integral del valor absoluto del error (IAE) mide el error absoluto acumulado:

$$\text{IAE} = \int_0^\infty |e(t)| dt \quad (21)$$

El criterio de la integral del error cuadrático (ISE) penaliza con mayor severidad los errores de magnitud elevada:

$$\text{ISE} = \int_0^\infty e^2(t) dt \quad (22)$$

El criterio de la integral del valor absoluto del error ponderado por el tiempo (ITAE) penaliza los errores de larga duración, favoreciendo controladores con rechazo rápido de perturbaciones:

$$\text{ITAE} = \int_0^\infty t |e(t)| dt \quad (23)$$

Finalmente, la integral del error cuadrático ponderado por el tiempo (ITSE) combina la penalización por magnitud y por duración del error:

$$\text{ITSE} = \int_0^\infty t e^2(t) dt \quad (24)$$

El uso conjunto de las métricas IAE, ISE, ITAE e ITSE proporciona una perspectiva integral del desempeño del controlador. Mientras que IAE e ISE caracterizan la magnitud global del error, ITAE e ITSE penalizan de manera más severa la persistencia del error en el tiempo. Este último aspecto resulta especialmente relevante en procesos lentos como la destilación, donde los

tiempos de estabilización pueden extenderse durante varias horas. Estas métricas de error integral permiten una evaluación más completa del desempeño del controlador, ya que cuantifican tanto la magnitud como la duración de los errores a lo largo del tiempo [23]. Los resultados obtenidos permitieron comparar la capacidad de los distintos modelos subrogados para mantener la estabilidad del proceso, minimizar el error de seguimiento y reducir el esfuerzo de control dentro del esquema de control predictivo basado en modelo (MPC), proporcionando así una evaluación cuantitativa del desempeño de cada estrategia de modelado.

4 Resultados y Discusión

En primer lugar, vamos a hablar sobre la capacidad de cada estructura de modelo para representar la dinámica del proceso a partir de los datos de identificación y a continuación, se analiza el desempeño de cada modelo como controlador MPC frente a perturbaciones en la alimentación, considerando los costos computacionales, las métricas básicas de control y los criterios integrales de desempeño. Finalmente, se discute la selección del modelo más adecuado para cada columna y se propone la estrategia de control resultante.

4.1 Subrogación de modelos

Los modelos subrogados se desarrollaron considerando dos variables manipuladas la potencia del rehervidor y la relación de reflujo — con una salida correspondiente a la temperatura de una etapa representativa de cada columna. Para la columna $T-101$ se seleccionó la temperatura de la etapa 36, y para la columna $T-102$ la temperatura de la etapa 8. Estas etapas fueron escogidas por presentar la mayor sensibilidad ante cambios en las variables manipuladas, conforme al análisis del perfil de temperatura reportado por Quintero y Botía et al. [10].

De este modo se obtuvieron cinco estructuras de modelo para cada columna: ARX, ARMAX, espacio de estados (SS), función de transferencia (TF) y modelo de primer orden con tiempo muerto (FOPDT).

En la Tabla 2 se presentan el RECM y el coeficiente de determinación (R^2) obtenidos durante la validación de cada modelo frente al segundo conjunto de datos de *steptest*. Las Figuras 2 y 3 ilustran la comparación entre las respuestas predichas y los datos reales para ambas columnas.




Figura 2. Comparación de los modelos subrogados respecto a los datos de validación para la columna $T-101$.




Figura 3. Comparación de los modelos subrogados respecto a los datos de validación para la columna T-102.

Tabla 2. Métricas de ajuste de los modelos subrogados evaluadas sobre el conjunto de validación.

Columna	Modelo	RECM	R^2
T-101	SS	0.2895	0.7709
T-101	ARX	0.3047	0.7462
T-101	ARMAX	0.3051	0.7456
T-101	FOPDT	0.3713	0.6231
T-101	TF	0.3766	0.6122
T-102	SS	7.1142	0.5316
T-102	ARX	6.8227	0.5692
T-102	ARMAX	6.1927	0.6451
T-102	FOPDT	6.9890	0.5480
T-102	TF	7.1117	0.5320

Los resultados evidencian que las dos columnas presentan dinámicas diferenciadas que requieren estructuras de modelado distintas. Asimismo, se confirma que un mejor ajuste estadístico no garantiza necesariamente un mejor desempeño dentro de un esquema de control predictivo, lo cual motiva la evaluación directa del desempeño dinámico del controlador.

4.2 Control predictivo frente a perturbaciones

Una vez obtenidos los modelos subrogados, se implementó el esquema MPC y se evaluó su desempeño frente a dos perturbaciones tipo escalón consistentes en una perturbación positiva del 5 % en el caudal de alimentación seguida de una perturbación negativa del 10 %, aplicadas en instantes predefinidos dentro de un horizonte total de simulación de 100 h.

La inclusión de perturbaciones de signo opuesto permite evaluar la capacidad del controlador para mantener la estabilidad y el seguimiento del valor de referencia bajo condiciones dinámicas asimétricas, representativas de variaciones reales en la operación industrial.

Las Figuras 4 y 5 presentan la evolución temporal de las variables controladas en ambas columnas.




Figura 4. Evolución temporal de la variable controlada de $T-101$ bajo una perturbación del 5 % seguida de una perturbación del -10 % en el caudal de alimentación.




Figura 5. Evolución temporal de la variable controlada de $T-102$ bajo una perturbación del 5 % seguida de una perturbación del -10 % en el caudal de alimentación.

4.3 Costos computacionales

La Tabla 3 presenta los costos computacionales medidos durante la co-simulación.

Tabla 3. Costos computacionales asociados a la co-simulación MPC.

Modelo	T. Simulink (s)	CPU/paso (ms)	RAM total (MB)
SS	2252.852	1125.863	8.716
ARX	1474.331	1227.586	5.985
ARMAX	1467.311	1221.741	5.920
TF	1495.474	1245.191	6.017

Los costos computacionales de todos los modelos son compatibles con aplicaciones de control en tiempo real, por lo que este

criterio no constituye un factor limitante para la selección del modelo.

4.4 Criterios integrales de desempeño

Tabla 4. Criterios integrales de desempeño del controlador.

Columna	Modelo	IAE	ISE	ITAE
T-101	SS	27.5578	20.9545	1025.0644
T-101	ARX	26.5185	19.2915	991.7413
T-101	ARMAX	26.3033	18.8767	985.9294
T-101	TF	30.8227	25.4487	1134.2923
T-102	SS	81.7076	334.8314	3548.2214
T-102	ARX	86.4958	375.6526	3777.0928
T-102	ARMAX	91.2713	409.5911	4004.9308
T-102	TF	140.9958	1014.5493	6222.5580

4.5 Selección del modelo y propuesta de control híbrido

Los resultados obtenidos demuestran que el modelo óptimo depende de la dinámica particular de cada columna.

Para la columna *T*-101, el modelo **ARMAX** presenta el mejor desempeño integral, mientras que para la columna *T*-102, el modelo **SS** ofrece la mayor robustez dinámica.

En consecuencia, se propone la implementación de un esquema de control híbrido en el que: El modelo ARMAX gobierne el controlador MPC de la columna *T*-101. El modelo SS gobierne el controlador MPC de la columna *T*-102.

Esta arquitectura permite maximizar el desempeño global del sistema y refleja la naturaleza dinámica diferenciada de las dos columnas de destilación.

5 Conclusiones

En este trabajo se evaluaron cuatro estructuras de modelos subrogados — ARX, ARMAX, espacio de estados (SS) y función de transferencia (TF) — como núcleo de un esquema de control predictivo basado en modelo (MPC) aplicado a un sistema de destilación extractiva de dos columnas acopladas (*T*-101 y *T*-102). La metodología abarcó desde la identificación de los modelos a partir de pruebas de escalón en Aspen Plus Dynamics hasta la evaluación de su desempeño de control mediante co-simulación con MATLAB®–Simulink®, considerando perturbaciones tipo escalón consistentes en un incremento del 5 % seguido de una reducción del 10 % en el caudal de alimentación sobre un horizonte total de simulación de 100 horas.

Los resultados de la etapa de subrogación mostraron que el orden de calidad del ajuste estadístico difiere entre columnas, lo que evidencia la naturaleza dinámica distinta de cada subsistema dentro del proceso de destilación extractiva. Para la columna *T*-101, el modelo de espacio de estados presentó el mejor coeficiente de determinación ($R^2 = 0.771$), mientras que para la columna *T*-102 el modelo ARMAX fue el más preciso ($R^2 = 0.645$). No obstante, el análisis posterior del desempeño dentro del esquema de control predictivo demostró que el mejor ajuste estadístico durante la identificación no garantiza necesariamente el mejor comportamiento dinámico del controlador. Este hallazgo confirma que la idoneidad de un modelo en aplicaciones de MPC debe evaluarse con base en su capacidad para representar la dinámica relevante dentro del horizonte de predicción, y no únicamente por la exactitud global sobre los datos de identificación.

En cuanto al desempeño de control, todos los modelos evaluados lograron estabilizar la variable controlada después de cada perturbación aplicada, manteniendo errores relativos inferiores al 1 %, lo que confirma la viabilidad general del uso de modelos subrogados lineales dentro de esquemas de control predictivo para sistemas de separación complejos. Sin embargo, las diferencias entre modelos son cuantitativamente significativas cuando se analizan los criterios integrales de desempeño sobre el horizonte completo de simulación.

Para la columna *T*-101, el modelo ARMAX presentó el mejor desempeño integral, minimizando simultáneamente los tres indicadores evaluados (IAE = 26.30 ISE = 18.88 ITAE = 985.93) y ofreciendo los menores tiempos de estabilización frente a perturbaciones en la alimentación. Este resultado sugiere que la estructura autorregresiva con media móvil proporciona una mayor flexibilidad para representar perturbaciones y dinámicas transitorias en la columna extractiva.

Para la columna *T*-102, el modelo de espacio de estados fue el más robusto desde el punto de vista dinámico, con un valor de IAE de 81.71 y un ITAE de 3548.22 valores inferiores a los obtenidos con los demás modelos evaluados. Este comportamiento indica que una representación estructurada basada en variables de estado permite describir con mayor precisión las dinámicas más lentas y los efectos acumulativos característicos de la columna de recuperación de solvente.

En ambas columnas, el modelo basado en función de transferencia presentó el peor desempeño integral, con diferencias especialmente pronunciadas en la columna *T*-102, donde los valores de error acumulado fueron significativamente mayores que los obtenidos con los modelos ARX, ARMAX y SS. Este resultado sugiere que una representación de parámetros reducidos

puede ser insuficiente para capturar las dinámicas de baja frecuencia y los acoplamientos presentes en sistemas de destilación multietapa bajo condiciones de control predictivo.

El análisis de los costos computacionales evidenció que todos los modelos evaluados presentan tiempos de simulación y requerimientos de memoria compatibles con aplicaciones de control en tiempo real. Aunque el modelo de espacio de estados mostró el mayor tiempo total de simulación, también presentó una eficiencia computacional adecuada por paso de control. En consecuencia, el desempeño dinámico del controlador se establece como el criterio principal para la selección del modelo dentro del contexto de este estudio, por encima de las diferencias en costo computacional.

A partir de la evidencia experimental y numérica obtenida, se concluye que la estrategia de control más adecuada para el sistema analizado corresponde a un esquema de control híbrido descentralizado, en el cual el modelo ARMAX gobierna el controlador MPC de la columna $T-101$, mientras que el modelo de espacio de estados gobierna el controlador MPC de la columna $T-102$. Esta arquitectura permite explotar las fortalezas dinámicas específicas de cada estructura de modelo en función de las características particulares de cada subsistema, maximizando el desempeño global del sistema de destilación.

Los resultados de este trabajo aportan evidencia cuantitativa sobre la importancia de evaluar los modelos subrogados directamente dentro del entorno de control, en lugar de seleccionarlos exclusivamente con base en métricas de ajuste estadístico. Este principio constituye una guía metodológica aplicable a sistemas de separación complejos y a procesos multivariados en general, en los cuales la selección del modelo debe basarse en criterios integrales de desempeño dinámico bajo condiciones operativas representativas.

Finalmente, el estudio demuestra que la integración de técnicas de identificación de sistemas con estrategias de control predictivo permite implementar soluciones de control robustas y computacionalmente viables para procesos de destilación extractiva. Los resultados obtenidos proporcionan una base sólida para la implementación futura de estrategias avanzadas de control en procesos químicos industriales, orientadas a mejorar la estabilidad operativa, la eficiencia energética y el desempeño dinámico del sistema.

References

- [1] Z. Zhang, S. Li, and Y. Yang, “Explorative policy optimization for industrial-scale operation of complex process control systems,” *Journal of Process Control*, vol. 152, Aug. 2025. DOI: 10.1016/j.jprocont.2025.103471
- [2] Y. Zou, X. Ma, Y. Yang, and S. Li, “An overview of chemical process operation-optimization under complex operating conditions,” *Digital Chemical Engineering*, Sep. 2025. DOI: 10.1016/j.dche.2025.100249
- [3] N. Hu, “The limitations of traditional pid controllers and modern optimization methods,” *Applied and Computational Engineering*, 2025. DOI: 10.54254/2755-2721/147/2025.22912
- [4] D. Mora-Mariano and A. Flores-Tlacuahuac, “A machine learning approach for the surrogate modeling of uncertain distributed process engineering models,” *Chemical Engineering Research and Design*, vol. 186, pp. 433–450, Oct. 2022. DOI: 10.1016/j.cherd.2022.07.050
- [5] T. Geyer, *Model Predictive Control of High Power Converters and Industrial Drives*. John Wiley & Sons, 2017.
- [6] C. He, Y. Zhang, D. Gong, and X. Ji, “A review of surrogate-assisted evolutionary algorithms for expensive optimization problems,” *Expert Systems with Applications*, May 2023. DOI: 10.1016/j.eswa.2022.119495
- [7] D. Štunek and S. Lazarova-Molnar, “Surrogate modeling: Review and opportunities for expert knowledge integration,” in *Procedia Computer Science*, 2025, pp. 826–833. DOI: 10.1016/j.procs.2025.03.106
- [8] Z. T. Wilson and N. V. Sahinidis, “The alamo approach to machine learning,” *Computers & Chemical Engineering*, vol. 106, pp. 785–795, Nov. 2017. DOI: 10.1016/j.compchemeng.2017.02.010
- [9] K. McBride and K. Sundmacher, “Overview of surrogate modeling in chemical process engineering,” *Chemie Ingenieur Technik*, Mar. 2019. DOI: 10.1002/cite.201800091
- [10] J. E. Quintero, M. Botía, and J. M. Gómez, *Subrogación de modelos para control y optimización de procesos*.
- [11] A. Perez and Y. Yang, “Offset-free arx-based adaptive model predictive control applied to a nonlinear process,” *ISA Transactions*, vol. 123, pp. 251–262, Apr. 2022. DOI: 10.1016/j.isatra.2021.05.030
- [12] A. Wahid and I. Maulana, “Optimization of depropanizer unit using turbo expander and its controller using model predictive control,” in *E3S Web of Conferences*, Nov. 2018. DOI: 10.1051/e3sconf/20186703014
- [13] MathWorks, *Continuous-time process model with identifiable parameters*, Accessed: April 19, 2026, 2026. [Online]. Available: <https://la.mathworks.com/help/ident/ref/idproc.html>
- [14] M. Adjisetya and A. Wahid, “Multivariable model predictive control to control bio-h₂ production from biomass,” *ChemEngineering*, vol. 7, no. 1, Feb. 2023. DOI: 10.3390/chemengineering7010007
- [15] V. C. Setiawan, I. U. A. Alifah, R. P. Anugraha, Juwari, and Renanto, “Comparison of model predictive controller and neural network controller on nonconventional distillation system,” *IOP Conference Series: Materials Science and Engineering*, vol. 1053, no. 1, p. 012108, Feb. 2021. DOI: 10.1088/1757-899x/1053/1/012108
- [16] MathWorks, *Transfer function model with identifiable parameters*, Accessed: April 25, 2026, 2026. [Online]. Available: <https://la.mathworks.com/help/ident/ref/idtf.html>
- [17] O. A. A. Al-khamis and B. Gumus, “Comparison and performance analysis of model predictive control developed by transfer function based model and state space based model,” *Journal of Electrical Engineering and Technology*, vol. 18, no. 1, pp. 111–121, Jan. 2023. DOI: 10.1007/s42835-022-01179-z
- [18] J. Zhou and Y. Zhu, “Fault isolation based on transfer-function models using an mpc algorithm,” *Computers & Chemical Engineering*, vol. 159, Mar. 2022. DOI: 10.1016/j.compchemeng.2022.107668
- [19] B. D. Tyreus and W. L. Luyben, “Tuning pi controllers for integrator/dead time processes,” *Industrial & Engineering Chemistry Research*, vol. 31, no. 11, pp. 2625–2628, 1992. DOI: 10.1021/ie00011a029
- [20] L. Ljung, *System Identification: Theory for the User*, 2nd ed. Upper Saddle River, NJ: Prentice Hall, 1999, ISBN: 978-0136566953.
- [21] T. Söderström and P. Stoica, *System Identification*. New York: Prentice Hall, 1989, ISBN: 978-0138816407.
- [22] D. Masti and A. Bemporad, “Learning nonlinear state-space models using autoencoders,” *Automatica*, vol. 129, Jul. 2021. DOI: 10.1016/j.automatica.2021.109666
- [23] R. Zhang, J. Lu, H. Qu, and F. Gao, “State space model predictive fault-tolerant control for batch processes with partial actuator failure,” *Journal of Process Control*, vol. 24, no. 5, pp. 613–620, 2014. DOI: 10.1016/j.jprocont.2014.03.004

Nomenclature

A. Latin symbols

Symbol	Description	Unit
A	State matrix of the state-space model (Eqs. 7–8)	–
$A(q)$	Autoregressive polynomial in the ARX/ARMAX model (Eqs. 1–2)	–
a_i	Coefficients of the autoregressive polynomial $A(q)$, $i = 1, \dots, n_a$	–
B	Input matrix of the state-space model (Eq. 7)	–
$B(q)$	Input polynomial in the ARX/ARMAX model (Eqs. 1, 3)	–
b_i	Coefficients of the input polynomial $B(q)$, $i = 1, \dots, n_b$	–
C	Output matrix of the state-space model (Eq. 8)	–
C	Number of chemical components in the MESH distillation model (Eq. 9)	–
$C(q)$	Noise polynomial in the ARMAX model (Eq. 4)	–
c_i	Coefficients of the noise polynomial $C(q)$, $i = 1, \dots, n_c$	–
$e(k)$	White-noise / unmodeled disturbance term in ARX (discrete time)	–
$\bar{e}(k)$	Discrete-time noise signal in the ARX/ARMAX formulation (Eq. 1)	–
$e(t)$	Control tracking error (continuous time), used in IAE, ISE, ITAE, ITSE	°C
$e_{rel}(t)$	Relative tracking error between controlled variable and setpoint (Eq. 20)	–
er_1, er_2	Relative steady-state errors after the first and second disturbances (Table 4)	–
i	Prediction-step index within the MPC horizon ($i = 1, \dots, p$)	–
j	Controlled-output or manipulated-variable index	–
$J(z_k)$	Total MPC cost (objective) function (Eq. 15)	–
$J_y(z_k)$	Output tracking term of the MPC cost function (Eq. 16)	–
$J_u(z_k)$	Manipulated-variable penalty term of the MPC cost function (Eq. 17)	–
$J_{\Delta u}(z_k)$	Control-move rate-of-change penalty term of the MPC cost function (Eq. 18)	–
$J_\epsilon(z_k)$	Slack-variable penalty term of the MPC cost function (Eq. 19)	–
k	Current discrete-time step index	–
n	Sample index used in the RECM and R^2 summations (Eqs. 12–13)	–
n_a	Order of the autoregressive polynomial $A(q)$ (number of poles)	–
n_b	Order of the input polynomial $B(q)$ (number of zeros)	–
n_c	Order of the noise polynomial $C(q)$ in the ARMAX model	–
n_k	Input delay of the ARX/ARMAX model (number of samples) (Eq. 1)	–
n_u	Number of manipulated variables in the MPC formulation	–
n_y	Number of controlled output variables in the MPC formulation	–
N	Number of data samples used in the RECM and R^2 calculations (Eqs. 12–13)	–
N	Number of theoretical stages in the distillation column (MESH model, Eq. 9)	–
N_{ec}	Number of algebraic equations describing the column at a given instant (Eq. 9)	–
N_{et}	Total number of equations solved throughout the dynamic simulation (Eq. 10)	–
N_i	Number of time intervals in the dynamic simulation (Eq. 10)	–
p	MPC prediction horizon length (Eqs. 14–18)	steps
P_1	Controlled-variable temperature after the first disturbance (Table 4)	°C
P_2	Controlled-variable temperature after the second disturbance (Table 4)	°C
q	Forward shift operator	–
q^{-1}	Backward shift (unit-delay) operator	–
Q_R	Reboiler heat duty (generic)	kW
$Q_{R,T-101}$	Reboiler heat duty of the extractive column T-101 (manipulated variable)	kW
$Q_{R,T-102}$	Reboiler heat duty of the solvent-recovery column T-102 (manipulated variable)	kW
R^2	Coefficient of determination (goodness-of-fit metric, Eq. 13)	–
$r_j(k+i k)$	Predicted reference (setpoint) for output j at prediction step i (Eq. 16)	–
$\bar{R}ECM$	Root mean square error — Raíz del Error Cuadrático Medio (Eq. 12)	°C
RR_{T-101}	Reflux ratio of column T-101 (manipulated variable)	–
RR_{T-102}	Reflux ratio of column T-102 (manipulated variable)	–
s_j^u	Scaling factor for manipulated variable j in the MPC cost (Eqs. 17–18)	–
s_j^y	Scaling factor for output variable j in the MPC cost (Eq. 16)	–
$\bar{S}P$	Setpoint (reference) temperature (Table 4)	°C
t	Continuous time; also integration variable in IAE, ISE, ITAE, ITSE	h
t_1	Settling time after the first disturbance (Table 4)	h
t_2	Settling time after the second disturbance (Table 4)	h
T	Temperature (generic)	°C
$T_{36,T-101}$	Temperature at stage 36 of column T-101 — controlled variable for T-101	°C
$T_{8,T-102}$	Temperature at stage 8 of column T-102 — controlled variable for T-102	°C
u	Manipulated variable (generic)	–
$u(k)$	Discrete-time manipulated-variable signal	–
$\bar{u}(k)$	Discrete-time input signal in the ARX/ARMAX formulation (Eq. 1)	–
$u(t)$	Continuous-time input vector (state-space, Eq. 7)	–
$u_j(k+i k)$	Predicted manipulated variable j at prediction step i (Eqs. 17–18)	–
$u_{j,target}(k+i k)$	Target (desired steady-state) value for manipulated variable j (Eq. 17)	–
$w_{i,j}^y$	MPC tuning weight for output j at prediction step i (Eq. 16)	–
$w_{i,j}^u$	MPC tuning weight for manipulated variable j at prediction step i (Eq. 17)	–

$w_{i,j}^{\Delta u}$	MPC tuning weight for the rate of change of manipulated variable j (Eq. 18)	—
$x(t)$	Continuous-time state vector (Eq. 7)	—
$\dot{x}(t)$	Time derivative of the state vector (Eq. 7)	—
X	Generic process variable used in the deviation normalisation (Eq. 11)	—
X_{desv}	Relative deviation of variable X from its nominal operating value (Eq. 11)	—
$X_{nominal}$	Nominal (steady-state) operating value of variable X (Eq. 11)	—
y	Controlled output variable (generic)	—
$y(k)$	Discrete-time system output signal (ARX/ARMAX inline description)	—
$\bar{y}(k)$	Discrete-time output signal in the ARX/ARMAX formulation (Eq. 1)	—
$y(t)$	Continuous-time output vector (state-space, Eq. 8)	—
$y_j(k+i k)$	Predicted controlled output j at prediction step i (Eqs. 16)	—
y_n	Observed (rigorous-model) output at sample n (Eqs. 12–13)	—
$\hat{y}_n$	Surrogate-model predicted output at sample n (Eqs. 12–13)	—
$\bar{y}$	Mean of the observed output samples; used in R^2 denominator (Eq. 13)	—
$Y(t)$	Controlled process output in continuous time (Eq. 20)	°C
$Y_{ref}(t)$	Reference (setpoint) value of the process output (Eq. 20)	°C
z_k	MPC decision vector — sequence of future control moves and slack variable (Eq. 14)	—
z_k^T	Transpose of the MPC decision vector (Eq. 14)	—

B. Greek symbols

Symbol	Description	Unit
Δ	Finite-difference / increment operator (e.g. Δu : change in manipulated variable)	—
ε_k	Slack variable for soft-constraint relaxation at time step k (written ϵ_k in Eq. 14 and ε_k in Eq. 19; both refer to the same variable)	—
ρ_ε	Penalty coefficient on the slack variable in the MPC cost (Eq. 19)	—

C. Subscripts

Subscript	Description
36	Stage 36 of column T-101 (temperature measurement location)
8	Stage 8 of column T-102 (temperature measurement location)
a	Autoregressive polynomial order
b	Input polynomial order
c	Noise polynomial order
$desv$	Relative deviation from the nominal operating point
ec	Algebraic equation count (MESH model)
et	Total equation count in the dynamic simulation
i	Prediction-step index within the MPC horizon
j	Controlled-output or manipulated-variable index
k	Current discrete-time step
n	Sample index in statistical fit metrics (RECM, R^2)
$nominal$	Nominal (steady-state) operating value
R	Reboiler (used in Q_R , $Q_{R,T-101}$, etc.)
ref	Reference (setpoint) value
rel	Relative quantity
$target$	Desired steady-state target for a manipulated variable
$T-101$	Extractive distillation column identifier
$T-102$	Solvent-recovery distillation column identifier

D. Superscripts

Superscript	Description
T	Transpose of a matrix or vector
$\hat{}$	Estimated (surrogate-model predicted) value
$\bar{}$	Mean value; also used in ARX/ARMAX overbar signal notation
Δu	Rate-of-change of the manipulated variable (as tuning-weight superscript)
u	Manipulated-variable quantity (as scaling or tuning-weight superscript)
y	Controlled-output quantity (as scaling or tuning-weight superscript)
-1	Unit-delay operation on shift operator q

E. Abbreviations

Abbreviation	Description
ARMAX	AutoRegressive Moving Average with eXogenous inputs
ARX	AutoRegressive with eXogenous inputs
CPU	Central Processing Unit
DMSO	Dimethyl sulfoxide (extractive distillation solvent)
IAE	Integral of Absolute Error (Eq. 21)
ISE	Integral of Squared Error (Eq. 22)
ITAE	Integral of Time-weighted Absolute Error (Eq. 23)
ITSE	Integral of Time-weighted Squared Error (Eq. 24)
MESH	Mass, Equilibrium, Summation, and Heat (distillation modelling framework)
MPC	Model Predictive Control
NARX	Nonlinear AutoRegressive with eXogenous inputs
NLARX-SVM	Nonlinear ARX model coupled with a Support Vector Machine
PFD	Process Flow Diagram
PI	Proportional-Integral controller
PID	Proportional-Integral-Derivative controller
QP	Quadratic Programming
RAM	Random Access Memory
RECM	Raíz del Error Cuadrático Medio (Eq. 12)
SS	State Space
SVM	Support Vector Machine

6 Anexos

6.1 Diagramas




Figura 6. Diagrama del proceso de destilación extractiva.




Figura 7. Diagrama del control implementado en Simulink.

6.2 Parámetros de los metamodelos

Tabla 6. Parámetros de modelos de subrogación para T-101

Modelo	Entrada	Parámetros
SS-T101	–	$A = [40.8, -41.47, -3.201, -2.235, -3.453, 4.586]$ $B = [0.165, -18.52, -1.84, -11.35, 0.8057, 7.268]$ $C = [10.59, 1.733, -2.845, -9.098, 0.9113, 2.971]$
ARX-T101	–	$A = [1.000, -1.354, 0.198, -0.003, 0.119, 0.085, 0.011, -0.024, -0.026, -0.036, 0.022, 0.005, -0.002, -0.002, 0.007]$ $B = [0.000, 0.164, -0.158, -0.027, -0.009, 0.012, 0.018, 0.011, 0.003, -0.008, -0.007, 0.002, 0.001, 0.000, -0.002]$
ARMAX-T101	–	$A = [1.000, -2.486, 2.019, -0.616, 0.179, -0.051, -0.050, -0.013, 0.004, -0.015, 0.054, -0.021, -0.005, 0.002, -0.000]$ $B = [0.000, 0.164, -0.343, 0.199, -0.024, 0.014, 0.002, -0.006, -0.005, -0.008, 0.003, 0.007, -0.001, -0.001, -0.001]$ $C = [1.000, -1.133, 0.288]$

Tabla 7. Parámetros de modelos de subrogación para T-102

Modelo	Entrada	Parámetros
SS-T102	–	$A = [-12.31, -3.067, 7.829, -8.206, -13.97, -8.776, -6.807, 5.213]$ $B = [-0.7859, -0.3498, 19.37, -3.938, -7.507, -2.394, 1.11, -0.09381]$ $C = [-7.394, -19, 0.3128, 13.91, 22.35, 7.993, 10.39, -5.793]$
ARX-T102	–	$A = [1.000, -1.756, 0.895, -0.162, 0.208, -0.086, -0.304, 0.270, -0.064, 0.060, -0.093, 0.000, 0.058, -0.039, 0.012]$ $B = [0.000, 0.310, -0.411, 0.085, 0.018, 0.115, -0.002, -0.174, 0.054, 0.016, 0.035, -0.036, -0.024, 0.021, -0.008]$
ARMAX-T102	–	$A = [1.000, -2.185, 2.223, -1.556, 0.797, -0.272, -0.152, 0.339, -0.321, 0.225, -0.154, 0.061, 0.018, -0.043, 0.021]$ $B = [0.000, 0.310, -0.544, 0.440, -0.255, 0.158, -0.041, -0.109, 0.123, -0.098, 0.058, -0.043, 0.005, 0.014, -0.015]$ $C = [1.000, -0.431, 0.581]$