

Implementación de Técnicas de Subrogación de Modelos para el Control de Procesos No Lineales

Álvaro Páez¹, Alejandro Ardila¹, Jorge M. Gómez¹

Departamento de Ingeniería Química y de Alimentos, Universidad de los Andes
Edificio Mario Laserna. Cra. 1 Este 19A-40, Bogotá, Colombia

1 Resumen

El presente trabajo evalúa diferentes técnicas de subrogación de modelos orientadas al control predictivo basado en modelo (MPC) para un proceso de destilación extractiva de una mezcla azeotrópica de metanol y acetona con dimetilsulfóxido (DMSO) como agente separador. A partir de datos dinámicos obtenidos mediante simulación rigurosa en Aspen Plus Dynamics, se identificaron cinco estructuras de modelo subrogado por columna: espacio de estados (SS), autorregresivo con entradas exógenas (ARX), autorregresivo de media móvil con entradas exógenas (ARMAX), función de transferencia identificable (TF) y primer orden con tiempo muerto (FOPDT). Los modelos fueron evaluados tanto en términos de ajuste estadístico en lazo abierto, mediante el coeficiente de determinación R^2 y la raíz del error cuadrático medio (RECM), como en términos de desempeño dinámico en lazo cerrado, mediante criterios integrales de error (IAE, ISE, ITAE) obtenidos a través de una co-simulación entre MATLAB®–Simulink® y Aspen Plus Dynamics. Los resultados demuestran que las métricas de ajuste en lazo abierto no constituyen un criterio válido para la selección de modelos en aplicaciones de control predictivo, dado que no existe correlación entre el *ranking* estadístico y el desempeño bajo retroalimentación continua con perturbaciones. Con base en la evaluación integral, se propone una estrategia de control híbrido descentralizado que asigna el modelo ARMAX a la columna extractiva T-101 y el modelo FOPDT a la columna de recuperación de solvente T-102, logrando un mejor compromiso entre precisión dinámica, robustez frente a perturbaciones y eficiencia computacional. Todos los modelos evaluados cumplen los requerimientos de viabilidad en tiempo real, lo que confirma que la selección del modelo subrogado debe atender exclusivamente al desempeño en lazo cerrado.

Palabras clave: modelos subrogados, control predictivo basado en modelo (MPC), destilación extractiva, identificación de sistemas, Espacio de Estados, ARX, ARMAX, función de transferencia, FOPDT, co-simulación.

2 Introducción

La optimización de procesos es fundamental en la industria química, debido a que constituye un factor clave para mejorar la eficiencia operativa, reducir costos y mantener una ventaja competitiva en el mercado global. Sin embargo, la búsqueda continua de un mejor rendimiento se enfrenta al desafío de gestionar procesos químicos no lineales y altamente complejos [1], [2]. Los sistemas industriales compuestos por múltiples equipos presentan comportamientos dinámicos complejos caracterizados por fuertes interacciones entre variables, no linealidades y acoplamientos que dificultan su análisis, y más importante aún, el control [3], [4]. Estas características representan un desafío significativo para los controladores convencionales, como los PID (Proporcional-Integral-Derivativo), para los cuales su implementación puede verse limitada o insuficiente. Como consecuencia, pueden generarse respuestas lentas, sobreoscilaciones y dificultades para mantener la estabilidad y el desempeño óptimo del proceso. Para superar estos desafíos, el Control Predictivo Basado en Modelo (Model Predictive Control, MPC) se ha consolidado como una de las estrategias de control avanzado más utilizadas en procesos industriales. Este método emplea un modelo dinámico del proceso para predecir su comportamiento futuro dentro de un horizonte de tiempo determinado y, en cada instante de operación, resolver un problema de optimización que permite determinar las acciones de control más adecuadas [5]. No obstante, incluso las estrategias de control avanzadas, como el MPC, presentan dificultades cuando la dinámica del proceso está sujeta a interacciones entre variables en un gran número de ecuaciones. La complejidad numérica, junto con la necesidad de resolver continuamente problemas de optimización, puede traducirse en respuestas insuficientes o en la falta de convergencia del controlador. Es por ello que los últimos años se ha implementado el uso de modelos subrogados, también conocidos como metamodelos, los cuales buscan aproximar el comportamiento del sistema mediante representaciones matemáticas más simples construidas a partir de datos históricos o de simulación rigurosa [6], [7]. Estos modelos permiten reducir significativamente la carga computacional asociada a la simulación y optimización de procesos complejos, manteniendo al mismo tiempo un nivel adecuado de precisión en la predicción del comportamiento y movimientos del sistema [8], [9]. El presente trabajo busca continuar la línea de investigación sobre la subrogación de control para un proceso químico complejo; con el objetivo de implementar estrategias de control predictivo orientadas al rechazo de perturbaciones en las variables del sistema [10]. En dicho estudio se utilizó un metamodelo basado en representación en el espacio de estados, el cual será empleado en este trabajo como

base de comparación frente a otros métodos de identificación y modelado, específicamente los modelos ARX, ARMAX, de primer orden con tiempo muerto (FOPDT) y modelos basados en función de transferencia; métodos lineales que abarcan los diferentes tipos de modelos compatibles con un MPC lineal. Además, se agregó un paso de verificación con datos diferentes a los de entrenamiento para no incurrir en el sobreajuste.

3 Estado del arte

La implementación de controles predictivos avanzados, como el control predictivo basado en modelos (Model Predictive Control, MPC), se ve limitada por el alto costo computacional asociado a los modelos rigurosos que describen procesos químicos complejos. Estos modelos requieren la solución numérica de sistemas de ecuaciones diferenciales y algebraicas de gran dimensión, lo que incrementa significativamente el tiempo de cálculo al utilizarse en algoritmos de optimización en tiempo real. En este contexto, la subrogación de modelos surge como una técnica eficiente para representar el comportamiento dinámico del sistema mediante aproximaciones matemáticas de menor complejidad. A través de metamodelos, es posible establecer relaciones entre variables de entrada y salida con el objetivo de mantener la integridad del control mientras se reduce la carga computacional [6]. Diversos estudios han explorado la subrogación de modelos con el propósito de integrarlos en sistemas de control predictivo aplicados a procesos químicos complejos, incluyendo sistemas de separación por destilación. El presente estudio se centró en el uso de metamodelos dinámicos lineales con el objetivo de tener una base de comparación con la representación en espacio de estados, al ser este un modelo lineal. Adicionalmente, se buscaron metamodelos con compatibilidad directa en el esquema planteado en el anterior estudio de MPC lineal, esto con un propósito de comparación. Finalmente, los modelos subrogados seleccionados (ARX, ARMAX, FOPDT y función de transferencia) cumplen con los anteriores requisitos; además de tener un uso significativo en literatura y representar el catálogo de tipos de modelos identificables del *System Identification Toolbox* de MATLAB®. A continuación, se presenta una revisión de cada una de estas técnicas de subrogación, destacando sus características principales, ventajas y limitaciones en el contexto del control predictivo aplicado a procesos químicos.

Las estrategias de subrogación consideradas en este trabajo fueron seleccionadas debido a su amplio uso en problemas de identificación de sistemas y control predictivo aplicados a procesos químicos complejos. Estos modelos representan algunas de las aproximaciones más utilizadas en la literatura para reducir la complejidad computacional de modelos rigurosos, manteniendo una representación adecuada de la dinámica del proceso. En conjunto, estas estrategias abarcan gran parte de los enfoques utilizados en problemas de modelado dinámico y control de procesos químicos. A continuación, se presenta una revisión detallada de cada una de estas técnicas, destacando sus características principales, ventajas, limitaciones y aplicaciones típicas en el contexto del control predictivo de procesos químicos.

3.1 Modelos ARX y ARMAX

Los modelos ARX (AutoRegressive with eXogenous inputs) constituyen una clase de modelos lineales de identificación de sistemas en tiempo discreto que describen la salida actual del sistema como una combinación lineal de sus salidas pasadas y de las entradas actuales y pasadas [11]. Su estructura general se expresa como:

$$A(q)y(k) = B(q)u(k - n_k) + e(k) \quad (1)$$

$$A(q) = 1 + a_1q^{-1} + a_2q^{-2} + \dots + a_{n_a}q^{-n_a} \quad (2)$$

$$B(q) = b_1q^{-1} + b_2q^{-2} + \dots + b_{n_b}q^{-n_b} \quad (3)$$

donde $y(k)$ representa la salida del sistema en el instante discreto k , $u(k)$ corresponde a la entrada manipulada, $A(q)$ y $B(q)$ son los polinomios que contienen los parámetros del modelo, n_a y n_b representan el número de polos y ceros del sistema, respectivamente, y n_k es el retraso del modelo. El término $e(k)$ corresponde al ruido blanco que captura perturbaciones no modeladas, mientras que q^{-1} representa el operador de retraso temporal. Los parámetros del modelo se estiman típicamente mediante el método de mínimos cuadrados ordinarios, lo que permite obtener una solución analítica cerrada y computacionalmente eficiente [11]. Una ventaja particular de los modelos ARX en el contexto del control predictivo es su compatibilidad directa con herramientas de identificación de sistemas empleadas en la industria, lo que facilita su integración en esquemas de control sin necesidad de conversiones adicionales y reduce el riesgo de inconsistencias en la discretización del modelo. El término de ruido en los modelos ARX tiene una interpretación física relevante en el contexto de simulaciones dinámicas de procesos químicos, ya que puede representar perturbaciones no medidas, incertidumbre en los parámetros termodinámicos del simulador o errores asociados a la discretización temporal del modelo. Estudios recientes han aplicado modelos ARX para la identificación y control de columnas de destilación, reportando desempeños adecuados incluso cuando el proceso presenta comportamientos dinámicos ligeramente no lineales. Sin embargo, su desempeño puede verse limitado en presencia de no linealidades significativas o altos niveles de ruido en los datos. Cuando el sistema presenta perturbaciones importantes o dinámicas de error más complejas, resulta conveniente utilizar modelos

ARMAX (AutoRegressive Moving Average with eXogenous inputs), los cuales incorporan un término adicional que modela explícitamente la dinámica del error:

$$C(q) = 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{n_c} q^{-n_c} \quad (4)$$

Esta extensión mejora la capacidad predictiva del modelo al capturar correlaciones temporales en el ruido del sistema, lo que resulta especialmente útil en aplicaciones de control predictivo, donde la precisión del modelo influye directamente en el desempeño del controlador. Sin embargo, la inclusión del término de media móvil también incrementa la complejidad del proceso de identificación y puede requerir un mayor volumen de datos para obtener estimaciones confiables de los parámetros del modelo. En general, los modelos ARMAX pueden ofrecer un mejor desempeño en términos de precisión de predicción y robustez frente a perturbaciones, aunque su implementación puede ser más compleja que la de los modelos ARX, lo cual debe considerarse para encontrar un balance entre carga computacional y precisión.

3.2 Modelos NLARX

Los modelos NLARX (NonLinear AutoRegressive with eXogenous inputs) constituyen una extensión de los modelos ARX que permiten capturar dinámicas no lineales mediante la incorporación de funciones no lineales en la relación entre las entradas y las salidas del sistema. Su estructura general consiste en los regresores de los modelos y una función de salida. Comenzando con los regresores, estos pueden ser tanto lineales; logrando representar un modelo ARX con los mismos parámetros de polos (n_a), ceros (n_b) y retardos (n_k); o bien, pueden ser polinomiales o de otro tipo, lo que permite capturar algunas no linealidades desde la estructura inicial. La función de salida, por su parte, consiste en una función lineal, una no lineal y un offset que describen la relación dinámica entre los regresores y la salida del modelo. La función de salida no lineal puede ser de diversos tipos, como redes neuronales, funciones de base radial o polinomios, lo que permite adaptar el modelo a las características específicas del proceso a modelar. Esta flexibilidad hace que los modelos NLARX sean adecuados para representar sistemas con dinámicas no lineales complejas, aunque su identificación puede requerir un mayor volumen de datos y un proceso de ajuste más complejo en comparación con los modelos lineales. Sin embargo, su implementación en esquemas de control predictivo se ve limitada por la necesidad de resolver problemas de optimización no lineales en tiempo real, lo que puede incrementar significativamente la carga computacional y dificultar su aplicación en procesos químicos complejos que requieren respuestas rápidas.

3.3 Modelo de primer orden con tiempo muerto (FOPDT)

Los modelos de primer orden con tiempo muerto (First-Order Plus Dead Time, FOPDT) representan dinámicamente un sistema mediante parámetros identificables, como la ganancia K_p , la constante de tiempo τ y el tiempo muerto θ . Las ganancias proporcionales tienen una interpretación física directa al relacionar las unidades de cambio entre variables. Conjuntamente, la constante de tiempo se interpreta como la velocidad de respuesta del sistema, la cual, a su vez, se complementa con el tiempo muerto, que es el tiempo antes de que el sistema reaccione frente a un cambio. Estos parámetros juntos son una representación comúnmente utilizada en procesos de control por su interpretabilidad y simpleza, subrogando en diferentes casos problemas SISO (Single Input, Single Output) [12]. La fórmula general del modelo es la siguiente:

$$y(s) = \sum_{i=1}^n \left(\frac{K_{p,i}}{1 + \tau_i s} e^{-\theta_i s} \right) u_i(s) \quad (5)$$

Para el caso de estudio proporcionado por Quintero y Botía et al. [10], que plantea un problema de control MISO (Multiple Inputs, Single Output), es importante notar que los parámetros del modelo se representan como una matriz de valores, uno para cada variable manipulada u_i [13]. Se han realizado diversos trabajos con modelos FOPDT en el contexto de control predictivo, tanto en procesos de producción de hidrógeno como en sistemas de destilación. Adjisetya y Wahid et al. [14] compararon estrategias de control predictivo basadas en modelos FOPDT formulados desde enfoques SISO y MIMO (Multiple Inputs, Multiple Outputs), desarrollando controladores MPC para cuatro compresores en un proceso de generación de biogás a partir de biomasa. Al comparar los resultados experimentales, los autores reportan un mejor desempeño en los modelos MIMO más robustos; sin embargo, también señalan que en algunos casos la mejora no es significativa, e incluso que modelos con menor número de variables pueden presentar mejores respuestas. En un caso más cercano al presente estudio, Setiawan y Alifah et al. [15] realizaron una comparación entre un MPC no lineal basado en redes neuronales y un MPC lineal basado en modelos FOPDT, aplicado a un proceso de destilación criogénica de gas natural licuado. Los autores identificaron dificultades en el modelo no lineal debido a discrepancias entre los valores de planta y del modelo. Solo tras modificar la función de costo del MPC, el modelo basado en redes neuronales superó el desempeño del modelo FOPDT. Estos resultados sugieren que, aunque los modelos FOPDT pueden ser adecuados para representar sistemas con comportamiento predominantemente lineal o con dinámicas moderadamente complejas, su desempeño puede verse limitado en presencia de no linealidades significativas o fuertes interacciones entre variables. Por lo tanto, es fundamental evaluar cuidadosamente la aplicabilidad de estos modelos en función de las características dinámicas del proceso y de los requerimientos específicos del esquema de control predictivo a implementar.

3.4 Modelo de función de transferencia identificable

Una representación del control mediante funciones de transferencia es una opción clásica en el desarrollo de lazos de control. Estas pueden derivarse de un análisis riguroso del sistema o bien identificarse a partir de datos, lo que reduce la complejidad del modelado. Los modelos de función de transferencia poseen parámetros identificables en el denominador, a_p , y en el numerador, b_z , además de un posible retraso temporal τ . Este tipo de modelo es similar a los modelos FOPDT, con la diferencia de que sus parámetros no tienen un significado físico directo. La estructura general del modelo para un problema MISO se presenta a continuación [16].

$$y(s) = \sum_{i=1}^n e^{-\tau_i s} \frac{b_z s^z + b_{z-1} s^{z-1} + \dots + b_0}{a_p s^p + a_{p-1} s^{p-1} + \dots + a_0} u_i(s) \quad (6)$$

En esta, n representa el número de variables de entrada, p el número de polos y z el número de ceros, siendo estos los parámetros estructurales que definen el modelo final en tiempo continuo s . De esta forma, se logra relacionar la variable controlada y con las variables manipuladas u y modelar la dinámica del sistema. Este enfoque lineal ha sido utilizado en diversos estudios de control predictivo, tanto en generadores eléctricos como en procesos químicos complejos. Al-Khamis y Gumis et al. [17] presentan un estudio comparativo entre un modelo en espacio de estados y un modelo basado en funciones de transferencia para el control predictivo de un generador de inducción. Sus resultados indican que el modelo de función de transferencia reduce el esfuerzo matemático, alcanza el estado estacionario más rápidamente y, en general, presenta un mejor desempeño que el modelo en el espacio de estados. Por otro lado, Zhou y Zhu et al. [18] proponen un método de aislamiento de fallos en procesos químicos complejos, como el *Tennessee Eastman Process*. Los resultados obtenidos son prometedores, ya que permiten implementar un algoritmo MPC basado en un modelo identificado mediante funciones de transferencia. Sin embargo, no se encontraron estudios que utilicen este tipo de modelo con el objetivo específico de rechazar perturbaciones.

3.5 Representación en espacio de estados

La representación en espacio de estados describe la dinámica de un sistema mediante un conjunto de ecuaciones diferenciales de primer orden que capturan su evolución temporal a través de variables internas denominadas estados. Esta formulación es particularmente adecuada para sistemas multivariables y para el diseño de estrategias de control avanzadas.

$$\dot{x}(t) = Ax(t) + Bu(t) \quad (7)$$

$$y(t) = Cx(t) \quad (8)$$

donde $x(t)$ representa el vector de variables de estado, $u(t)$ corresponde al vector de entradas manipuladas, $y(t)$ representa el vector de salidas del sistema y A , B y C son las matrices que describen la dinámica del proceso. La representación en el espacio de estados resulta especialmente útil en el diseño de controladores predictivos por su capacidad para manejar sistemas multivariables y restricciones operativas. No obstante, el incremento de la dimensión del vector de estados puede aumentar la complejidad computacional del problema de optimización, lo que motiva la búsqueda de modelos subrogados más simples para su implementación en tiempo real. Diversos estudios han aplicado la representación en el espacio de estados para el diseño de controladores predictivos en procesos químicos complejos, y han reportado que esta formulación puede mejorar el desempeño del controlador al capturar dinámicas multivariables y no lineales con mayor precisión. Sin embargo, esta representación puede implicar una mayor demanda computacional.

3.6 Modelo Hammerstein-Wiener

Los modelos Hammerstein-Wiener constituyen una estructura ampliamente utilizada para la identificación de sistemas no lineales. En este enfoque, la dinámica del proceso se describe mediante un bloque lineal combinado con funciones no lineales estáticas aplicadas a la entrada y/o a la salida del sistema. Esta arquitectura permite representar comportamientos no lineales al combinar un modelo dinámico lineal con transformaciones estáticas capaces de capturar fenómenos como saturaciones, zonas muertas o ganancias dependientes del estado. Debido a esta estructura híbrida, los modelos Hammerstein-Wiener resultan adecuados para procesos químicos en los que las relaciones entre variables presentan no linealidades moderadas. A pesar de su capacidad para representar no linealidades, la identificación y validación de estos modelos pueden requerir un mayor volumen de datos y un proceso de ajuste más complejo, lo que puede limitar su aplicación en entornos que requieren implementación en tiempo real o integración directa con algoritmos de control predictivo.

3.7 Resumen de las estrategias de subrogación

Tabla 1. Comparación de estrategias de subrogación para control de procesos

Modelo	Tipo	Capacidad para no linealidades	Complejidad computacional	Integración con MPC	Aplicaciones típicas
Espacio de estados	Lineal dinámico	Baja–media	Media	Directa	Control multivariable
ARX y ARMAX	Lineal dinámico	Media	Media	Directa	Identificación de sistemas y control multivariable
NLARX	Híbrido lineal–no lineal	Alta	Media–alta	Compatible con MPC no lineal	Simulación de procesos no lineales
FOPDT (First Order Plus Dead Time)	Lineal dinámico con parámetros físicos	Baja–media	Baja	Directa	Procesos térmicos, destilación, sistemas SISO/MISO
Función de transferencia identificable	Lineal dinámico	Baja	Baja–media	Directa	Modelado empírico del proceso
Hammerstein–Wiener	Híbrido lineal–no lineal	Media–alta	Media	Compatible con MPC no lineal	Procesos químicos no lineales

3.8 Métodos de modelamiento de columnas de destilación

Las columnas de destilación constituyen uno de los procesos más utilizados y energéticamente intensivos en la industria química, por lo que representan un caso de estudio relevante para la implementación de estrategias de control predictivo avanzado. Debido a la fuerte interacción entre variables, las dinámicas multivariables y la presencia de restricciones operativas, estos sistemas suelen requerir modelos dinámicos rigurosos para describir adecuadamente su comportamiento. Sin embargo, la elevada complejidad matemática asociada a estos modelos incrementa considerablemente el costo computacional de los algoritmos de optimización en tiempo real. En este contexto, la subrogación de modelos adquiere especial importancia en aplicaciones de control predictivo sobre procesos de separación, particularmente en columnas de destilación extractiva.

Los modelos dinámicos rigurosos utilizados para representar columnas de destilación suelen basarse en las ecuaciones MESH (Mass, Equilibrium, Summation and Heat), las cuales describen simultáneamente los balances de masa, equilibrio termodinámico, sumatorias de fracción y balances de energía en cada etapa de la columna. Este enfoque constituye la base de la mayoría de simuladores comerciales de procesos químicos y permite representar con alta precisión la dinámica del sistema. No obstante, debido al elevado número de ecuaciones diferenciales y algebraicas involucradas, estos modelos presentan una alta carga computacional, especialmente cuando son utilizados dentro de algoritmos de optimización y control predictivo en tiempo real. El número total de ecuaciones algebraicas que describen una columna de destilación en un instante dado puede calcularse mediante:

$$N_{ec} = N(2C + 3) \quad (9)$$

donde N corresponde al número de etapas y C al número de componentes. En simulaciones dinámicas, este sistema de ecuaciones debe resolverse para cada intervalo de tiempo considerado en la discretización temporal del proceso. Por lo tanto, el número total de ecuaciones que resuelve el simulador durante una simulación dinámica puede expresarse como:

$$N_{et} = N_{ec} \times N_i \quad (10)$$

donde N_i corresponde al número de intervalos de tiempo utilizados durante la simulación dinámica del proceso. Este incremento en la carga computacional representa una de las principales limitaciones para la implementación de modelos rigurosos dentro de estrategias MPC, especialmente en procesos multivariables complejos como la destilación extractiva. Debido a esta elevada complejidad computacional, las columnas de destilación representan un escenario adecuado para evaluar estrategias de subrogación orientadas a la implementación de esquemas MPC en tiempo real. En particular, el presente trabajo se enfoca en una columna de destilación extractiva, cuyo esquema general se presenta en el Anexo correspondiente.

4 Metodología

La metodología se estructuró en dos fases: (i) la replicación de la base metodológica de Quintero y Botía et al. [10], que incluye el caso de estudio, las simulaciones rigurosas y la generación de datos dinámicos; y (ii) la implementación y

evaluación de nuevas estrategias de subrogación orientadas al control predictivo. El caso de estudio y el modelo riguroso se describen en detalle en la Sección 4.2.

Para la subrogación del sistema completo, se aplicaron pruebas de escalón sobre las corrientes de alimentación, registrando la respuesta de las fracciones molares de acetona y metanol. Estos datos permitieron identificar modelos tipo Hammerstein–Wiener y NLARX, orientados a capturar la dinámica no lineal del proceso. Para la subrogación orientada al control, se realizaron pruebas de escalón independientes sobre las variables manipuladas (potencia de rehervidor y razón de reflujo de cada columna) monitoreando las temperaturas de etapa como variables controladas. Los datos de cada columna se dividieron en dos conjuntos independientes de entrenamiento y validación para evitar sobreajuste.

Estos datos fueron utilizados para la construcción de modelos subrogados capaces de aproximar el comportamiento dinámico del modelo riguroso. En el trabajo anterior de la investigación, la subrogación del sistema se realizó mediante representaciones en espacio de estados (SS). En el presente estudio, este enfoque se mantiene como referencia y se implementan adicionalmente modelos ARX, ARMAX, FOPDT y función de transferencia con el objetivo de comparar el desempeño de diferentes estrategias de subrogación orientadas al control. Los modelos obtenidos fueron evaluados mediante métricas estadísticas de ajuste y posteriormente integrados en un esquema de control predictivo basado en modelo (MPC), mediante una co-simulación entre Aspen Plus Dynamics y MATLAB®–Simulink®, lo que permitió analizar su desempeño frente a perturbaciones en las corrientes de alimentación del proceso. El flujo general de la metodología se ilustra en la Figura 1.



Figura 1. Flujo del proceso de subrogación de modelos para el control predictivo.

4.1 Software empleado

Para el desarrollo de las simulaciones del proceso se empleó la suite aspenONE® de Aspen Technology Inc. (versión 11), específicamente los módulos Aspen Plus V11 y Aspen Plus Dynamics V11, con el objetivo de simular el proceso tanto en estado estacionario como en régimen dinámico. Aspen Plus Dynamics permite exportar modelos en estado estacionario a un entorno dinámico que resuelve las ecuaciones diferenciales algebraicas (DAE) del proceso con paso de tiempo variable, lo que resulta especialmente adecuado para la generación de datos de identificación en procesos altamente no lineales como la destilación extractiva [10]. Los datos generados durante la simulación dinámica fueron exportados al entorno de MATLAB® y Simulink® R2025b de MathWorks Inc., donde se realizaron las tareas de procesamiento de datos, la identificación de modelos subrogados y la implementación de los esquemas de control predictivo basados en modelo (MPC). Para la identificación de los modelos ARX y ARMAX se empleó el *System Identification Toolbox* de MATLAB®, el cual permite estimar modelos dinámicos lineales a partir de datos de entrada-salida. El esquema de control MPC se implementó mediante el *Model Predictive Control Toolbox*, lo que permitió integrar directamente los modelos identificados en el controlador y evaluar su desempeño en el entorno de co-simulación con Aspen Plus Dynamics.

4.2 Caso de estudio y simulación rigurosa

Con el fin de establecer una base de comparación consistente, se adoptó el mismo caso de estudio y modelo riguroso desarrollado por Quintero y Botía et al. [10], correspondiente a un proceso de destilación extractiva para la separación de

una mezcla azeotrópica de metanol y acetona.

4.2.1 Descripción del proceso

El proceso consiste en la separación de una mezcla azeotrópica de metanol y acetona mediante destilación extractiva, utilizando dimetilsulfóxido (DMSO) como agente separador. La configuración del sistema comprende dos columnas de destilación acopladas: una columna extractiva ($T-101$) y una columna de recuperación de solvente ($T-102$). El esquema general del proceso y las principales corrientes involucradas se presentan en el diagrama de flujo del proceso (PFD) incluido en el Anexo de diagramas Figura 7. En la columna extractiva $T-101$ se introduce la mezcla azeotrópica junto con el solvente DMSO, que modifica la volatilidad relativa de los componentes al alterar el equilibrio vapor-líquido del sistema, permitiendo así romper el azeótropo y obtener acetona de alta pureza en el destilado. La corriente de fondos, compuesta por metanol y DMSO, se envía a la columna $T-102$, donde se recupera el solvente mediante destilación convencional, obteniéndose metanol en el destilado y DMSO en el fondo para su recirculación al proceso. El modelo del proceso se implementó inicialmente en Aspen Plus para verificar la consistencia de las condiciones operativas en estado estacionario antes de proceder con el análisis dinámico.

4.2.2 Esquema de control regulatorio

Para garantizar la estabilidad hidráulica y operativa del sistema durante las simulaciones dinámicas, se implementó un esquema de control regulatorio basado en controladores de retroalimentación proporcional-integral (PI). La configuración general del sistema y la ubicación de los lazos de control implementados pueden observarse en el diagrama de flujo del proceso (PFD) presentado en el Anexo diagramas. El esquema regulatorio está compuesto por un total de seis lazos de control distribuidos entre las dos columnas de destilación. Para cada columna se implementó: (i) un lazo de control de presión asociado al condensador, (ii) un lazo de control de nivel en la vasiya de reflujo ubicada después del condensador y (iii) un lazo de control de nivel en la corriente de fondos del rehervidor. Estos lazos permiten mantener condiciones de operación estables y evitar problemas operativos, como el sobrellenado de equipos, variaciones indeseadas de presión o inestabilidades hidráulicas durante la operación dinámica del sistema. Sin estos lazos regulatorios, perturbaciones en variables operativas podrían generar desviaciones acumulativas en los inventarios de masa y energía del proceso, comprometiendo la estabilidad dinámica de las columnas durante la simulación. La sintonización de los controladores PI se realizó mediante el método de Tyreus-Luyben, el cual determina los parámetros proporcionales e integrales a partir de la ganancia y el período último del sistema [19]. Los valores finales de sintonización corresponden a los reportados por Quintero y Botía et al. [10]. La robustez del esquema de control regulatorio se evaluó mediante una prueba de estabilidad consistente en una perturbación tipo escalón del 15 % en el flujo molar de la corriente de alimentación azeotrópica respecto a su valor nominal. Los resultados confirmaron que el sistema mantiene la estabilidad hidráulica ante esta perturbación, constituyendo una base adecuada para el análisis dinámico posterior.

4.2.3 Generación de datos dinámicos mediante pruebas de escalón

Para obtener los datos necesarios para la identificación de los modelos subrogados se realizaron pruebas de escalón (*step tests*) en la simulación dinámica del proceso en Aspen Plus Dynamics. Estas pruebas consistieron en aplicar cambios tipo escalón sobre las corrientes de alimentación de mezcla azeotrópica y de DMSO, registrando la respuesta dinámica de las fracciones molares de acetona y metanol en las corrientes de salida del proceso. El propósito de este procedimiento fue establecer las relaciones dinámicas entre las variables de entrada y las composiciones de salida, de manera que fuera posible identificar modelos capaces de representar el comportamiento no lineal del sistema con una menor complejidad matemática respecto al modelo MESH. Por el otro lado, para el propósito de control se realizaron otro set de pruebas que tienen realización cambios tipo escalón en las variables manipuladas y registrar la respuesta dinámica de las variables de salida de interés, con el propósito traducir las dinámica del sistema y lograr la identificación de parámetros de los modelos [20]. En el contexto de la subrogación orientada al control, las variables manipuladas consideradas fueron la potencia de los rehervidores y la razón de reflujo de cada columna ($Q_{R,T-101}$, $Q_{R,T-102}$, RR_{T-101} y RR_{T-102}). Dado que la medición directa de fracciones molares en procesos industriales continuos puede resultar costosa o difícil de implementar en línea, se seleccionaron las temperaturas de etapa como variables controladas, en virtud de su correlación con la pureza de los productos. En particular, se seleccionaron la temperatura de la etapa 36 ($T_{36,T-101}^{Acet}$) para la columna $T-101$ y la de la etapa 8 ($T_{8,T-102}^{MetOH}$) para la columna $T-102$, por presentar la mayor sensibilidad frente a cambios en las condiciones operativas, determinada mediante el análisis del perfil de temperatura de cada columna [10]. Con el objetivo de disponer de conjuntos independientes para entrenamiento y validación, el procedimiento se realizó para dos *datasets* obtenidos de pruebas de escalón diferentes.

Durante el análisis de los datos se observaron pequeñas variaciones residuales en las señales de temperatura que no se explican completamente por los cambios de escalón aplicados. Estas variaciones pueden interpretarse como ruido en los datos, asociado a errores de modelado, a efectos numéricos inherentes a la discretización temporal y a los algoritmos de integración empleados en la simulación dinámica. Este comportamiento resulta especialmente relevante para los modelos

ARX y ARMAX, cuya estructura incluye explícitamente un término de ruido que permite capturar dinámicas no modeladas y errores de aproximación inherentes al proceso de identificación [21].

4.3 Subrogación de modelos

La subrogación del proceso se realizó con el objetivo de construir modelos dinámicos simplificados capaces de reproducir el comportamiento del modelo riguroso en un rango de operación relevante para el control, de modo que puedan integrarse eficientemente en esquemas de control predictivo basados en modelo. En el trabajo previo de Quintero y Botía et al. [10], la subrogación se realizó mediante representaciones en espacio de estados y modelos Hammerstein-Wiener. En el presente estudio, dicho enfoque se mantiene como línea base de comparación, y se implementan adicionalmente modelos de tipo ARX, ARMAX y NLARX; además de función de transferencia (TF), y FOPDT con el fin de evaluar su capacidad para representar la dinámica del proceso en una simulación, además de su adaptación dentro del esquema de control.

4.3.1 Preprocesamiento de datos

Antes de proceder a la identificación de los modelos, todas las variables de entrada y salida se transformaron en desviaciones relativas respecto a su valor nominal de operación. Esta transformación, estándar en la identificación de sistemas de control, permite que los modelos se centren en la dinámica del proceso alrededor del punto de operación, lo que facilita la linealización y mejora el condicionamiento numérico del problema de identificación. La desviación relativa de cada variable se calculó mediante:

$$X_{\text{desv}} = \frac{X - X_{\text{nominal}}}{X_{\text{nominal}}} \quad (11)$$

donde X es el valor medido de la variable y X_{nominal} es su valor en estado estacionario nominal.

4.3.2 Identificación de modelos subrogados

La identificación de los modelos subrogados se realizó en el entorno MATLAB® R2025b, utilizando el System Identification Toolbox y a partir de los datos obtenidos de las simulaciones dinámicas del proceso. En primer lugar, se consideró como referencia el modelo en espacio de estados desarrollado en el trabajo previo. Posteriormente, se identificaron modelos de tipo ARX y ARMAX con el objetivo de evaluar su capacidad para aproximar la dinámica del proceso mediante estructuras lineales discretas. Para los modelos ARX se realizó un barrido sistemático de órdenes utilizando las funciones `arxstruc` y `selstruc`, las cuales permiten explorar distintas combinaciones de parámetros autorregresivos y exógenos. En este contexto, los términos autorregresivos corresponden a valores pasados de la variable de salida del sistema (temperatura de etapa), mientras que los términos exógenos representan la influencia de las variables de entrada del proceso, es decir, la potencia del rehervidor y la razón de reflujo de cada columna. De manera similar, se realizó un barrido para los modelos ARMAX, variando el orden asociado al polinomio de ruido (n_c) y estimando los parámetros del modelo mediante las rutinas de identificación disponibles en el toolbox. Para cada valor de n_c se generó un modelo candidato, cuyo desempeño se evaluó mediante simulación frente a los datos teóricos simulados. Por otra parte, en los modelos de función de transferencia se seleccionaron los polos y ceros que ofrecieron el mejor ajuste, junto con el retraso temporal identificado por MATLAB. En el caso de los modelos FOPDT, al tratarse de una estructura predefinida, se utilizó directamente la función correspondiente del toolbox.

Con el objetivo de evitar el sobreajuste, la validación de los modelos se realizó mediante un conjunto de datos correspondiente a un segundo *step test*. Para aquellos modelos con mayor flexibilidad estructural, como los de espacio de estados, ARX y ARMAX, se realizó una nueva iteración de los parámetros estructurales para mejorar el ajuste al conjunto de validación. En cambio, los modelos de función de transferencia y FOPDT se validaron únicamente mediante la comparación entre las salidas reales y las predicciones del modelo ya identificado. El desempeño de la subrogación, para cada columna del proceso (T-101 y T-102), se evaluó mediante el coeficiente de determinación (R^2) y el error cuadrático medio (RMSE) entre las salidas del modelo y los datos generados por el modelo riguroso. Estos indicadores permitieron obtener una estimación preliminar del desempeño esperado de los modelos en el esquema de control predictivo.

4.3.3 Métricas de evaluación de los modelos subrogados

Para evaluar la capacidad de los modelos subrogados de reproducir la dinámica del proceso se emplearon métricas estadísticas de ajuste. En particular, se calcularon el coeficiente de determinación (R^2) y la raíz del error cuadrático medio (RECM), calculados entre las salidas predichas por el modelo y los datos generados por la simulación rigurosa. Estas métricas se calcularon según las Ecs. (12) y (13):

$$\text{RECM} = \sqrt{\frac{\sum_{n=1}^N (\hat{y}_n - y_n)^2}{N}} \quad (12)$$

$$R^2 = 1 - \frac{\sum_{n=1}^N (y_n - \hat{y}_n)^2}{\sum_{n=1}^N (y_n - \bar{y})^2} \quad (13)$$

donde N es el número de datos, y_n es el valor real, $\hat{y}_n$ es el valor predicho por el modelo para el instante n , y $\bar{y}$ es la media de los datos reales. Un valor de R^2 cercano a la unidad indica un ajuste adecuado, mientras que valores bajos de RECM señalan errores de predicción pequeños. Estos indicadores proporcionaron una evaluación previa de la capacidad predictiva de cada estructura, sirviendo de guía para su posterior implementación en el esquema de control.

4.4 Implementación del control MPC y co-simulación

Con el fin de evaluar el desempeño de los modelos subrogados en un entorno de control real, se implementó un esquema de MPC mediante una co-simulación entre Aspen Plus Dynamics y MATLAB®–Simulink®. En este esquema, la simulación dinámica rigurosa del proceso se ejecuta en Aspen Plus Dynamics, mientras que el controlador MPC opera en Simulink. La comunicación entre ambos entornos se realiza a través de un bloque en Simulink donde en cada intervalo de muestreo: Aspen envía a Simulink las mediciones actuales de las variables controladas (temperaturas de etapa), y el controlador calcula las acciones de control, que se devuelven a Aspen como consignas de potencia de los rehervidores y de la razón de reflujo, cerrando así el lazo de control. Para evaluar el desempeño del controlador se aplicaron dos perturbaciones tipo escalón en el flujo de alimentación del proceso (un incremento del 10 % seguido por una disminución del 10 %), sobre un horizonte de simulación de 100 horas. Las perturbaciones se aplicaron en instantes predefinidos dentro del horizonte de simulación para evaluar la capacidad de rechazo del controlador en condiciones reproducibles. Este horizonte de simulación además puede ser considerado el *output horizon*, que debe ser lo suficientemente grande como para que el *input horizon* alcance a modificar las variables manipulables y logre el rechazo de la perturbación.




Figura 2. Ejemplo MISO de la esquematica de un controlador MPC utilizando la T-102.

4.4.1 Formulación del problema de optimización MPC

En cada instante de control k , el controlador MPC resuelve un problema de programación cuadrática (QP) sobre un horizonte de predicción p . El vector de decisión z_k agrupa las acciones de control futuras y la variable de holgura ε_k :

$$z_k^T = [u(k|k)^T, u(k+1|k)^T, \dots, u(k+p-1|k)^T, \varepsilon_k] \quad (14)$$

El problema de optimización minimiza la función de costo compuesta:

$$\min_{z_k} J(z_k) = J_y(z_k) + J_u(z_k) + J_{\Delta u}(z_k) + J_\varepsilon(z_k) \quad (15)$$

donde cada término penaliza un aspecto distinto del desempeño del controlador. El término J_y cuantifica el error entre la trayectoria predicha y la referencia:

$$J_y(z_k) = \sum_{j=1}^{n_y} \sum_{i=1}^p \left\{ \frac{w_{i,j}^y}{s_j^y} [r_j(k+i|k) - y_j(k+i|k)] \right\}^2 \quad (16)$$

El término J_u penaliza las desviaciones de las variables manipuladas respecto a su valor objetivo en estado estable:

$$J_u(z_k) = \sum_{j=1}^{n_u} \sum_{i=1}^{p-1} \left\{ \frac{w_{i,j}^u}{s_j^u} [u_j(k+i|k) - u_{j,\text{target}}(k+i|k)] \right\}^2 \quad (17)$$

El término $J_{\Delta u}$ penaliza los cambios bruscos en las acciones de control, favoreciendo trayectorias suaves de las variables manipuladas:

$$J_{\Delta u}(z_k) = \sum_{j=1}^{n_u} \sum_{i=1}^{p-1} \left\{ \frac{w_{i,j}^{\Delta u}}{s_j^u} [u_j(k+i|k) - u_j(k+i-1|k)] \right\}^2 \quad (18)$$

Finalmente, J_ε penaliza la variable de holgura asociada a posibles violaciones de restricciones, garantizando la factibilidad del problema de optimización:

$$J_\varepsilon(z_k) = \rho_\varepsilon \varepsilon_k^2 \quad (19)$$

En las expresiones anteriores, $w_{i,j}^y$, $w_{i,j}^u$ y $w_{i,j}^{\Delta u}$ son los pesos de ponderación, s_j^y y s_j^u son los factores de escala, $r_j(k+i|k)$ es la referencia predicha, y $y_j(k+i|k)$ y $u_j(k+i|k)$ son las salidas y entradas predichas, respectivamente, para el instante $k+i$ calculadas en el instante k [22]. En el contexto del presente estudio, los modelos subrogados SS, ARX, ARMAX y TF son los encargados de proporcionar las salidas predichas $y_j(k+i|k)$, es decir, la relación dinámica entre las variables manipuladas futuras y el comportamiento esperado del proceso, lo que permite al optimizador evaluar el impacto de cada secuencia de control posible sobre el desempeño futuro del sistema.

4.4.2 Evaluación del desempeño del controlador

Para cuantificar la efectividad del esquema de control implementado, se empleó un conjunto de métricas complementarias que permiten analizar la calidad del seguimiento de referencia, la rapidez de la respuesta y el esfuerzo de control requerido. El **error relativo de seguimiento** cuantifica la diferencia entre la variable controlada y su referencia en cada instante:

$$e_{\text{rel}}(t) = \frac{|Y(t) - Y_{\text{ref}}(t)|}{Y_{\text{ref}}(t)} \quad (20)$$

El **tiempo de estabilización** se define como el tiempo requerido para que la variable controlada ingrese y permanezca dentro de una banda de tolerancia de $\pm 2\%$ respecto a su valor nominal tras la aplicación de una perturbación.

Las **métricas de error integral** permiten una evaluación cuantitativa global del desempeño del controlador a lo largo de toda la simulación, considerando tanto la magnitud de los errores como su persistencia en el tiempo. El criterio de la integral del valor absoluto del error (IAE) mide el error absoluto acumulado:

$$\text{IAE} = \int_0^\infty |e(t)| dt \quad (21)$$

El criterio de la integral del error cuadrático (ISE) penaliza con mayor severidad los errores de magnitud elevada:

$$\text{ISE} = \int_0^\infty e^2(t) dt \quad (22)$$

El criterio de la integral del valor absoluto del error ponderado por el tiempo (ITAE) penaliza los errores de larga duración, favoreciendo controladores con rechazo rápido de perturbaciones:

$$\text{ITAE} = \int_0^\infty t |e(t)| dt \quad (23)$$

Finalmente, la integral del error cuadrático ponderado por el tiempo (ITSE) combina la penalización por magnitud y por duración del error:

$$ITSE = \int_0^{\infty} t e^2(t) dt \quad (24)$$

El uso conjunto de las métricas IAE, ISE, ITAE e ITSE proporciona una perspectiva integral del desempeño del controlador. Mientras que IAE e ISE caracterizan la magnitud global del error, ITAE e ITSE penalizan de manera más severa la persistencia del error en el tiempo. Este último aspecto resulta especialmente relevante en procesos lentos como la destilación, donde los tiempos de estabilización pueden extenderse durante varias horas. Estas métricas de error integral permiten una evaluación más completa del desempeño del controlador, ya que cuantifican tanto la magnitud como la duración de los errores a lo largo del tiempo [23]. Los resultados obtenidos permitieron comparar la capacidad de los distintos modelos subrogados para mantener la estabilidad del proceso, minimizar el error de seguimiento y reducir el esfuerzo de control dentro del esquema de control predictivo basado en modelo (MPC), proporcionando así una evaluación cuantitativa del desempeño de cada estrategia de modelado.

5 Resultados y Discusión

En primer lugar, vamos a hablar sobre la capacidad de cada estructura de modelo para representar la dinámica del proceso a partir de los datos de identificación y a continuación, se analiza el desempeño de cada modelo como controlador MPC frente a perturbaciones en la alimentación, considerando los costos computacionales, las métricas básicas de control y los criterios integrales de desempeño. Finalmente, se discute la selección del modelo más adecuado para cada columna y se propone la estrategia de control resultante.

5.1 Subrogación de modelos

5.1.1 Subrogación del sistema y número de ecuaciones

Cuando se realiza la subrogación del sistema completo, es necesario obtener un metamodelo con un ajuste altamente significativo para garantizar que el metamodelo describa adecuadamente la dinámica del proceso. Es por ello que los modelos lineales no son la mejor opción en este caso, y se opta por transformaciones no lineales que logran un mejor ajuste como es el caso del modelo Hammerstein-Wiener y NLARX. El primero parte de una estructura de espacio de estados, de dimensiones 5 y 9 para la T-101 y T-102 respectivamente, que al incorporar las salidas de una transformación no lineal tipo wavelets, con 8 y 10 unidades ocultas respectivamente, logra computar las no linealidades del sistema. Por otro lado, el modelo NLARX parte de una estructura de ARX, representada por regresores lineales, que entran a un bloque de salida que se compone por una función lineal, una no lineal tipo wavelets y un desfase que permite modelar las dinámicas del proceso; sin embargo, los regresores también pueden desviarse de ARX al agregarse unos términos polinomiales, mejorando en mayor medida el ajuste. En el caso de la T-101, se utilizaron 12 regresores lineales y 8 unidades de wavelets, mientras que para la T-102 se utilizaron un total de 15 regresores combinando lineales y polinomiales, y 18 unidades de wavelets. La comparación entre los modelos y los valores del modelo riguroso MESH se encuentran en la Figura 3 y las métricas de ajuste en la Tabla 2.




Figura 3. Comparación de los modelos subrogados del sistema para la columna T-101. y T-102.

Ya comprobando el buen ajuste de ambos modelos es importante destacar el número de ecuaciones que cada uno de ellos resuelve al simular el proceso. El modelo MESH, como se describió en la sección 3.8, resuelve un número de ecuaciones dependiendo de las etapas y componentes para cada torre. En el caso de la T-101, con 37 etapas resulta un total de 333 ecuaciones, mientras que para la T-102 con 17 etapas resuelve 153; esto para cada paso temporal. Por el contrario, los

Tabla 2. Métricas de ajuste de los modelos subrogados del sistema con respecto al modelo MESH.

Columna	Modelo	RECM	R^2
T-101	Hammerstein-Wiener	0.0011	0.9980
T-101	NLARX	0.0025	0.9885
T-102	Hammerstein-Wiener	0.0050	0.9734
T-102	NLARX	0.0058	0.9651

metamodelos Hammerstein-Wiener y NLARX resuelven un número significativamente menor de ecuaciones. En el caso del modelo Hammerstein-Wiener, se resuelven 7 ecuaciones para la T-101 y 11 para la T-102, mientras que en NLARX este número es de 14 y 17 respectivamente. Considerando un promedio de 120 intervalos, el modelo MESH resuelve un total de 39,960 ecuaciones para la T-101 y 18,360 para la T-102. En contraste, el modelo Hammerstein-Wiener resuelve 840 ecuaciones totales para la acetona y 1,320 para el metanol, mientras que el modelo NLARX resuelve 1,680 y 2,040 ecuaciones respectivamente. Esto representa una reducción altamente significativa, denotando así la importancia de la subrogación a la hora de disminuir la carga computacional en procesos químicos complejos.

5.1.2 Subrogación para control predictivo

Los modelos subrogados se desarrollaron considerando dos variables manipuladas la potencia del rehervidor y la relación de reflujo con una salida correspondiente a la temperatura de una etapa representativa de cada columna. Para la columna T-101 se seleccionó la temperatura de la etapa 36, y para la columna T-102 la temperatura de la etapa 8. De este modo se obtuvieron cinco estructuras de modelo para cada columna: ARX, ARMAX, espacio de estados (SS), función de transferencia (TF) y modelo de primer orden con tiempo muerto (FOPDT). En la Tabla 3 se presentan el RECM y el coeficiente de determinación (R^2) obtenidos durante la validación de cada modelo frente al segundo conjunto de datos de *steptest*. Las Figuras 4 ilustra la comparación entre las respuestas predichas y los datos reales para ambas columnas.




Figura 4. Comparación de los modelos subrogados respecto a los datos de validación para la columna T-101 y T-102.

Los resultados evidencian que ambas columnas presentan dinámicas diferenciadas que requieren estructuras de modelado distintas. Asimismo, se confirma que un mejor ajuste estadístico no garantiza necesariamente un mejor desempeño en un esquema de control predictivo, lo que motiva la evaluación directa del desempeño dinámico del controlador.

5.2 Control predictivo frente a perturbaciones

Una vez obtenidos los modelos subrogados, se implementó el esquema MPC y se evaluó su desempeño frente a dos perturbaciones tipo escalón consistentes en una perturbación positiva del 10 % en el caudal de alimentación seguida de una perturbación negativa del 10 % en el mismo caudal, aplicadas en instantes predefinidos dentro de un horizonte de simulación total de 100 h. La inclusión de perturbaciones de signo opuesto permite evaluar la capacidad del controlador para mantener la estabilidad y el seguimiento del valor de referencia bajo condiciones dinámicas asimétricas, representativas de

Tabla 3. Métricas de ajuste de los modelos subrogados evaluadas sobre el conjunto de validación.

Columna	Modelo	RECM	R^2
T-101	SS	0.2895	0.7709
T-101	ARX	0.3047	0.7462
T-101	ARMAX	0.3051	0.7456
T-101	FOPDT	0.3713	0.6231
T-101	TF	0.3766	0.6122
T-102	SS	7.1142	0.5316
T-102	ARX	6.8227	0.5692
T-102	ARMAX	6.1927	0.6451
T-102	FOPDT	6.9890	0.5480
T-102	TF	7.1117	0.5320

variaciones reales en la operación industrial. Las Figuras 5 y 6 presentan la evolución temporal de las variables controladas en ambas columnas.




Figura 5. Evolución temporal de la variable controlada de $T-101$ bajo una perturbación del 10 % seguida de una perturbación del -10 %.




Figura 6. Evolución temporal de la variable controlada de $T-102$ bajo una perturbación del 10 % seguida de una perturbación del -10 %.

5.3 Costos computacionales

La Tabla 4 presenta los costos computacionales medidos durante la co-simulación:

El tiempo de simulación en Simulink corresponde al tiempo total requerido para ejecutar la co-simulación dinámica completa del sistema bajo control MPC, incluyendo la resolución del problema de optimización, la actualización de las variables manipuladas y la integración dinámica de las columnas de destilación dentro del entorno Simulink. Esta métrica permite comparar la carga computacional global asociada a cada modelo subrogado durante todo el horizonte dinámico evaluado. Por otra parte, la métrica CPU/paso representa el tiempo computacional promedio requerido por el controlador para ejecutar una actualización del MPC en cada intervalo de muestreo. Esta métrica constituye el criterio más relevante para evaluar la factibilidad de implementación en tiempo real, dado que en aplicaciones MPC el tiempo requerido para calcular la acción

Tabla 4. Costos computacionales asociados a la co-simulación MPC.

Modelo	T. Simulink (s)	CPU/paso (ms)	RAM total (MB)
SS	2245.7673	1122.3225	8.7162
ARX	1462.7764	1217.9654	5.9852
ARMAX	1462.3853	1217.6397	5.9203
TF	1461.2886	1216.7265	6.0173
IDPROC	1457.9294	1213.9295	5.7724

de control debe ser menor que el tiempo de muestreo del controlador:

$$t_{\text{CPU/paso}} < T_s$$

En este trabajo se utilizó un tiempo de muestreo de $T_s = 5 \text{ min}$ (300 s), mientras que los costos computacionales promedio por paso obtenidos fueron del orden de 1.100 a 1.300 ms. En consecuencia, todos los modelos evaluados cumplen ampliamente la condición de viabilidad computacional para aplicaciones MPC en tiempo real, ya que el tiempo requerido para resolver el problema de optimización es considerablemente menor que el intervalo disponible entre actualizaciones del controlador. Los resultados obtenidos evidencian que los modelos subrogados basados en identificación de sistemas presentan menores requerimientos de memoria en comparación con el modelo Space State, lo cual resulta consistente con la menor complejidad estructural de dichos modelos. En términos generales, los resultados demuestran que los modelos ARX, ARMAX, TF, FOPDT reducen significativamente el costo computacional global respecto al modelo Space State, manteniendo simultáneamente tiempos de cálculo por intervalo de control compatibles con aplicaciones MPC en columnas de destilación.

5.4 Criterios integrales de desempeño

Inicialmente, los criterios integrales de desempeño fueron evaluados considerando únicamente el horizonte completo de simulación. Sin embargo, este enfoque introducía un sesgo en la comparación entre modelos, debido a que incluía periodos en donde la simulación volvía al punto de partida y el error de control continuaba acumulándose a lo largo de toda la simulación. Con el fin de obtener una comparación más representativa del desempeño dinámico del MPC, las métricas integrales se calcularon de manera independiente sobre las regiones transitorias asociadas a las perturbaciones introducidas en el sistema. De esta manera, los criterios IAE, ISE e ITAE fueron evaluados específicamente durante las ventanas temporales correspondientes a la respuesta dinámica de cada perturbación, permitiendo cuantificar de forma más precisa la capacidad de seguimiento y rechazo de perturbaciones de cada modelo subrogado. Las ventanas utilizadas fueron: $P1$, comprendida entre $t = 5 \text{ h}$ y $t = 20 \text{ h}$, y $P2$, comprendida entre $t = 40 \text{ h}$ y $t = 60 \text{ h}$ donde $P1$ corresponde a la respuesta transitoria generada por la perturbación positiva en el caudal de alimentación, mientras que $P2$ representa la respuesta dinámica frente a la perturbación negativa del mismo flujo. Bajo este enfoque, las métricas integrales permiten evaluar directamente el comportamiento dinámico relevante del controlador durante los periodos de mayor exigencia operacional, evitando que los intervalos en los que la simulación retorna a la región de operación estacionaria dominen artificialmente los indicadores globales de desempeño.

Tabla 5. Criterios integrales de desempeño del controlador durante la perturbación $P1$.

Columna	Modelo	IAE	ISE	ITAE
T-101	SS	18.1000	24.7239	120.0463
T-101	ARX	16.8292	22.6828	107.7224
T-101	ARMAX	16.5155	22.0807	104.5858
T-101	TF	20.5656	32.6839	131.5741
T-101	FOPDT	18.7076	26.2708	125.1015
T-102	SS	20.9149	158.4216	59.0310
T-102	ARX	21.8780	223.5930	60.0760
T-102	ARMAX	22.0188	225.6600	55.1203
T-102	TF	44.6542	1050.2536	74.9766
T-102	FOPDT	20.7053	153.2183	62.0400

Los resultados obtenidos muestran que los modelos ARX y ARMAX presentan el mejor desempeño dinámico para la columna T-101 en ambas perturbaciones, alcanzando los menores valores de IAE, ISE e ITAE. Esto indica una mejor capacidad de seguimiento del setpoint y una reducción tanto de la magnitud como de la duración del error dinámico frente a cambios en las condiciones de operación. Para la columna T-102, el modelo FOPDT presentó los menores valores de IAE e ISE en ambas perturbaciones, mientras que el modelo Space State obtuvo el menor ITAE durante la perturbación $P2$. En contraste, el modelo TF exhibió consistentemente los mayores errores integrales, particularmente en términos de ISE, evidenciando una menor capacidad para representar adecuadamente la dinámica transitoria de la columna bajo el esquema MPC implementado.

Tabla 6. Criterios integrales de desempeño del controlador durante la perturbación P2.

Columna	Modelo	IAE	ISE	ITAE
T-101	SS	17.0926	14.8854	162.3119
T-101	ARX	16.2154	13.5419	151.1818
T-101	ARMAX	16.0023	13.2267	148.3574
T-101	TF	18.3538	17.2229	172.0311
T-101	FOPDT	17.4630	15.5124	166.5548
T-102	SS	37.8201	151.3642	198.0105
T-102	ARX	41.2758	168.5212	230.9104
T-102	ARMAX	41.7543	177.5120	219.4193
T-102	TF	60.8113	317.6746	342.7771
T-102	FOPDT	37.2705	144.9297	204.0501

5.5 Selección del modelo y propuesta de control híbrido

La selección final de los modelos subrogados no se realizó únicamente con base en las métricas estadísticas de identificación, sino considerando simultáneamente el desempeño dinámico bajo control MPC y los costos computacionales asociados a la implementación del controlador. Este enfoque permitió evaluar de manera integral la capacidad de cada estructura para representar la dinámica del proceso y su comportamiento dentro de un esquema de control predictivo aplicado a columnas de destilación extractiva. Para la columna T-101, los modelos ARX y ARMAX presentaron consistentemente los menores valores de IAE, ISE e ITAE durante ambas perturbaciones evaluadas. En particular, el modelo ARMAX obtuvo el mejor desempeño global en las métricas integrales, evidenciando una mayor capacidad para rechazar perturbaciones y mantener la variable controlada cercana al valor de referencia. Aunque el modelo Space State presentó un mejor ajuste estadístico durante la etapa de validación, su costo computacional resultó significativamente superior y no se tradujo en un mejor desempeño dinámico bajo MPC. Por esta razón, el modelo ARMAX fue seleccionado como la estructura más adecuada para representar la dinámica de la columna T-101. En el caso de la columna T-102, los resultados mostraron un comportamiento distinto. El modelo FOPDT presentó los menores valores de IAE e ISE en ambas perturbaciones, mientras que el modelo Space State obtuvo el menor ITAE durante la perturbación P2. Estos resultados indican que, para esta columna, modelos de estructura más simple fueron capaces de capturar adecuadamente la dinámica dominante del proceso y ofrecer un desempeño competitivo dentro del esquema MPC. Adicionalmente, el modelo FOPDT presentó uno de los menores costos computacionales y requerimientos de memoria entre todos los modelos evaluados, lo cual representa una ventaja importante desde el punto de vista de implementación en tiempo real. A partir de estos resultados, se propone una estrategia de control híbrido en la cual cada columna emplea el modelo subrogado que presentó el mejor compromiso entre precisión dinámica, robustez frente a perturbaciones y eficiencia computacional. Bajo este criterio, la estrategia seleccionada consiste en: T-101, asociado al modelo ARMAX, y T-102, asociado al modelo FOPDT. La combinación propuesta permite aprovechar la mayor capacidad predictiva de los modelos ARMAX en sistemas con dinámicas más complejas, mientras que utiliza modelos FOPDT en procesos donde predominan dinámicas lentas y de menor complejidad estructural. De esta manera, el esquema híbrido reduce la carga computacional total del sistema de control sin comprometer el desempeño dinámico del MPC.

6 Conclusiones

El presente trabajo evaluó cinco estructuras de modelo subrogado (ARX, ARMAX, FOPDT, TF y SS) como predictores internos de un esquema MPC aplicado a un proceso de destilación extractiva, tomando el modelo de espacio de estados como referencia de comparación. Los resultados demuestran que todos los modelos evaluados son capaces de garantizar un control eficaz frente a perturbaciones en la alimentación, lo que evidencia que un proceso riguroso de identificación y entrenamiento es determinante para el desempeño del controlador, independientemente de la estructura de modelo seleccionada.

Es importante mencionar entonces que las métricas de ajuste en lazo abierto, RECM y R^2 , no son un criterio relevante para la selección del modelo en aplicaciones de control predictivo. Lo que determina el desempeño del MPC es la capacidad del modelo para reproducir fielmente los movimientos de la variable controlada dentro del horizonte de predicción, bajo retroalimentación continua y en presencia de perturbaciones. La evaluación mediante criterios integrales de desempeño y costos computacionales mostró mejoras leves frente al espacio de estados en términos dinámicos, aunque más significativas en eficiencia computacional, lo cual es consistente con la menor dimensión estructural de los modelos identificados. Con base en estos resultados, el modelo ARMAX presentó el mejor desempeño para la columna T-101, mientras que el modelo FOPDT fue superior para la columna T-102. Estos resultados abren la posibilidad de un esquema de control híbrido descentralizado en el que cada controlador emplea el modelo subrogado de mejor desempeño para su subsistema. Como extensiones naturales de este trabajo se identifican dos líneas de investigación: la implementación de un MPC centralizado para el sistema completo, que aproveche explícitamente el acoplamiento dinámico entre ambas columnas en lugar de tratarlo como perturbación no medida; y la extensión hacia MPC no lineal, empleando modelos NLARX o Hammerstein-Wiener, para evaluar si la mayor precisión dinámica justifica el costo computacional adicional cuando el proceso opera lejos

del punto nominal de diseño.

7 Declaración de uso de inteligencia artificial generativa

En el artículo se realizaron revisiones y correcciones generales utilizando el modelo GPT-5.3 de OpenAI LLC. Se compartieron párrafos con el objetivo de corregir errores ortográficos y de redacción básicos. Los autores asumen la responsabilidad del contenido escrito.

References

- [1] Z. Zhang, S. Li, and Y. Yang, "Explorative policy optimization for industrial-scale operation of complex process control systems," *Journal of Process Control*, vol. 152, Aug. 2025. DOI: 10.1016/j.jprocont.2025.103471
- [2] Y. Zou, X. Ma, Y. Yang, and S. Li, "An overview of chemical process operation-optimization under complex operating conditions," *Digital Chemical Engineering*, Sep. 2025. DOI: 10.1016/j.dche.2025.100249
- [3] N. Hu, "The limitations of traditional pid controllers and modern optimization methods," *Applied and Computational Engineering*, 2025. DOI: 10.54254/2755-2721/147/2025.22912
- [4] D. Mora-Mariano and A. Flores-Tlacuahuac, "A machine learning approach for the surrogate modeling of uncertain distributed process engineering models," *Chemical Engineering Research and Design*, vol. 186, pp. 433–450, Oct. 2022. DOI: 10.1016/j.cherd.2022.07.050
- [5] T. Geyer, *Model Predictive Control of High Power Converters and Industrial Drives*. John Wiley & Sons, 2017.
- [6] C. He, Y. Zhang, D. Gong, and X. Ji, "A review of surrogate-assisted evolutionary algorithms for expensive optimization problems," *Expert Systems with Applications*, May 2023. DOI: 10.1016/j.eswa.2022.119495
- [7] D. Štunek and S. Lazarova-Molnar, "Surrogate modeling: Review and opportunities for expert knowledge integration," in *Procedia Computer Science*, 2025, pp. 826–833. DOI: 10.1016/j.procs.2025.03.106
- [8] Z. T. Wilson and N. V. Sahinidis, "The alamo approach to machine learning," *Computers & Chemical Engineering*, vol. 106, pp. 785–795, Nov. 2017. DOI: 10.1016/j.compchemeng.2017.02.010
- [9] K. McBride and K. Sundmacher, "Overview of surrogate modeling in chemical process engineering," *Chemie Ingenieur Technik*, Mar. 2019. DOI: 10.1002/cite.201800091
- [10] J. E. Quintero, M. Botía, and J. M. Gómez, *Subrogación de modelos para control y optimización de procesos*.
- [11] A. Perez and Y. Yang, "Offset-free arx-based adaptive model predictive control applied to a nonlinear process," *ISA Transactions*, vol. 123, pp. 251–262, Apr. 2022. DOI: 10.1016/j.isatra.2021.05.030
- [12] A. Wahid and I. Maulana, "Optimization of depropanizer unit using turbo expander and its controller using model predictive control," in *E3S Web of Conferences*, Nov. 2018. DOI: 10.1051/e3sconf/20186703014
- [13] MathWorks, *Continuous-time process model with identifiable parameters*, Accessed: April 19, 2026, 2026. [Online]. Available: <https://la.mathworks.com/help/ident/ref/idproc.html>
- [14] M. Adjisetya and A. Wahid, "Multivariable model predictive control to control bio-h₂ production from biomass," *ChemEngineering*, vol. 7, no. 1, Feb. 2023. DOI: 10.3390/chemengineering7010007
- [15] V. C. Setiawan, I. U. A. Alifah, R. P. Anugraha, Juwari, and Renanto, "Comparison of model predictive controller and neural network controller on nonconventional distillation system," *IOP Conference Series: Materials Science and Engineering*, vol. 1053, no. 1, p. 012108, Feb. 2021. DOI: 10.1088/1757-899x/1053/1/012108
- [16] MathWorks, *Transfer function model with identifiable parameters*, Accessed: April 25, 2026, 2026. [Online]. Available: <https://la.mathworks.com/help/ident/ref/idtf.html>
- [17] O. A. A. Al-khamis and B. Gumus, "Comparison and performance analysis of model predictive control developed by transfer function based model and state space based model," *Journal of Electrical Engineering and Technology*, vol. 18, no. 1, pp. 111–121, Jan. 2023. DOI: 10.1007/s42835-022-01179-z
- [18] J. Zhou and Y. Zhu, "Fault isolation based on transfer-function models using an mpc algorithm," *Computers & Chemical Engineering*, vol. 159, Mar. 2022. DOI: 10.1016/j.compchemeng.2022.107668
- [19] B. D. Tyreus and W. L. Luyben, "Tuning pi controllers for integrator/dead time processes," *Industrial & Engineering Chemistry Research*, vol. 31, no. 11, pp. 2625–2628, 1992. DOI: 10.1021/ie00011a029
- [20] L. Ljung, *System Identification: Theory for the User*, 2nd ed. Upper Saddle River, NJ: Prentice Hall, 1999, ISBN: 978-0136566953.
- [21] T. Söderström and P. Stoica, *System Identification*. New York: Prentice Hall, 1989, ISBN: 978-0138816407.
- [22] D. Masti and A. Bemporad, "Learning nonlinear state–space models using autoencoders," *Automatica*, vol. 129, Jul. 2021. DOI: 10.1016/j.automatica.2021.109666
- [23] R. Zhang, J. Lu, H. Qu, and F. Gao, "State space model predictive fault-tolerant control for batch processes with partial actuator failure," *Journal of Process Control*, vol. 24, no. 5, pp. 613–620, 2014. DOI: 10.1016/j.jprocont.2014.03.004

Nomenclatura

A. Símbolos latinos

Símbolo	Descripción	Unidad
A	Matriz de estado del modelo en espacio de estados (Ecs. 7–8)	–
$A(q)$	Polinomio autorregresivo del modelo ARX/ARMAX (Ecs. 1–2)	–
a_i	Coefficientes del polinomio $A(q)$, $i = 1, \dots, n_a$	–
B	Matriz de entrada del modelo en espacio de estados (Ec. 7)	–
$B(q)$	Polinomio de entrada del modelo ARX/ARMAX (Ecs. 1, 3)	–
b_i	Coefficientes del polinomio $B(q)$, $i = 1, \dots, n_b$	–
C	Matriz de salida del modelo en espacio de estados (Ec. 8)	–
C	Número de componentes químicos en el modelo MESH de destilación (Ec. 9)	–
$C(q)$	Polinomio de ruido del modelo ARMAX (Ec. 4)	–
c_i	Coefficientes del polinomio $C(q)$, $i = 1, \dots, n_c$	–
$e(k)$	Término de ruido blanco / perturbación no modelada en ARX (tiempo discreto)	–
$\bar{e}(k)$	Señal de ruido en tiempo discreto en la formulación ARX/ARMAX (Ec. 1)	–
$e(t)$	Error de seguimiento de control (tiempo continuo), utilizado en IAE, ISE, ITAE, ITSE	°C
$e_{rel}(t)$	Error relativo de seguimiento entre la variable controlada y el setpoint (Ec. 20)	–
er_1, er_2	Errores relativos en estado estacionario tras la primera y segunda perturbación (Tabla 5–6)	–
i	Índice de paso de predicción dentro del horizonte MPC ($i = 1, \dots, p$)	–
j	Índice de variable controlada o variable manipulada	–
$J(z_k)$	Función de costo (objetivo) total del MPC (Ec. 15)	–
$J_y(z_k)$	Término de seguimiento de salida de la función de costo MPC (Ec. 16)	–
$J_u(z_k)$	Término de penalización de variables manipuladas de la función de costo MPC (Ec. 17)	–
$J_{\Delta u}(z_k)$	Término de penalización de tasa de cambio de las acciones de control (Ec. 18)	–
$J_\varepsilon(z_k)$	Término de penalización de la variable de holgura (Ec. 19)	–
k	Índice de paso de tiempo discreto actual	–
n	Índice de muestra utilizado en las sumatorias de RECM y R^2 (Ecs. 12–13)	–
n_a	Orden del polinomio autorregresivo $A(q)$ (número de polos)	–
n_b	Orden del polinomio de entrada $B(q)$ (número de ceros)	–
n_c	Orden del polinomio de ruido $C(q)$ en el modelo ARMAX	–
n_k	Retardo de entrada del modelo ARX/ARMAX (número de muestras) (Ec. 1)	–
n_u	Número de variables manipuladas en la formulación MPC	–
n_y	Número de variables controladas en la formulación MPC	–
N	Número de muestras de datos utilizadas en los cálculos de RECM y R^2 (Ecs. 12–13)	–
N	Número de etapas teóricas de la columna de destilación (modelo MESH, Ec. 9)	–
N_{ec}	Número de ecuaciones algebraicas que describen la columna en un instante dado (Ec. 9)	–
N_{et}	Número total de ecuaciones resueltas durante la simulación dinámica (Ec. 10)	–
N_i	Número de intervalos de tiempo en la simulación dinámica (Ec. 10)	–
p	Horizonte de predicción del MPC (Ecs. 14–18)	pasos
P_1	Temperatura de la variable controlada tras la primera perturbación (Tabla 5–6)	°C
P_2	Temperatura de la variable controlada tras la segunda perturbación (Tabla 5–6)	°C
q	Operador de avance (adelanto)	–
q^{-1}	Operador de retardo unitario	–
Q_R	Calor del rehervidor (genérico)	kW
$Q_{R,T-101}$	Calor del rehervidor de la columna extractiva T-101 (variable manipulada)	kW
$Q_{R,T-102}$	Calor del rehervidor de la columna de recuperación de solvente T-102 (variable manipulada)	kW
R^2	Coefficiente de determinación (métrica de ajuste, Ec. 13)	–
$r_j(k+i k)$	Referencia predicha (setpoint) para la salida j en el paso de predicción i (Ec. 16)	–
$RECM$	Raíz del Error Cuadrático Medio (Ec. 12)	°C
RR_{T-101}	Razón de reflujo de la columna T-101 (variable manipulada)	–
RR_{T-102}	Razón de reflujo de la columna T-102 (variable manipulada)	–
s_j^u	Factor de escala para la variable manipulada j en el costo MPC (Ecs. 17–18)	–
s_j^y	Factor de escala para la variable de salida j en el costo MPC (Ec. 16)	–
SP	Temperatura de referencia (setpoint) (Tabla 5–6)	°C
t	Tiempo continuo; también variable de integración en IAE, ISE, ITAE, ITSE	h
t_1	Tiempo de estabilización tras la primera perturbación (Tabla 5–6)	h

t_2	Tiempo de estabilización tras la segunda perturbación (Tabla 5–6)	h
T	Temperatura (genérica)	°C
$T_{36,T-101}$	Temperatura en la etapa 36 de la columna T-101 — variable controlada de T-101	°C
$T_{8,T-102}$	Temperatura en la etapa 8 de la columna T-102 — variable controlada de T-102	°C
u	Variable manipulada (genérica)	—
$u(k)$	Señal de variable manipulada en tiempo discreto	—
$\bar{u}(k)$	Señal de entrada en tiempo discreto en la formulación ARX/ARMAX (Ec. 1)	—
$u(t)$	Vector de entradas en tiempo continuo (espacio de estados, Ec. 7)	—
$u_j(k+i k)$	Variable manipulada j predicha en el paso i (Ecs. 17–18)	—
$u_{j,target}(k+i k)$	Valor objetivo (estado estable deseado) para la variable manipulada j (Ec. 17)	—
$w_{i,j}^y$	Peso de sintonización MPC para la salida j en el paso i (Ec. 16)	—
$w_{i,j}^u$	Peso de sintonización MPC para la variable manipulada j en el paso i (Ec. 17)	—
$w_{i,j}^{\Delta u}$	Peso de sintonización MPC para la tasa de cambio de la variable manipulada j (Ec. 18)	—
$x(t)$	Vector de estados en tiempo continuo (Ec. 7)	—
$\dot{x}(t)$	Derivada temporal del vector de estados (Ec. 7)	—
X	Variable de proceso genérica utilizada en la normalización por desviación (Ec. 11)	—
X_{desv}	Desviación relativa de la variable X respecto a su valor nominal de operación (Ec. 11)	—
$X_{nominal}$	Valor nominal (estado estacionario) de la variable X (Ec. 11)	—
y	Variable de salida controlada (genérica)	—
$y(k)$	Señal de salida del sistema en tiempo discreto (formulación ARX/ARMAX)	—
$\bar{y}(k)$	Señal de salida en tiempo discreto en la formulación ARX/ARMAX (Ec. 1)	—
$y(t)$	Vector de salidas en tiempo continuo (espacio de estados, Ec. 8)	—
$y_j(k+i k)$	Salida controlada j predicha en el paso i (Ec. 16)	—
y_n	Salida observada (modelo riguroso) en la muestra n (Ecs. 12–13)	—
$\hat{y}_n$	Salida predicha por el modelo subrogado en la muestra n (Ecs. 12–13)	—
$\bar{y}$	Media de las muestras de salida observadas; utilizada en el denominador de R^2 (Ec. 13)	—
$Y(t)$	Salida del proceso controlado en tiempo continuo (Ec. 20)	°C
$Y_{ref}(t)$	Valor de referencia (setpoint) de la salida del proceso (Ec. 20)	°C
z_k	Vector de decisión MPC — secuencia de acciones de control futuras y variable de holgura (Ec. 14)	—
z_k^T	Transpuesta del vector de decisión MPC (Ec. 14)	—

B. Símbolos griegos

Símbolo	Descripción	Unidad
Δ	Operador de diferencia finita / incremento (p.ej. Δu : cambio en la variable manipulada)	—
ε_k	Variable de holgura para la relajación de restricciones blandas en el paso k (escrita como ϵ_k en la Ec. 14 y como ε_k en la Ec. 19; ambas se refieren a la misma variable)	—
ρ_ε	Coefficiente de penalización sobre la variable de holgura en el costo MPC (Ec. 19)	—

C. Subíndices

Subíndice	Descripción
36	Etapa 36 de la columna T-101 (ubicación de medición de temperatura)
8	Etapa 8 de la columna T-102 (ubicación de medición de temperatura)
a	Orden del polinomio autorregresivo
b	Orden del polinomio de entrada
c	Orden del polinomio de ruido
ec	Conteo de ecuaciones algebraicas (modelo MESH)
et	Conteo total de ecuaciones en la simulación dinámica
i	Índice de paso de predicción dentro del horizonte MPC
j	Índice de variable controlada o variable manipulada
k	Paso de tiempo discreto actual
n	Índice de muestra en las métricas de ajuste estadístico (RECM, R^2)
R	Rehervidor (utilizado en Q_R , $Q_{R,T-101}$, etc.)
ref	Valor de referencia (setpoint)
T-101	Identificador de la columna de destilación extractiva
T-102	Identificador de la columna de recuperación de solvente

E. Abreviaturas

Abreviatura	Descripción
ARMAX	AutoRegressive Moving Average with eXogenous inputs (Autorregresivo de media móvil con entradas exógenas)
ARX	AutoRegressive with eXogenous inputs (Autorregresivo con entradas exógenas)
CPU	Central Processing Unit (Unidad Central de Procesamiento)
DMSO	Dimetilsulfóxido (solvente de destilación extractiva)
FOPDT	First-Order Plus Dead Time (Primer orden con tiempo muerto)
IAE	Integral of Absolute Error — Integral del valor absoluto del error (Ec. 21)
ISE	Integral of Squared Error — Integral del error cuadrático (Ec. 22)
ITAE	Integral of Time-weighted Absolute Error — Integral del valor absoluto del error ponderado por el tiempo (Ec. 23)
ITSE	Integral of Time-weighted Squared Error — Integral del error cuadrático ponderado por el tiempo (Ec. 24)
MESH	Mass, Equilibrium, Summation and Heat (marco de modelado de columnas de destilación)
MIMO	Multiple Inputs, Multiple Outputs (múltiples entradas, múltiples salidas)
MISO	Multiple Inputs, Single Output (múltiples entradas, una salida)
MPC	Model Predictive Control — Control Predictivo Basado en Modelo
NLARX	NonLinear AutoRegressive with eXogenous inputs (Autorregresivo no lineal con entradas exógenas)
PFD	Process Flow Diagram — Diagrama de Flujo del Proceso
PI	Controlador Proporcional-Integral
PID	Controlador Proporcional-Integral-Derivativo
QP	Quadratic Programming — Programación Cuadrática
RAM	Random Access Memory — Memoria de Acceso Aleatorio
RECM	Raíz del Error Cuadrático Medio (Ec. 12)
SISO	Single Input, Single Output (una entrada, una salida)
SS	State Space — Espacio de Estados

8 Anexos

8.1 Tablas de parámetros

Tabla 8. Condiciones de las corrientes de alimentación

Parámetro	Corriente azeotrópica	Solvente
Flujo [kmol/h]	100	150
Temperatura [°C]	47	47
Presión absoluta [bar]	3	3
Composición molar	0,5 – 0,5	1

Tabla 9. Condiciones de operación de las columnas

Parámetro	T-101	T-102
Presión absoluta [bar]	1	1
Flujo de destilado [kmol/h]	50	50,5
Razón de reflujo [mol/mol]	1	0,5
Número de etapas	37	17
Etapas de alimentación	24	8
Etapas de alimentación del agente separador	4	—

Tabla 10. Parámetros de sintonización de controladores PI

Controlador	Nivel de Condensador T-101	Nivel de Rehervidor T-101	Presión T-101	Nivel de Condensador T-102	Nivel de Rehervidor T-102	Presión T-102
Ganancia (%/%)	4,145	259,658	1,108	483,133	758,406	2,249
Constante de tiempo τ [min]	13,20	5,28	5,99	3,96	6,60	2,00

8.2 Figuras adicionales




Figura 9. Esquema general del controlador MPC.




Figura 7. Diagrama del proceso de destilación extractiva.




Figura 8. Diagrama del control implementado en Simulink.

8.3 Parámetros de los metamodelos

Tabla 11. Parámetros de los modelos de espacio de estados

Estado	A_i	$B_{1,i}$	$B_{2,i}$	C_i
SS-T101				
1	$[-41.655, -49.448, -11.960, 9.380, \dots, 26.246]$	-35.724	-51.136	-0.100
2	$[-5.326, -27.083, -9.948, 9.762, \dots, 29.930]$	36.406	-25.489	0.116
3	$[10.541, 1.169, -3.682, 10.149, \dots, 23.047]$	37.626	1.090	-0.089
4	$[-2.281, -4.874, -5.059, -2.856, \dots, -24.919]$	-12.244	-1.923	-0.014
5	$[-3.141, -1.297, 1.134, 4.075, \dots, -21.496]$	-23.773	0.404	0.053
6	$[2.365, 0.575, -1.673, -4.301, \dots, 34.320]$	53.140	-7.741	0.013
7	$[-1.560, -1.509, -0.196, -1.116, \dots, -19.207]$	5.868	-2.972	0.001
8	$[0.473, 1.124, 1.055, 0.045, \dots, 22.195]$	14.265	-3.948	-0.009
9	$[0.046, 1.309, 1.704, 4.322, \dots, -31.655]$	-61.955	11.695	-0.013
10	$[-3.113, -4.404, -1.517, -5.524, \dots, 71.055]$	82.031	-17.452	-0.043
11	$[-0.695, -1.063, -0.714, -1.194, \dots, 23.119]$	15.281	-3.157	-0.028
12	$[0.860, 1.355, 0.502, 1.572, \dots, -29.076]$	-267.557	59.473	0.024
13	$[3.162, 3.380, 0.714, 4.249, \dots, -307.461]$	-347.218	67.553	0.032
SS-T102				
1	$[5.290, 7.568, 13.909, -1.207, \dots, -379.285]$	459.701	-186.502	-0.627
2	$[6.534, 4.208, 19.349, -0.231, \dots, -168.272]$	212.734	-83.893	0.411
3	$[-16.876, -22.461, -4.348, 8.047, \dots, 210.423]$	-300.916	103.820	0.069
4	$[10.072, 9.761, -2.790, 0.628, \dots, -343.757]$	431.665	-164.476	0.120
5	$[-12.012, -14.175, 3.581, -16.123, \dots, 368.584]$	-493.973	183.489	0.011
6	$[14.530, 10.441, 3.549, 4.795, \dots, -378.990]$	523.556	-195.367	0.033
7	$[-13.793, -11.231, -6.545, 1.252, \dots, 325.515]$	-501.844	170.494	0.048
8	$[-2.810, -2.390, -1.212, 0.593, \dots, 93.562]$	-123.083	47.610	-0.807
9	$[-1.659, -0.068, -1.629, -0.456, \dots, 36.076]$	-60.950	27.741	-0.043
10	$[0.574, 0.682, 0.160, -0.201, \dots, -23.202]$	36.153	-14.139	0.654
11	$[0.807, -0.032, 0.606, 0.480, \dots, -8.720]$	7.865	-4.027	0.853
12	$[-1.459, -0.762, -0.775, -0.357, \dots, 32.508]$	-47.033	18.620	0.058
13	$[-2.253, -1.489, -1.114, -0.126, \dots, 41.423]$	-64.506	22.583	-0.560
14	$[-0.288, -0.338, 0.040, -0.068, \dots, 12.602]$	-7.311	2.070	-1.404
15	$[0.575, 0.360, 0.254, 0.058, \dots, -15.549]$	17.748	-6.781	-3.085

Tabla 12. Parámetros de modelos de subrogación para T-101

Modelo	Entrada	Parámetros
ARX-T101	-	$A = [1.000, -1.356, 0.200, -0.001, 0.119, 0.080, 0.005, -0.028, -0.030, -0.001, 0.010]$ $B_1 = [0.000, 0.164, -0.158, -0.027, -0.009, 0.012, 0.018, 0.010, 0.002, -0.009, -0.002, 0.002, 0.001, 0.001, -0.003]$ $B_2 = [0.000, 0.004, -0.041, 0.040, 0.000, 0.001, -0.003, -0.004, -0.001, 0.001, 0.002, 0.001]$
ARMAX-T101	-	$A = [1.000, -3.882, 5.962, -4.459, 1.470, 0.033, -0.176, 0.086, -0.051, 0.028, -0.022, 0.019, -0.013, 0.006, -0.001]$ $B_1 = [0.000, 0.164, -0.572, 0.755, -0.438, 0.065, 0.045, -0.021, 0.006, -0.011, 0.017, -0.014, 0.004, 0.001]$ $B_2 = [0.000, 0.004, -0.051, 0.153, -0.199, 0.125, -0.028, -0.008, 0.008, -0.004, 0.001]$ $C = [1.000, -2.530, 2.345, -0.789, -0.185, 0.165]$
TF-T101	-	$b_{z1} = [3820.400, 17617.000]$ $b_{z2} = [-34.711, -14016.000]$ $a_{p1} = [1.000, 212.299, 10892.000, 50753.000]$ $a_{p2} = [1.000, 77.591, 5064.300, 181330.000]$ $\tau_1 = 1, \quad \tau_2 = 2$
FOPDT-T101	-	$K_{p1} = 0.358, \quad K_{p2} = -0.079$ $\tau_1 = 0.125, \quad \tau_2 = 0.203$ $\theta_1 = 0.000, \quad \theta_2 = 0.050$

Tabla 13. Parámetros de modelos de subrogación para T-102

Modelo	Entrada	Parámetros
ARX-T102	-	$A = [1.000, -1.753, 0.895, -0.168, 0.210, -0.086, -0.286, 0.247, -0.064, 0.068, -0.100, 0.028, 0.013, -0.010, 0.005]$ $B_1 = [0.000, 0.310, -0.410, 0.086, 0.017, 0.115, -0.001, -0.169, 0.049, 0.014, 0.037, -0.037, -0.010]$ $B_2 = [0.000, -0.036, 0.054, -0.020, 0.003, -0.011, -0.012, -0.001, 0.022, 0.007, -0.010, -0.003, 0.002, 0.006]$
ARMAX-T102	-	$A = [1.000, -2.548, 2.294, -0.909, 0.157, 0.042, -0.090, 0.110, -0.098, 0.072, -0.047, 0.018, 0.002, -0.002, -0.001]$ $B_1 = [0.000, 0.310, -0.657, 0.414, -0.060, 0.040, -0.028, -0.096, 0.094, -0.028, 0.020, -0.009]$ $B_2 = [0.000, -0.036, 0.082, -0.063, 0.021, -0.007, -0.012, 0.003, 0.033, -0.012, -0.011, 0.004, -0.002, 0.000]$ $C = [1.000, -0.800, 0.014, -0.025, -0.239, -0.092, 0.199]$
TF-T102	-	$b_{z1} = [-12642.000, 573210.000]$ $b_{z2} = [-765.156, -29177.000]$ $a_{p1} = [1.000, 104.584, 16107.000, 581590.000]$ $a_{p2} = [1.000, 214.425, 9192.300, 261610.000]$ $\tau_1 = 1, \quad \tau_2 = 1$
FOPDT-T102	-	$K_{p1} = 1.010, \quad K_{p2} = -0.113$ $\tau_1 = 0.222, \quad \tau_2 = 0.255$ $\theta_1 = 0.000, \quad \theta_2 = 0.000$